



La théorie des espaces conceptuels

Applications et limites

Sous la direction de

M. Igor Douven et M. Max Kistler

par

Gwendal Tsang

Année universitaire 2023-2024

Remerciements

Je tiens à remercier M. Kistler et M. Douven pour avoir encadré ce mémoire avec bienveillance et prodigué des conseils éclairants et précieux tout au long de sa rédaction. Je dois beaucoup à tous mes professeurs, qui prennent toujours le temps de répondre à mes questions même si elles sont parfois bêtes, et de me diriger vers des livres, des articles ou toutes autres références.

Je suis reconnaissant envers David Waszek, Alberto Naibo, Jean Fichot et Mirna Dzamonja pour avoir suscité mon intérêt pour les sciences formelles par leur passion communicative. Merci à Denis Forest, Denis Bonnay et Philippe Lusson, qui m'ont initié au domaine passionnant de la philosophie des sciences cognitives. Je remercie tous les professeurs rattachés à l'IHPST pour m'avoir donné goût à la philosophie des sciences.

Ce mémoire a été rendu possible grâce à tous mes professeurs, y compris ceux de lycée et de collège qui m'ont marqué. Je remercie particulièrement Cécile Poulolo-Romain, Nathalie Guérault et Lucie Lebouteiller.

Merci à François S., à Baptiste L.-D. et à Camille F. pour leur présence bienveillante.

Merci à tout le personnel de l'université Paris-1, de l'ICP et de l'ENS. Merci au personnel et aux camarades du bâtiment Ricœur de l'université de Nanterre pour la convivialité.

Merci à Hippolyte S., Siân-José P. et Lucas G. pour leur soutien et pour m'avoir offert une atmosphère de légèreté, de joie et de rires.

Enfin, mon travail doit beaucoup à mes parents et à ma grand-mère, qui m'ont beaucoup encouragé et soutenu tout au long de la rédaction de ce mémoire. Merci infiniment.

Sommaire

Qu'est-ce qu'un espace conceptuel ?

- 0.1. Dimensions et modalités sensorielles
- 0.2. Les propriétés, les concepts et les instances
- 0.3. Comment construire un espace de similarité ?
 - Première étape : collecter des données empiriques
 - Deuxième étape : faire une réduction de la dimensionnalité
- 0.4. La similarité comme proximité, la dissimilarité comme distance
- 0.5. De l'espace de similarité à l'espace conceptuel
- 0.6. Limites de l'applicabilité de la théorie des espaces conceptuels

Chapitre 1. Application de la théorie des espaces conceptuels aux couleurs

- 1.1. De RGB à HSL
- 1.2. Partir des expériences psychophysiques sur la vision humaine
- 1.3. Les propriétés des couleurs comme des régions dans l'espace colorimétrique
- 1.4. Représentation de la catégorisation d'une couleur : de la similarité aux prototypes
 - 1.4.1. $\text{Sim}(x, y) > \text{Sim}(x, z) \Rightarrow P(\exists i : C_i(x) \wedge C_i(y)) \geq P(\exists i : C_i(x) \wedge C_i(z))$
 - 1.4.2. Représenter la similarité par la proximité
 - 1.4.3. La catégorisation dans la théorie des exemplaires
 - 1.4.4. La catégorisation dans la théorie du prototype
- 1.5. Critiques et améliorations de la technique des diagrammes de Voronoï
 - 1.5.1. Critique de l'unicité du prototype
 - 1.5.2. Accorder aux cas-limites un espace propre

Au-delà des couleurs : le défi de la sémantique lexicale

Chapitre 2. Distorsions de la mémoire basées sur la similarité

- 2.1.2. Résultats de l'expérience de Roediger & McDermott (1995)
- 2.2. Mesurer la force associative entre deux mots
- 2.3. La relation étroite entre force associative et degré de similarité
 - 2.3.1. WAS pour la force associative et LSA pour le degré de similarité

- 2.3.2. Les espaces d'association de mots sont un bon indicateur...
- 2.3.3. Évaluer la porosité entre force associative et degré de similarité
- 2.3.4. Spatialisation des relations associatives et de similarité
- 2.3.5. Que la similarité globale peut être décomposée en similarités locales...
- 2.4. Traitement relationnel et traitement distinctif
 - 2.4.1. Résultats des expériences comparant traitement relationnel et spécifique
 - 2.4.2. L'appauvrissement du traitement relationnel
 - 2.4.3. L'heuristique de la distinctivité
 - 2.4.4. Expériences visant à départager les deux hypothèses
- 2.5. Tentatives de modélisations avec des espaces conceptuels
 - 2.5.1. Réadapter un modèle existant avec des espaces conceptuels
 - 2.5.2. L'indétermination comme élargissement d'une région
 - 2.5.3. L'interprétabilité des vecteurs
 - 2.5.4. Pondération différentielle
 - 2.5.5. Comment la pondération des dimensions affecte-t-elle...
 - 2.5.6. Prédire la réponse lors de l'épreuve de reconnaissance...
- 2.6. Limites

Chapitre 3. Interférences et facilitations

- 3.1. Interférences et facilitations chez les bilingues
- 3.2. Un modèle de l'interférence associative
 - 3.2.1. La récupération indicée
 - 3.2.2. L'interférence associative
 - 3.2.3. Interprétations psychologiques du modèle

Conclusion

Annexe A : Deux approches de la sémantique

Annexe B : Notions mathématiques utilisées

Annexe C - Supplément au chapitre 2

Annexe D - Les modèles GAN et la théorie des espaces conceptuels

Introduction

Gärdenfors distingue deux orientations principales au sein des théories sémantiques : d'un côté, une approche réaliste estimant que la signification des mots trouve sa source dans le monde extérieur, et de l'autre, une approche cognitive, selon laquelle la signification dérive des projets et des rêves¹. Le philosophe suédois place sa théorie des espaces conceptuels plutôt au sein de cette seconde orientation, puisqu'elle modélise la dynamique des représentations sémantiques sans référence directe au monde extérieur : la signification n'est *que* dans l'esprit des locuteurs. Ce qui compte avant tout, c'est d'expliquer ce qui rend la communication possible et comment fonctionnent certaines opérations cognitives comme la catégorisation, l'induction ou les raisonnements analogiques².

Pour saisir toute la portée de la théorie des espaces conceptuels, il est essentiel de la situer par rapport aux deux approches traditionnelles qu'elle vise à réconcilier. Il s'agit de deux familles de représentations très différentes pour un même objet d'étude : la signification des mots du langage naturel.

Dans l'approche dite symbolique, on manipule des symboles discrets selon des règles formelles (par exemple la logique des prédicats, voir annexe A). Cette approche traditionnelle, interprétable et parcimonieuse, modélise souvent un concept par un ensemble de propriétés nécessaires et suffisantes. Si cette approche fonctionne bien en mathématiques, où les frontières entre les objets sont nettes, elle atteint vite ses limites lorsqu'on l'applique à certains concepts du langage naturel. De plus, cette approche ne peut pas représenter la similarité graduelle, la typicité et les frontières floues.

À l'autre pôle, les approches non-symboliques parfois appelées "approches distribuées" représentent les concepts par des états continus : il s'agit par exemple d'associer à un concept une multiplicité de schémas d'activations dans un réseau connexionniste (par exemple, un réseau de neurones) ou de l'associer à un vecteur dans les modèles distributionnels conçus à partir de corpus de textes. Ce pôle recouvre un éventail assez large de modèles et de techniques³.

1. GÄRDENFORS (2000, p. 5.1.1), GÄRDENFORS (2014, sec. 1.2).

2. Pour une formalisation des inférences basées sur la similarité, voir DOUVEN, VERHEYEN et al. (2023)

3. Les modèles de cette catégorie qui tentent d'être plausibles sont souvent informés/évalués par des données IRMf / EEG / MEG. Mais dans cette approche rentrent aussi les réseaux de neurones artificiels qui semblent souvent

Cette dichotomie recoupe le problème plus général de l'ancrage formulé par HARNAD (1990) : Comment les mots du langage naturel acquièrent-ils une signification ? On y retrouve très schématiquement ces deux grands pôles de réponses possibles : ou bien la signification s'ancre entièrement dans le langage lui-même, ou bien elle dépend d'une strate sous-jacente et les mots ne sont que des "étiquettes" reposant sur des points d'appui extra-linguistiques.

L'ambition de Gärdenfors, avec la théorie des espaces conceptuels, est de combler le fossé entre les approches symboliques et les approches distribuées en proposant un modèle hybride. La théorie des espaces conceptuels est une tentative de représentation à la fois fine et proche des données empiriques (comme dans les modèles non-symboliques), mais qui reste parcimonieuse et interprétable (comme dans les modèles symboliques)¹. L'espace conceptuel occupe donc une *position intermédiaire* et peut être considéré comme "*semi-symbolique*". Gärdenfors distingue alors trois niveaux interdépendants : au sommet, celui des mots et des représentations linguistiques ; au niveau le plus bas se trouvent les représentations connexionnistes distribuées, souvent peu interprétables ; et, entre les deux, le niveau des espaces conceptuels, interface entre les objets continus et les unités linguistiques symboliques². Plus le niveau est haut, plus le grain est épais³.

Pour expliquer la différence entre ces trois niveaux, imaginons qu'une personne pense au visage d'un ami. Les schémas d'activation neuronale correspondent au niveau le plus bas et sont très difficilement interprétables. Au niveau le plus élevé, on trouve l'image mentale et les étiquettes linguistiques que l'on associe au visage (ex. "brun", "barbu", "yeux verts", etc.). Entre les deux se trouve l'espace conceptuel des visages, niveau intermédiaire faisant le pont entre les deux précédents : l'espace est structuré par des dimensions interprétables (couleur

viser plutôt la *performance fonctionnelle* (répondre le mieux possible à un objectif) que la plausibilité cognitive.

1. BECHBERGER (2023, p.26) : "[...] this intermediate layer with geometric representations has several advantages over both symbolic and subsymbolic approaches"

2. BECHBERGER (2023, p.26) : "Individual observations, which correspond to high-dimensional activation vectors in the subsymbolic layer, are represented by points in the lower-dimensional conceptual space and can be mapped onto constants and variables from the symbolic layer".

3. GÄRDENFORS (2000, sec. 2.4) : "[...] the conceptual level should be placed between the symbolic and the subconceptual levels in terms of representational granularity". La granularité correspond à la précision, on dira par exemple que "la France est un hexagone" ou "l'Italie est une botte" sont des descriptions ayant un grain plus épais que les images satellites de ces pays.

des yeux, forme du nez, etc.) et muni d’une métrique de similarité. Un visage particulier peut alors être décrit comme un point (ou une petite région) dans cet espace conceptuel. Ce niveau combine ainsi du continu quantitatif (des coordonnées et des distances) avec des dimensions sémantiquement interprétables, ce qui le rend à la fois proche des données et plus facile à lire.

Ce niveau intermédiaire est « semi-symbolique » parce qu’il représente le sens en combinant des traits communs aux deux approches. Il est d’abord *symbolique* de par son caractère compositionnel : la signification d’un concept se comprend comme combinaison de sous-unités sémantiques. Ces sous-unités peuvent être partiellement interprétées. Mais elle n’est symbolique *qu’en partie* : ces sous-unités se décrivent par des coordonnées dans un espace continu et peuvent seulement être *approchées* par des mots ¹.

Qu’est-ce qu’un espace conceptuel ?

0.1 Dimensions et modalités sensorielles

Pour commencer, il faut choisir des *dimensions*. Ce choix dépend de ce que l’on veut représenter. Par exemple, l’espace des couleurs comporte trois dimensions : d_{teinte} , $d_{\text{saturation}}$, $d_{\text{luminosité}}$. Chaque dimension d_i est un ensemble de valeurs numériques qui correspond à l’*espace de toutes les valeurs possibles* sur la qualité perceptive correspondante². Étant données ces trois dimensions, on peut définir l’espace des couleurs par

$$\mathcal{S}_{\text{couleur}} = d_{\text{teinte}} \times d_{\text{saturation}} \times d_{\text{luminosité}}.$$

L’espace $\mathcal{S}_{\text{couleur}}$ est tridimensionnel et contient toutes les nuances de couleurs.

De manière analogue, pour représenter des sons simples, on peut retenir les deux dimensions³ : d_{volume} , d_{hauteur} . L’espace induit est le produit cartésien des deux dimensions correspon-

1. Dans les sections 0.1 et 0.2 nous exposons la théorie des espaces conceptuels dans sa version minimale, laquelle nous paraît plutôt du côté de l’approche symbolique que de l’autre côté. Mais le cadre peut être enrichi et amendé. Ainsi, certaines variantes du modèle, comme celle de BECHBERGER (2023), tirent la théorie plutôt du côté des approches non-symboliques et distribuées.

2. Souvent un intervalle de $\mathbb{R}$, mais d’autres représentations sont possibles. Dans la mesure où il y a des limites perceptives, ces dimensions sont souvent modélisées par des intervalles bornés.

3. Aussi bien pour les couleurs que pour les sons, la relation entre grandeurs physiques et sensations n’est pas

dant à ces deux attributs :

$$\mathcal{S}_{\text{son}} = d_{\text{hauteur}} \times d_{\text{volume}}$$

Selon Gärdenfors, les différentes dimensions qui composent une même modalité sensorielle sont toujours perçues simultanément dans notre expérience subjective. Par exemple, une nuance de couleur est perçue conjointement selon sa teinte, sa saturation et sa luminosité, nous l’appréhendons toujours *selon ses trois dimensions conjointement*. Il en conclut qu’il faut toujours représenter *toute* une modalité sensorielle en même temps. Il propose de tenir chaque modalité pour un *bloc* en regroupant ensemble ses différentes dimensions. Ainsi, une *modalité sensorielle*, notée δ , est définie comme un ensemble fini de dimensions :

$$\delta = \{ d_1, \dots, d_n \}.$$

Bien qu’une modalité δ *contienne* plusieurs espaces d_i , elle *n’est pas elle-même un espace*. Toutefois, chaque modalité sensorielle δ est effectivement associée à un unique espace, appelé *domaine*. Le domaine associé à la modalité δ est le produit cartésien des petits espaces qu’elle contient, et se note :

$$\mathcal{S}_{\delta} = \prod_{d \in \delta} d = d_1 \times \dots \times d_n.$$

$\mathcal{S}_{\text{couleur}}$ et $\mathcal{S}_{\text{son}}$ sont deux exemples de *domaines*.

0.2 Les propriétés, les concepts et les instances

Dans un espace conceptuel, une **propriété** est représentée par une *région* dans un *domaine sensoriel unique* $\mathcal{S}_{\delta}$. Une propriété correspond à une qualité ou un attribut exprimé par un adjectif associé à une seule modalité sensorielle, par exemple « ROUGE » est une région dans $\mathcal{S}_{\text{couleur}}$, « AIGU » est une région dans $\mathcal{S}_{\text{son}}$, « RUGUEUX » une région dans $\mathcal{S}_{\text{toucher}}$, etc.

L’espace contenu dans cette région correspond non seulement aux informations sur les membres déjà observés, mais aussi sur les membres *potentiels* non encore rencontrés. Étant définie sur plusieurs dimensions d’un domaine, l’extension de la région indique toutes les

linéaire et varie selon le contexte, donc il est nécessaire que ces dimensions dérivent d’un étalonnage basé sur des méthodes psychophysiques. Pour une revue complète des relations entre les paramètres physiques du son et les sensations perceptives (intensité sonore, hauteur, timbre, etc.) voir MOORE (2013). Pour le cas des couleurs, voir la section 1.2.

combinaisons de valeurs possibles sur ces dimensions pour les membres de la catégorie correspondante. Ainsi, la propriété ROUGE est appréhendée comme une *région* dans le domaine des couleurs. Ces propriétés sont *graduelles* car elles peuvent prendre des valeurs *continues* dans des intervalles définis sur chaque dimension du domaine¹. Plus précisément, si $\delta_{couleur}$ est l'ensemble des dimensions pour la modalité des couleurs, alors, pour chaque dimension $d_i \in \delta_{couleur}$, il existe un intervalle de valeurs correspondant à l'extension du *rouge* sur cette dimension.

Dans un espace conceptuel, chaque *exemplaire* d'une propriété est représenté par un *point* situé à l'intérieur de la région correspondant à cette propriété. Nous parlerons indifféremment d'un exemplaire ou d'une *instance* pour renvoyer à un point². Par exemple, une nuance de couleur est notée $\mathbf{x} = (x_{teinte}, x_{saturation}, x_{luminosité})$ et un son particulier dans l'espace S_{son} est noté $\mathbf{x} = (x_{sonie}, x_{hauteur})$.

Dans le langage courant, l'expression "couleur spécifique" peut faire référence soit à une *région*, soit à un *exemplaire*. Pour éviter cette ambiguïté et distinguer ces deux genres d'emplois, lorsqu'un mot réfère à une *région*, nous l'écrirons en petites lettres majuscules. Par exemple, cette différence apparaît explicitement dans la phrase : « cette nuance de rouge est un *point* dans la *région* du ROUGE ». Cette notation permet de distinguer les *petites régions* correspondant à des *propriétés spécifiques* des simples points représentant des exemplaires³. Cette convention permet par exemple de distinguer « ce carmin *appartient* au ROUGE » de l'énoncé « la région CARMIN *est incluse* dans le ROUGE ».

Contrairement aux *propriétés*, les *concepts* recouvrent plusieurs modalités sensorielles. Chaque concept est *défini* par une combinaison de régions provenant de différents domaines.

1. Nous n'imposons ni seuil minimal ni seuil maximal à ces intervalles et donc à la taille d'une « région ». Ainsi, un intervalle de $\mathbb{R}$ aussi petit soit-il peut être pris pour une région, et — à l'autre extrémité — l'ensemble tout entier du domaine peut également être considéré comme une région (la plus grande).

2. Comme on le verra dans la suite de ce mémoire, le fait de considérer un exemplaire comme un *point* est une idéalisation. Car la position du point, à un niveau de granularité très fin, est imprécise. Cette imprécision peut être représentée par (1) un intervalle, (2) une distribution de probabilité sur la dimension, ou (3) un ensemble flou via une fonction d'appartenance. En pratique, c'est le cas, par exemple, des sons complexes ou inharmoniques, où la hauteur perçue peut être ambiguë.

3. Le mot "exemplaire" a ici seulement une signification cognitive sans référence directe au monde, i.e. on admet que deux nuances absolument identiques constituent un même exemplaire

Ces régions contiennent *toutes les instances possibles* de ce concept sur leur domaine respectif. Par exemple, le concept de « pomme » est représenté par des régions dans quatre domaines : la couleur (e.g. rouge, vert, jaune), le goût (e.g. variant de sucré à acidulé), la forme (e.g. ronde, ovale, cycloïde), la texture (e.g. croquante, molle). Plus formellement, on note Δ l'ensemble des domaines sensoriels pertinents pour le concept de « pomme », et S_Δ l'espace produit :

$$\Delta = \{ \delta_{\text{couleur}}, \delta_{\text{goût}}, \delta_{\text{forme}}, \delta_{\text{texture}} \}, \quad S_\Delta = S_{\delta_{\text{couleur}}} \times S_{\delta_{\text{goût}}} \times S_{\delta_{\text{forme}}} \times S_{\delta_{\text{texture}}}.$$

où chaque δ_i renvoie à l'une de ces différentes modalités sensorielles (contenant, à l'intérieur d'elles, les dimensions de la modalité sensorielle spécifique). Attention : il ne faut pas identifier S_Δ à un "espace des pommes" : tel qu'il est défini S_Δ contient un potentiel de signification qui va bien au-delà des pommes. Ainsi, il existe énormément de points dans S_Δ qui ne sont *pas* des pommes. On peut par exemple déterminer un point dans S_Δ qui correspond plus à un citron qu'à une pomme. Les pommes ne se trouvent que dans une petite parcelle de cet espace. Pour saisir l'extension du concept de pomme, noté **POMME**, qui correspond à un sous-ensemble de cet espace, il faut déterminer dans chaque domaine une région :

$$\begin{aligned} \mathcal{R}_{\delta_{\text{couleur}}}^{\text{pomme}} &= \text{ROUGE, VERT OU JAUNE} \\ \mathcal{R}_{\delta_{\text{goût}}}^{\text{pomme}} &= \text{SUCRÉ à ACIDULÉ} \\ \mathcal{R}_{\delta_{\text{forme}}}^{\text{pomme}} &= \text{RONDE à OBLONGUE} \\ \mathcal{R}_{\delta_{\text{texture}}}^{\text{pomme}} &= \text{CROQUANTE OU MOLLE} \end{aligned}$$

Où $\mathcal{R}_{\delta}^{\text{POMME}}$ se lit « la région du concept **POMME** pour la modalité δ ».

Dans l'espace conceptuel défini sur tous ces domaines, la région correspondant à l'extension du concept **POMME** est donc :

$$\mathbf{POMME} = \prod_{\delta \in \Delta} \mathcal{R}_{\delta}^{\text{pomme}} \subseteq S_\Delta.$$

Une *pomme singulière* est un point $x \in \mathbf{POMME}$ dont chaque composante $x_{|\delta}$ appartient à $\mathcal{R}_{\delta}^{\text{pomme}}$. Autrement dit, une instance de ce concept est un point dont les coordonnées reflètent les valeurs précises de cette pomme en termes de couleur, goût, forme, et texture.

Plus généralement pour un concept **C** notons Δ l'ensemble des domaines pertinents (Δ est l'ensemble des δ dans lequel le concept prend sens). Les régions associées à **C** dans chaque

domaine sont notées :

$$\mathcal{R}_\delta^C \subseteq \mathcal{S}_\delta \quad (\delta \in \Delta).$$

Le concept **C** est alors représenté par :

$$\mathcal{R}^C := \prod_{\delta \in \Delta} \mathcal{R}_\delta^C \subseteq \mathcal{S}_\Delta.$$

Cette définition explicite le fait que chaque composante $\mathcal{R}_\delta^C$ est un sous-ensemble du domaine associé $\mathcal{S}_\delta$. Cela montre que la représentation dans un espace conceptuel est "*compositionnelle*" : tous les exemplaires spécifiques d'un concept sont des points localisés dans chacune de ses régions en fonction de leurs attributs sur chaque dimension¹.

Descendre en deçà des représentations symboliques

Revenons sur l'exemple de l'espace conceptuel du concept de **POMME** précédemment construit. Il s'agit d'un espace conceptuel *fabriqué à la main*², c'est-à-dire que les propriétés de ce concept sont déterminées *a priori*. La construction de cet espace conceptuel s'adosse à une hypothèse très forte de compositionnalité linguistique selon laquelle les régions du concept de **POMME** sur tous les domaines correspondent à des combinaisons de régions associées à des propriétés connues, exprimées par des adjectifs disponibles dans le langage. Or, la compositionnalité sur laquelle s'appuie la théorie des espaces conceptuels est *plus faible* que cette compositionnalité linguistique : la sémantique d'un concept ne peut pas être décomposée en unités linguistiques *connues*. En effet, en général, *aucun adjectif connu* ne correspond précisément à la région correspondant à un concept sur un domaine donné. Par exemple, la région correspondant à l'extension du concept de **CERISE** sur le domaine des couleurs est beaucoup plus fine et subtile que la propriété ROUGE. En général, les espaces "faits main" ont le mérite de définir le concept d'une manière *interprétable* et *intuitive*, mais ont le désavantage de ne pas avoir de pouvoir prédictif, puisqu'ils ne définissent pas chaque propriété du concept de manière

1. Deux remarques formelles concernant l'opérationnalisation de ce modèle s'il y a plusieurs concepts. Par exemple si on manipule deux concepts *A* et *B* simultanément, il faut ajouter un indice et noter Δ_A , Δ_B pour les distinguer. Ces deux concepts *A*, *B* peuvent être définis sur des ensembles de modalités différents Δ_A et Δ_B . Pour comparer de tels concepts (distance, similarité, etc.), on se place en général sur leur partie commune $\Delta_A \cap \Delta_B$. Voir BECHBERGER et KÜHNBERGER (2017).

2. BECHBERGER (2023, p.46) : "Handcrafting a conceptual space usually consists in manually defining the dimensions of the conceptual space based on the available sensors".

quantitative à partir de données empiriques.

C'est l'une des raisons pour lesquelles, aujourd'hui, une part de la recherche tente d'obtenir des espaces conceptuels en traitant des données. Dans la mesure où on peut *mener des expérimentations* pour déterminer les coordonnées de la région associée à un concept dans un domaine δ ou d'une région associée à un adjectif dans ce domaine, on peut *théoriquement* visualiser et quantifier le caractère approximatif de la première vis-à-vis de la seconde¹.

Les sections qui suivent expliquent comment construire un espace conceptuel qui n'est pas fabriqué à la main mais qui est conçu de manière à être sémantiquement plausible. La section 0.3 expose d'abord la méthode pour obtenir un espace de similarité, puis la section 0.5 explique comment l'enrichir pour le transformer en espace conceptuel. L'objectif est double : (i) *représenter* la dissimilarité perçue entre stimuli par une distance dans un espace de faible dimension, et (ii) *modéliser* l'extension des concepts/propriétés par des régions de cet espace de sorte que des stimuli perceptuellement proches tombent dans la même région.

0.3 Comment construire un espace de similarité ?


Première étape : collecter des données empiriques

Avant de construire un espace de similarité, il faut tout d'abord obtenir des données empiriques sur n éléments d'un même domaine qu'on souhaite y représenter. Ces n éléments sont des sous-catégories ou des instances d'une catégorie plus générale (par exemple, pour le "domaine des fleurs", on peut prendre n noms de fleurs ou bien n images de fleurs différentes).

1. Imaginons qu'on souhaite *voir* si la région associée à un adjectif (ou une combinaison d'adjectifs) dans un domaine S_δ approxime bien la région associée à un concept C dans le même domaine. Notons $\mathcal{R}_\delta^{\text{adj}}$ la première région et $\mathcal{R}_\delta^C$ la seconde région.

Admettons qu'on ait préalablement collecté des données quantitatives sur l'extension de l'adjectif et du concept sur ce domaine.

Plus grande est la zone commune aux deux régions, meilleure est l'approximation. Plus grandes sont les zones de non-recouvrement, moins bonne est l'approximation. Il y a deux zones de non-recouvrement : la surcouverture (les x qui sont dans $\mathcal{R}_\delta^{\text{adj}}$ mais pas dans $\mathcal{R}_\delta^C$) et la sous-couverture (les x qui sont dans $\mathcal{R}_\delta^C$ mais pas dans $\mathcal{R}_\delta^{\text{adj}}$). Ces trois variables peuvent être visualisées dans le schéma ci-dessous :



La première étape est donc de définir un protocole expérimental pour recueillir des mesures de similarité concernant ces n objets à représenter¹. Il faut sélectionner les stimuli, le type de tâche (jugements paire-à-paire², tâche d’arrangement spatial³, statistiques de cooccurrences⁴, etc.), la taille et la nature de l’échantillon de participants et les consignes.

Les données, qui se présentent donc sous forme de valeur de similarité, sont ensuite rangées dans une matrice de similarité. Cette matrice reflète les jugements de similarité entre les éléments : chaque cellule (i, j) de la matrice contient la similarité de i avec j . Puisque les n lignes et n colonnes de cette matrice correspondent aux mêmes objets, toutes les cellules diagonales (i, i) (pour tout entier $i \leq n$) contiennent la valeur de similarité maximale (étant admis que tout objet i est maximalement similaire à lui-même), et les deux moitiés triangulaires de chaque côté de cette diagonale sont symétriques⁵ (étant admis que, pour toute paire $(i, j) \in \llbracket 1; n \rrbracket^2$, la similarité entre i et j est égale à la similarité entre j et i).

Deuxième étape : faire une réduction de la dimensionnalité

Bien qu’il y ait une certaine diversité des *sources* et des *protocoles* pouvant être mis en œuvre pour obtenir ces données de similarité, une *même* technique de réduction de dimensionnalité revient presque systématiquement dans la littérature visant à construire des espaces conceptuels à partir de ces données. Cette technique est le *positionnement multidimensionnel* (*Multidimensional Scaling*, MDS). Le MDS permet de projeter ces éléments dans un espace de

1. DOUVEN, WENMACKERS et al. (2017, p.690) : “The structure of a conceptual space is typically determined on the basis of similarity ratings”.

2. la tâche de jugement paire-à-paire consiste à demander aux participants d’estimer la similarité entre toutes les paires possibles avec ces n éléments. C’est ce que fait MOULLEC (2024) avec un LLM.

3. DOUVEN, VERHEYEN et al. (2023) utilisent cette technique et disent que c’est beaucoup plus rapide et moins lourd qu’une tâche de jugement paire-à-paire

4. Par exemple BENDIFALLAH et al. (2025) demandent aux participants de regrouper des noms en plusieurs groupes. Ils calculent ensuite une similarité basée sur la fréquence de cooccurrence de deux noms dans un même groupe (si un participant met deux noms dans un même groupe, cela compte comme *une* cooccurrence). On peut employer diverses méthodes de statistiques de cooccurrences, par exemple DERRAC et SCHOCKAERT (2015) quantifient la cooccurrence entre deux mots en utilisant le PPMI.

5. SHEPARD (1974) : “(. . .) these measures to be arrayed in the below-diagonal triangular half of an $n \times n$ matrix which the n rows and n columns correspond to the same n objects”.

plus faible dimensionnalité, tout en préservant au mieux les relations de similarité initiales¹. Plus précisément, il s'agit de minimiser une fonction de coût appelée *Stress*, qui mesure l'écart entre les similarités initiales et les distances dans l'espace projeté².

La qualité de l'ajustement obtenu se visualise dans un graphique appelé *diagramme de Shepard*. Plus précisément, un diagramme de Shepard représente la relation entre les similarités initiales dans la matrice et les distances obtenues dans l'espace après application du MDS. Les relations de similarité des données initiales sont figurées sur l'axe des abscisses tandis que les distances entre les paires d'éléments sont sur l'axe des ordonnées. Idéalement, si les distances dans l'espace projeté correspondent parfaitement aux similarités initiales, les points dans un diagramme de Shepard devraient se situer exactement sur une droite monotone décroissante³. A l'inverse, moins l'espace est fidèle aux dissimilarités initiales, plus ces points s'écarteront de cette droite. En général, les espaces de faible dimension sont plus interprétables, mais risquent d'être moins fidèles aux données. A l'inverse, les espaces de grande dimension sont plus fidèles aux données, mais moins interprétables⁴. Les diagrammes de Shepard aident à trouver le meilleur compromis.

L'application du MDS à une matrice de dissimilarité crée ainsi un espace de similarité de faible dimension (2D ou 3D), sous la forme d'une configuration de points, dans lequel les distances géométriques reflètent les dissimilarités d'origine. Cependant, l'espace de similarité obtenu à la suite d'un MDS mérite encore d'être enrichi pour mériter l'appellation d'« espace conceptuel ». Mais qu'est-ce qu'un espace conceptuel a *en plus* d'un espace de similarité ? Premièrement, dans un espace de similarité, chaque concept et chaque propriété sont représen-

1. BECHBERGER (2023, p.642) : "MDS is capable of successfully compressing this information into very low-dimensional spaces".

2. Formellement, appliqué à la matrice de dissimilarité obtenue à l'étape précédente (d_{ij}), le MDS cherche des points $\mathbf{x}_1, \dots, \mathbf{x}_n$ dans $\mathbb{R}^m$ (avec m choisi petit) tels que les distances euclidiennes s'approchent au mieux des dissimilarités dans la matrice. Voir annexe B, sec. 4.

3. BORG et GROENEN (2005, p. 43 ; 2013, p. 35) : "[Points] all lie on a monotonically descending line, as requested by the ordinal MDS model used to scale these data".

4. BORG, GROENEN et MAIR (2018) : "Increasing the dimensionality of the MDS space always makes it easier to find a solution with a better fit". Si les données de départ sont des jugements de dissimilarité, et que le MDS représente de manière fidèle ces données, les points suivront une droite monotone décroissante dans le diagramme de Shepard

tés par un *point*, tandis que dans un espace conceptuel, ils sont représentés par des *régions*. Deuxièmement, dans un espace de similarité obtenu par MDS, les dimensions peuvent rester abstraites et difficiles à interpréter. De nombreuses méthodes existent pour *enrichir* un espace de similarité. La section 0.5 vise à exposer de manière non exhaustive certaines de ces méthodes.

L'espace obtenu à la suite d'un MDS peut être considéré comme un domaine S_δ si chaque élément qu'il contient est ou bien une *instance* ou bien une *sous-catégorie* d'une autre catégorie plus générale. L'expérience de SHEPARD (1974) illustre ce principe : les stimuli à représenter étaient des nuances particulières de couleur. Selon le diagramme de Shepard, un espace tridimensionnel rend correctement compte des données de similarité initiales. Ainsi, dans cet espace, deux nuances appartenant à la même couleur apparaissent plus proches que deux nuances issues de couleurs distinctes. Cette propriété est fondamentale, car elle rend possible à la fois la construction de régions (ex : la région du rouge) et l'interprétation sémantique des axes dimensionnels.

0.4 La similarité comme proximité, la dissimilarité comme distance

Historiquement, l'utilisation du MDS pour représenter des jugements de similarité sur des catégories naturelles précède la théorie des espaces conceptuels. SHEPARD (1974) cherchait déjà à placer les couleurs dans un « espace psychologique » interprétable. L'une de ses résultats centraux est sa *loi universelle de généralisation*, selon laquelle la similarité décroît exponentiellement avec la distance psychologique :

$$\text{Sim}(x, y) = e^{-c \mathcal{D}(x, y)}$$

où $\mathcal{D}(x, y)$ est la distance dans l'espace psychologique et $c > 0$ un paramètre de sensibilité¹. Cette fonction est largement utilisée dans le cadre des espaces conceptuels².

L'application de la théorie des espaces conceptuels aux couleurs hérite donc de l'ambition de Shepard d'extraire des *directions interprétables qui rendent compte* des données empiriques, où les variables sont interprétées par des objets de la psychologie cognitive, mais dont les

1. SHEPARD (1987, p.1319) : “The data are from a number of researchers, who tested both visual and auditory stimuli, and both human and animal subjects. Yet, in every case, the decrease of generalization with psychological distance is monotonic, generally concave upward, and more or less approximates a simple exponential decay function.”

2. GÄRDENFORS (2000, sec. 1.6.5); OSTA VÉLEZ (2020, p.82); BECHBERGER (2023, p.14).

relations relèvent de la géométrie. L'ambition de Shepard est d'utiliser une telle fonction pour des stimuli de différentes natures (visuels, auditifs, etc.) et pour différentes espèces (humains, singes, oiseaux, etc.).

0.5 De l'espace de similarité à l'espace conceptuel

A. Des points aux régions


L'une des idées que Gärdenfors reprend à Shepard est que plus deux points sont *éloignés* dans l'espace de similarité, moins il est probable qu'ils appartiennent à la *même* catégorie, et inversement, plus ils sont proches, plus il est probable qu'il existe une catégorie dont l'extension les contient tous les deux ¹.

Cette hypothèse est cruciale parce qu'elle suggère que les points appartenant à une même catégorie ont tendance à apparaître comme des *clusters* dans un espace de similarité. Si une catégorie spécifique regroupe des éléments homogènes et similaires entre eux, ceux-ci devraient prendre la forme d'un cluster dense et séparable du reste des points dans l'espace de similarité ². À l'inverse, plus une catégorie est hétérogène, plus le cluster des points représentant ses éléments sera *diffus*, plus les points seront *étalés* dans l'espace de similarité.

Par exemple, imaginons qu'on applique un MDS sur une matrice de dissimilarités obtenue à partir de jugements sur 30 stimuli : 15 images de loutre et 15 images de chat. Dans l'espace de faible dimension obtenu après MDS, chaque point représente une image unique. Dans l'idéal les points correspondant à des instances d'une même catégorie (loutre ou chat) forment des clusters (regroupements) distincts. C'est par exemple le cas dans le schéma ci-dessous, où on distingue nettement deux nuages de points :

1. POTH (2019, p.9) : "For a set of stimuli, i and j , the empirical probability of an organism to generalise a type of behaviour towards j upon having observed i is a monotone and exponentially decreasing function of the distance between i and j in a continuous psychological similarity space".

2. BORG et GROENEN (2005, p.104) : "(...) a cluster is a particular region whose points are all closer to each other than to any point in some other region. This makes the points in a cluster look relatively densely packed, with "empty" space around the cluster. For regions, such a requirement generally is not relevant".




Espace de similarité factice en 2D.

La cohésion interne de chaque cluster reflète la similarité intra-catégorielle, tandis que la séparation nette entre les deux clusters illustre la dissimilarité inter-catégorielle. Plusieurs hypothèses sur l'organisation spatiale justifient donc le passage des *points* (instances) aux *régions* (propriétés/concepts)¹.

B. interpréter les dimensions

Commençons par donner un exemple de tentative d'interprétation des axes d'un espace de similarité. On peut déterminer une liste de noms de mammifères, qui sont liés à des caractéristiques, comme leurs habitats respectifs (terrestre, aquatique, aérien), leurs tailles (petit, moyen, grand). Les données issues des jugements de similarité sur ces animaux peuvent être *projetées* dans un espace de similarité en appliquant un MDS. On peut ensuite tenter d'interpréter cet espace à partir de la liste des caractéristiques initialement établie. C'est précisément ce que proposent DOUVEN, VERHEYEN et al. (2023), avec l'espace de similarité suivant :

1. Les régions peuvent être détectées de façon non supervisée par des méthodes de clustering. Il est courant, et souvent plus robuste, d'effectuer le clustering directement sur la matrice de dissimilarités plutôt que sur une projection de faible dimension. La section 1.4.4 propose une technique géométrique élégante pour construire des régions à partir des points.



Espace de similarité contenant 20 mammifères. Extrait de DOUVEN, VERHEYEN et al. (2023)

L'axe y semble corrélé à la férocité des vingt mammifères¹ et l'axe x semble corrélé à leurs tailles. On peut essayer de donner du sens aux différents regroupements de points (*clusters*), en identifiant celui du bas comme correspondant aux petits animaux, celui à gauche comme correspondant aux herbivores, et celui du haut aux carnivores².

Ainsi l'interprétation des dimensions d'un espace de similarité permet de révéler les traits sémantiques qui rendent compte des similarités et dissimilarités entre les éléments et donc d'ordonner les éléments représentés. BENDIFALLAH et al. (2025) fournissent un autre exemple parlant en interprétant les dimensions d'un espace de similarité contenant des noms de figures féministes³.

Bien qu'il soit souhaitable que chaque dimension ait une signification claire et identifiable,

1. HENLEY (1969, p.180) : "[the dimension] seems to be characterizable as one of mildness vs. ferocity".

2. HENLEY (1969, pp.180-181) : "Again there is the grouping into small animals (rabbit and mouse), herbivores (cow, deer, horse, goat, sheep) and other carnivores (bear, lion, dog, cat)".

3. À partir de jugements expérimentaux menés auprès de participants en études de genre, ils ont projeté 31 noms de figures féministes dans un espace construit par MDS. Ce MDS a produit un espace à trois dimensions dans lequel les noms se regroupent en petits nuages de points. Dans l'espace de similarité, on distingue un *cluster* pour les féministes queer (p. ex. Paul B. Preciado, Monique Wittig), un autre pour les féministes intersectionnelles (p. ex. Kimberlé Crenshaw), et un autre pour les féministes matérialistes (p. ex. Silvia Federici).

représentant un attribut ou une caractéristique conceptuelle, il n'est pas nécessaire que les dimensions soient parfaitement interprétables pour parler d'*espace conceptuel*. En pratique, il est assez rare que les dimensions d'un espace de similarité obtenu par MDS soient directement *parfaitement* interprétables.

De plus, cette contrainte d'interprétabilité rentre parfois en tension avec l'exigence de performances des prédictions du modèle. Parfois mais pas toujours. Ainsi Igor Douven propose un espace conceptuel des couleurs partitionné en régions qui allie à la fois faible dimensionnalité, interprétabilité des dimensions et performances prédictives des jugements humains sur les couleurs¹. Selon DOUVEN et GÄRDENFORS (2020), cette application est un *succès*, car les régions correspondant aux catégories des couleurs semblent suivre certaines contraintes d'optimalité (c.f. section 1.4.4). Mais ce succès même soulève une question : s'agit-il d'un modèle de niche, exceptionnellement adapté à la perception, ou d'un cadre généralisable aux niveaux plus abstraits de la cognition sémantique ?

0.6 Limites de l'applicabilité de la théorie des espaces conceptuels

Au-delà des domaines sensoriels

Dans ce mémoire, nous explorons la question de savoir si les espaces conceptuels sont adaptés *uniquement* aux catégories sensorielles ou s'ils sont applicables aux catégories dont la signification englobe une plus grande variété de domaines. En effet, l'utilisation des *domaines*, c'est-à-dire d'ensembles de dimensions indissociables, paraît *prima facie* particulièrement adaptée pour les catégories sensorielles. D'un côté, GÄRDENFORS (2014) affirme que les dimensions des espaces conceptuels sont étroitement liées à ce qui est produit par les récepteurs sensoriels², de l'autre côté, il écrit qu'il existe aussi des dimensions qualitatives abstraites et non sensorielles³. Les recherches ont souvent porté sur la modalité des *couleurs* définie par les dimensions de la teinte, de l'intensité et de la luminosité. D'autres recherches l'ont appliqué à la

1. Ces jugements sont notamment les jugements de similarité, la catégorisation et l'induction. Cette performance prédictive doit beaucoup à l'amélioration des espaces colorimétriques, dans lesquels les nuances de couleur sont organisées de manière fidèle à la perception humaine.

2. GÄRDENFORS (2014) : "These dimensions are closely connected to what is produced by our sensory receptors"

3. GÄRDENFORS (2014, sec. 2.1) : "there also exist quality dimensions that are of an abstract, non sensory character".

catégorie des *sons* en utilisant des dimensions telles que la hauteur et l'intensité (voir BOLT et al. (2019)). D'autres encore l'ont appliqué à la modalité du goût avec des dimensions telles que le sucré, l'acide, l'amer et le salé¹. Cependant, à notre connaissance, aucun modèle ne permet aujourd'hui de représenter la sémantique des concepts du langage naturel en combinant (i) *interprétabilité* des dimensions, (ii) représentation des concepts comme *régions* et (iii) performances prédictives.

Mais peut-on étendre ce modèle géométrique de la similarité pour rendre compte de phénomènes cognitifs de plus haut niveau, comme les distorsions de la mémoire sémantique ou les interférences linguistiques, sans en perdre les vertus explicatives fondamentales (interprétabilité, structure compositionnelle) ? Pour répondre à cette question, notre mémoire se déroulera en trois moments. Nous établirons d'abord, dans le Chapitre 1, le succès de la théorie avec l'application aux couleurs, qui servira de référence. Puis, dans le Chapitre 2, nous confronterons le modèle à des phénomènes de distorsions infra-conscientes de la mémoire sémantique, en analysant s'il est capable d'en rendre compte. Enfin, le Chapitre 3 poussera la théorie dans ses retranchements en abordant les aspects dynamiques de l'interférence linguistique, nous obligeant à questionner le caractère statique du modèle géométrique

Depuis environ une décennie, une partie de la recherche² dans le cadre des espaces conceptuels s'inspire des *plongements sémantiques* (*word embedding*) dans lesquels les mots sont représentés sous la forme de grands vecteurs, ce qui les rend représentables sous forme de *points* dans des espaces avec plusieurs centaines de dimensions *non interprétables*. Puisque chaque mot est représenté par un vecteur unique, ces modèles permettent de mesurer la distance et la similarité entre deux mots. Selon nous, cette approche diffère de la théorie des espaces conceptuels aux deux égards suivants.

Premièrement, la théorie des espaces conceptuels représente les concepts comme des *régions* qui délimitent l'ensemble des objets qui satisfont les conditions d'appartenance du concept. La représentation avec des points rend moins bien compte de la variabilité et de la flexibilité de la sémantique des concepts concernés. Deuxièmement, les dimensions individuelles qui constituent les mots-vecteurs dans les modèles d'embeddings de mots sont généralement très difficiles à

1. BECHBERGER (2023, pp.75-78) note les dimensions du goût par "TASTE = ⟨sweet; sour; bitter; salt⟩"

2. DERRAC et SCHOCKAERT (2015, p.69) : "Most approaches represent natural language terms as points or vectors"

interpréter, tandis que dans les espaces conceptuels, chaque dimension représente une qualité *interprétable*¹ par exemple pour le *goût* on peut prendre le degré d'acidité et de douceur², etc.) Il y a de nombreuses techniques permettant de rapprocher les plongements sémantiques avec les espaces conceptuels.

Nous nous demanderons en premier lieu s'il y a une corrélation entre l'interprétabilité d'un espace et sa dimensionnalité : est-ce que la difficulté à interpréter les vecteurs des mots dans les plongements sémantiques est liée au fait qu'ils aient plusieurs centaines de dimensions ? Cette question conduit à une autre : est-ce que seuls les espaces de faible dimensionnalité sont interprétables ? Dans la section 2.5.3, nous répondrons à cette question par la négative.

Ce mémoire montre aussi que la théorie des espaces conceptuels s'inscrit dans un ensemble plus large de recherches qui visent à évaluer la qualité d'une classification X d'un ensemble de données *en cherchant à voir si cette classification X permet de bien rendre compte de cet ensemble de données*³. Traditionnellement, les classifications sont posées *a priori* (par convention, parce qu'il y a des grilles et des taxonomies officielles, etc.). L'approche par réduction de dimensionnalité vise au contraire à identifier des *dimensions de variation* et, idéalement, à révéler des structures inattendues dans les données, et parfois même atteindre ce qui peut paraître, aux yeux des chercheurs, comme des "classifications idéales" des données.

1. BECHBERGER (2023, p.271) : "Interpretable dimensions, however, are a corner stone of the conceptual spaces framework".

2. D'autres dimensions peuvent aussi être prises en compte dans le domaine du goût BOLT et al. (2019). Bien que degré d'acidité soit généralement une dimension séparée du degré de douceur (sweetness) et qu'elles soient séparées du domaine des couleurs, BECHBERGER (2023, pp. 89-97) formalise la corrélation entre la couleur verte d'une pomme et son acidité, ainsi qu'entre la couleur rouge d'une pomme et sa douceur.

3. C'est par exemple le cas de EVAÏN (2024, sec. 2.2) qui fusionne deux dimensions de variation traditionnellement utilisées qui sont étroitement liées. Elle obtient ainsi un seul axe qui permet une meilleure classification des données

Chapitre 1

Application de la théorie des espaces conceptuels aux couleurs

1.1. De RGB à HSL

Un espace colorimétrique est utilisé pour représenter l'organisation tridimensionnelle des couleurs. Les couleurs sont mappées le long d'axes qui représentent différentes propriétés. Un premier exemple est l'espace **RGB** dont les trois dimensions représentent respectivement le rouge, le vert et le bleu. Une nuance de couleur singulière est représentée dans **RGB** par un triplet¹ $(x_1, x_2, x_3) \in (R \times G \times B)$ où $R \times G \times B = \llbracket 0; 255 \rrbracket \times \llbracket 0; 255 \rrbracket \times \llbracket 0; 255 \rrbracket \subset \mathbb{N}^3$. Intuitivement, ce triplet représente le niveau de rouge, de vert et de bleu dans la nuance de couleur singulière. Plus généralement, l'espace **RGB** modélise chaque nuance de couleur comme une combinaison additive de sa valeur sur les trois dimensions de rouge, vert et bleu. L'espace **RGB** peut être représenté par un cube, où chaque axe représente l'intensité des composantes : rouge, vert et bleu.

Bien que l'espace **RGB** ait le mérite d'être simple, nous présenterons deux idées schématiques qui montrent qu'il n'est pas du tout adapté pour modéliser la vision humaine. Premièrement, puisque les dimensions de **RGB** sont chromatiques, le degré de luminosité doit être extrait des trois valeurs composants encodant la chromaticité. Cependant, pour modéliser le système visuel humain, il est plus approprié d'isoler un paramètre de luminosité des paramètres de chromaticité (FAIRCHILD 2013, p.78). La deuxième critique concerne les couleurs opposées dans **RGB**. Lorsque l'espace **RGB** est représenté comme un cube, il apparaît que chaque sommet – qui correspond intuitivement à une « couleur pure » – a un sommet opposé qui est également le plus éloigné sur le cube. En d'autres termes, les quatre diagonales joignant les quatre sommets opposés sur le cube indiquent les quatre paires de couleurs les plus éloignées (cf. Fig. 1a). Ainsi, l'une des lacunes du modèle **RGB** est que le sommet opposé à celui du ROUGE est celui

1. Cet espace est souvent utilisé en informatique, où la valeur du rouge, du vert et du bleu est encodée par un octet qui peut avoir 256 valeurs différentes.

correspondant au CYAN. Cependant, au cours des XIXe et XXe siècles, un certain nombre d'études empiriques et de théories¹ soutiennent l'idée que la couleur la plus opposée au ROUGE est le VERT, et non le CYAN comme c'est le cas dans **RGB**.

GÄRDENFORS (2014, section 2.1) présente l'espace colorimétrique tridimensionnel **HSL**, comprenant les dimensions de teinte, de saturation et de luminosité. Ce modèle résout les deux problèmes précédemment soulevés : premièrement, il dissocie la dimension de luminosité des dimensions chromatiques, et deuxièmement, il sépare le ROUGE et le VERT sur l'axe de saturation aussi loin que possible (voir Fig. 1.b).




Figure 1a. **RGB** Space




Figure 1b. **HSL** Space

1.2. Partir des expériences psychophysiques sur la vision humaine

La *Commission internationale de l'éclairage* (CIE) est l'institution en charge des normes pour la photométrie et la colorimétrie. En 1976, la CIE a recommandé l'utilisation de l'espace **CIELAB** pour représenter les couleurs vues sur papier ou textiles, et l'espace **CIELUV** pour représenter les couleurs perçues sur un écran. Depuis lors, l'espace **CIELAB** a été ajusté, corrigé et optimisé, ce qui est moins le cas avec **CIELUV**, dont l'utilisation a quelque peu diminué en faveur d'autres espaces². Pour mettre en place ces espaces colorimétriques et les opérations

1. Basé sur des expériences psychophysiques, Hering (1834-1918) a soutenu que le rouge carmin est l'opposé du vert et que le bleu est l'opposé du jaune. Cette idée a donné naissance à la théorie des processus opposés, qui stipule schématiquement que certains stimuli verts et certains stimuli rouges génèrent des réponses neurobiologiques opposées (sur les 3 types de bâtonnets : L ; S ; M) ou même antagonistes (mutuellement incompatibles).

2. FAIRCHILD (2013, pp.313-316) passe en revue les conditions de plusieurs expériences dans lesquelles **CIELAB** a obtenu de meilleurs résultats que **CIELUV**. Entre autres, il cite une expérience utilisant des comparaisons par

correspondantes, la CIE a d'abord dû définir certaines *conditions de référence psychophysiques*. Ces conditions sont celles d'un « observateur standard » qui est utilisé pour *standardiser* les différents résultats d'observations, c'est-à-dire pour les interpréter selon les mêmes normes méthodologiques. Par exemple, l'une des normes pour les tests colorimétriques est l'utilisation de l'illuminant D65, qui a été défini statistiquement à partir de nombreuses mesures de la lumière du jour (FAIRCHILD 2013, p.62). Dans « D65 », la majuscule « D » indique qu'il s'agit d'une mesure de la lumière du jour (« Daylight ») et le nombre indique approximativement la température de couleur¹. L'illuminant D65 est un blanc légèrement froid qui correspond à peu près à la lumière du jour dans l'hémisphère nord, sous des ciels légèrement nuageux, entre 10h et 12h au printemps et en automne (BERNS et al. 2019, p.4 Hirsch, 2014, p.72). En plus de l'éclairage, les conditions de référence psychophysiques incluent également les modalités d'objet (par exemple, *tissu, papier, écran*), la couleur de fond ou la taille du stimulus en degrés d'angle visuel²

L'espace **CIELAB** est défini en trois dimensions $\langle L; a; b \rangle$. L'axe *a* représente la saturation, l'axe *b* représente la teinte et l'axe *L* indique le degré de luminosité. Ainsi, bien que la structure des espaces **CIELAB** et **CIELUV** semble similaire³ à celle de **HSL** (ils comprennent une dimension dédiée à la luminosité, et la teinte *y* est déterminée par rotation), contrairement à **HSL**, ces espaces s'appuient sur de nombreuses données psychophysiques concernant les jugements de similarité entre couleurs. Bien que l'espace **HSL** semble mieux représenter que **RVB** le système visuel humain, il n'est pas construit à partir de données empiriques concernant les jugements de similarité entre les couleurs.

Les espaces **CIELAB** et **CIELUV** ont ouvert la voie à de nombreux *Modèles d'Apparence des Couleurs* (MAC). Ces modèles cherchent à décrire mathématiquement le fonctionnement de la vision humaine des couleurs. Par exemple, l'espace **CIELAB** peut prédire le fait qu'une

paires d'images imprimées dans laquelle les prédictions de **CIELAB** étaient significativement meilleures que celles de **CIELUV**

1. La température de D65 est de 6504 Kelvin.

2. En 1995, la CIE a introduit une mesure de différence de couleur appelée « CIE94 », dont les conditions de référence incluent un fond uniforme avec un gris neutre ($L = 50$) et un angle visuel supérieur à 4° , ce qui correspond à peu près à la taille perçue d'un cercle de 3,5 cm de diamètre placé à 50 cm d'un observateur (BERNS et al. (2019, p.103), FAIRCHILD (2013, p.83)

3. Sur les différences précises entre **CIELAB** et **CIELUV**, voir FAIRCHILD (2013, p.211).

couleur, comme celle d'une pomme rouge, est perçue de manière *constante* malgré les variations de source lumineuse, comme le soleil, un feu ou une ampoule électrique. Ce phénomène, appelé *adaptation chromatique*, intégré à **CIELAB**, dérive d'une loi formulée en 1902 par le physiologiste allemand von Kries¹. Il existe aujourd'hui de nombreuses variantes, dont certaines visent à prendre en compte plus de facteurs pour mieux reproduire d'autres phénomènes de la perception visuelle humaine, tels que l'effet des zones adjacentes ou contours².

La transformation des espaces **RVB** ou **HSL** à ces espaces est non linéaire³, cela signifie que la distance euclidienne entre deux points dans **RVB** ou **HSL** ne sera pas la même dans ces espaces. Imaginons par exemple qu'on pioche arbitrairement trois nuances de couleurs différentes dans **RVB**. Pour exemplifier cette non-linéarité, prenons $x, y, z \in \mathbf{RVB}$, trois triplets différents correspondant à trois nuances de couleurs. Soit la fonction $\mathcal{D}_E : (\mathbb{R}^3)^2 \rightarrow \mathbb{R}^+$ permettant de mesurer la distance euclidienne entre deux vecteurs tridimensionnels⁴. Imaginons que la distance entre x et y (*resp.* z) est k fois plus petite (*resp.* grande) que la distance entre x et z (*resp.* z), en d'autres termes $\exists k \in \mathbb{R} \quad k \times \mathcal{D}_E(x, y) = \mathcal{D}_E(x, z)$. Soit la fonction $Conv : \mathbf{RVB} \rightarrow \mathbf{CIELAB}$ permettant de passer d'un code $\langle R; V; B \rangle$ à un code $\langle L; a; b \rangle$ l'un et l'autre renvoyant à la même couleur perçue. Si donc on transforme les trois points $x, y, z \in \mathbf{RVB}$ en trois points $x', y', z' \in \mathbf{CIELAB}$, il est probable que la relation $k \times \mathcal{D}_E(x, y) = \mathcal{D}_E(x, z)$ ne soit pas préservée après cette conversion, c'est-à-dire que $k \times \mathcal{D}_E(x', y') \neq \mathcal{D}_E(x', z')$. Cela signifie plus généralement que si deux couleurs sont proches l'une de l'autre dans **RVB** ou **HSL**, elles peuvent ne plus l'être dans un espace colorimétrique, et vice versa.

Les parties suivantes visent à défendre l'idée que si on admet que la similarité (*resp.* dissimilarité) équivaut à la proximité (*resp.* distance) dans un espace, les points qui tombent sous la même catégorie doivent être représentés de manière *groupée* plutôt que *dispersée* dans cet

1. L'idée de von Kries est que les trois types de cônes (L, M, S) dans la rétine humaine ajustent leur sensibilité en fonction de la lumière ambiante. A la place de coder les signaux de ces cônes isolément, les lois de von Kries cherchent à tenir compte de l'intensité de la lumière ambiante dans la détermination de la chromaticité (FAIRCHILD (2013, sec. 9.1); BERNS et al. (2019, p.22)).

2. Il est par exemple possible, dans le MAC **CIECAM02**, d'intégrer comme variable la luminosité du contour (surround) (FAIRCHILD (2013, p.289)); c'est également possible dans le plus récent **CAM16**.

3. FAIRCHILD (2013, p.43) : « CIELAB color space that are based on a cube-root compressive power-law nonlinearity ».

4. $\mathcal{D}_E(x, y) = \sqrt{\sum_{i=1}^3 (x_i - y_i)^2}$, voir l'annexe B

espace. Une représentation "en bloc" des concepts de couleurs, où tous les points catégorisés comme C_i sont *regroupés* dans l'espace psychologique, est plus conforme à nos intuitions sur les couleurs.

1.3. Les propriétés des couleurs comme des régions dans l'espace colorimétrique.

Disposer d'un espace colorimétrique permet de *le découper* pour représenter les différentes couleurs comme des *régions* dans cet espace. Pour savoir si une nuance de couleur quelconque est rouge, il convient alors de déterminer un seuil inférieur et un seuil supérieur dans l'espace choisi pour déterminer la plage des nuances considérées comme rouges. Plus spatialement, cela consiste à délimiter une région correspondant au ROUGE. Cette région contient, entres autres, ÉCARLATE ou BORDEAUX comme sous-régions. Pour toute nuance singulière, pour décider s'il s'agit, ou non, d'une instance de rouge, il suffit de vérifier si le triplet correspondant $\langle x_1, x_2, x_3 \rangle$ est à l'intérieur ou à l'extérieur de la région du rouge.

Cette idée consiste à définir *en compréhension* une couleur C_i dans l'espace colorimétrique $\mathcal{U}$ en notant $C_i = \{x \in \mathcal{U} \mid \varphi(x)\}$, qui se lit « C_i est l'ensemble des x dans $\mathcal{U}$ pour lesquels la formule $\varphi(x)$ est vraie. » Il est donc possible de définir une *fonction indicatrice* associée à la couleur C_i qui renvoie 1 si l'élément appartient à la couleur, sinon 0. La fonction indicatrice décide, pour tout élément $x \in \mathcal{U}$, si $x \in C_i$ ou si $x \in \mathcal{U} \setminus C_i$. En d'autres termes, en prenant n'importe quel élément de $\mathcal{U}$, cette fonction renvoie 1 pour dire "Oui, x est dans C_i " ou bien renvoie 0 pour dire "Non, x est hors de C_i ". Cette fonction, notée $\chi_{C_i} : \mathcal{U} \rightarrow \{0, 1\}$, *situe* l'élément x , ou bien dans C_i , ou bien dans $\mathcal{U} \setminus C_i$, le complémentaire de C_i dans $\mathcal{U}$:

$$\chi_{C_i}(x) = \begin{cases} 1, & \text{si } \varphi(x), \quad \text{alors } x \in C_i \\ 0, & \text{si } \neg\varphi(x), \quad \text{alors } x \in \mathcal{U} \setminus C_i \end{cases}$$

Ce genre de définition de C_i le sépare *partes extra partes* de $\mathcal{U} \setminus C_i$. Or, intuitivement, il existe des nuances *entre deux*, au bord des frontières d'une région correspondant à une couleur. Une fonction d'appartenance *tout ou rien*, c'est-à-dire *binaire* ne permet pas de rendre compte du statut de ces *cas-limites* : un rouge qui tire vers l'orange n'est pas comme n'importe quel autre rouge, il n'est pas rouge au même *degré*¹. Dans le langage naturel, des locutions et adverb

1. KLEIBER (2007, p.12) : « L'existence de nombreux adjectifs de couleur composés tels que rouge vif, jaune pâle, vert pomme, etc. serait, selon Noailly, la preuve linguistique d'une gradation à l'intérieur d'une catégorie

comme « très », « un peu », « presque », « complètement », « proche de », sont utilisés pour exprimer ces degrés d'appartenance.

À la différence d'une fonction d'appartenance bivalente, où un changement infime dans l'argument x peut produire un renversement complet du degré d'appartenance, le problème consiste donc dès lors à déterminer une formule générale permettant de calculer, pour tout x , à quel degré x est C_i .

1.4. Représentation de la catégorisation d'une couleur : de la similarité aux prototypes

1.4.1. La corrélation entre le degré de similarité de deux couleurs et la probabilité qu'elles soient classées dans la même catégorie

La procédure employée par EKMAN (1954) est directe et simple. Il part de n couleurs différentes et veut obtenir une matrice de similarité de dimension $n \times n$. Celle-ci prend la forme d'un tableau dans lequel la cellule, où la colonne i et la ligne j se croisent, contient le degré de similarité des couleurs i et j . Le protocole pour obtenir cette matrice de similarité consiste à demander aux sujets un jugement de similarité subjectif entre toutes les paires possibles avec les n couleurs. Ainsi, chaque participant évalue la similarité entre $\frac{n \times (n-1)}{2}$ paires de couleurs différentes sur une échelle de 0 à 4. Ces jugements de similarité permettent, pour toute couleur $C_i \in \{C_1, \dots, C_n\}$ de classer par ordre décroissant de similarité les autres couleurs. Soit $C'_1 \in \{C_1, \dots, C_n\} \setminus \{C_i\}$ la couleur la plus similaire à C_i , et supposons que la deuxième couleur la plus similaire à C_i est notée C'_2 et ainsi de suite jusqu'à C'_{n-1} , la couleur la moins similaire à C_i . Cette mise en ordre est donc telle que $\forall k \in \llbracket 1; n-1 \rrbracket$ la couleur C'_k est moins similaire à C_i que C'_{k-1} mais en est plus similaire que C'_{k+1} . Imaginez que vous n'avez *jamais vu* la couleur C_i et que vous *ignorez* à quelle catégorie elle appartient, mais que vous connaissez les catégories assignées à toutes les autres couleurs $C_1, \dots, C_n$. Utilisez maintenant vos intuitions sur la question suivante : avec quelle couleur parmi $C'_1, \dots, C'_n$ la couleur C'_i est-elle la plus susceptible d'appartenir à la même catégorie sachant que $Sim(C_i, C'_1) > \dots > Sim(C_i, C'_{n-1})$?

chromatique, puisqu'il revient à ces adjectifs de discriminer entre le plus ou le moins bleu, le plus ou le moins jaune. Et, pour Van de Velde, ce sont les dérivés adjectivaux tels que blanchâtre, rougeâtre, etc. (...) qui indiquent la possession, à un faible degré d'intensité, d'une couleur déterminée (...) ».

Pour répondre à cette question, il faut imaginer que tout ce que nous savons des couleurs est d'une part les catégories attachées aux nuances de couleur $C'_1, \dots, C'_{n-1}$ et d'autre part que $C'_1, \dots, C'_{n-1}$ sont triées par ordre de similarité par rapport à C_i . Cette question invite à s'appuyer sur l'hypothèse théorique selon laquelle si une couleur x est plus similaire à une couleur y qu'à une couleur z , alors il est plus probable que x soit de la même catégorie que y , qu'elle soit de la même catégorie que z . En l'occurrence, puisque la couleur la plus similaire à C_i est C'_1 , la probabilité que C_i partage la même catégorie que C'_1 est *a priori* supérieure ou égale à la probabilité que C_i partage la même catégorie que C'_k pour tout $k \in \llbracket 2; n-1 \rrbracket$. Suivant cette même hypothèse, la probabilité que C_i partage la même catégorie que C'_{n-1} , qui est la nuance de couleur qui lui est le plus dissimilaire, est la moins élevée, l'idée étant que ces probabilités diminuent de manière monotone de C'_1 à C'_{n-1} . Faire comme si on ne connaissait rien d'autre sur la catégorie qu'un petit nombre d'exemplaires implique de prendre ces exemplaires comme « points de références » de ces catégories, en ce sens que c'est à partir de ceci que le jugement de similarité sera opéré.

1.4.2. Représenter la similarité (*resp.* dissimilarité) par la proximité (*resp.* distance)

L'une des idées qui traverse les travaux de Shepard¹ est que la dissimilarité entre deux stimuli est représentable par leur distance dans un espace psychologique. Ainsi SHEPARD (1962) propose d'appliquer une technique de réduction de la dimensionnalité appelé *multidimensional scaling* (MDS) sur les données d'EKMAN (1954) concernant les jugements de similarité entre couleurs. L'objectif du MDS est de réduire la complexité des données en minimisant la perte d'information et en conservant les relations de similarité entre les éléments. Les résultats du MDS indiquent que le plus optimal est de choisir deux dimensions² pour représenter ces données de similarité

1. SHEPARD (1974) applique cette idée à d'autres stimulus que les couleurs comme les consonnes de sa langue maternelle ou les intervalles musicaux.

2. L'optimalité de la dimensionnalité est mesurée par la fonction de coût du MDS, appelée "Stress" (cf. Annexe B, sec. 4). BORG et GROENEN (2005, p.66) appliquent un MDS sur la matrice de similarité utilisée par Shepard et obtiennent que "Measured in terms of Stress, the badness-of-fit of the 1D, 2D, and 3D solutions is 0.272, 0.023, and 0.018, respectively. (...) The 1D solution has high Stress, and adding one additional dimension leads to a major Stress reduction. Adding yet another dimension has very little further effect and, indeed, cannot have much of an effect because the 0.023 for the 2D solution is so close to zero already".

en excluant le paramètre de luminosité. Ce résultat suggère que deux paramètres suffisent pour modéliser au mieux les variations de la chromaticité dans l'espace des couleurs représentées par les humains (KISTLER, 2016, p.139). Il est possible de prendre cet espace pour expliquer les jugements de similarité : lorsqu'on juge du degré de similarité entre deux couleurs, on calculerait la *distance* entre les points correspondant à ces deux couleurs dans un espace déterminé. L'idée de Shepard est que la similarité entre deux stimulus (*e.g.* deux couleurs) est représentable par une fonction monotone décroissante de leur distance dans cet espace psychologique. Cela signifie que si deux couleurs A et B sont jugées plus semblables que deux couleurs C et D , alors la distance dans l'espace psychologique entre A et B est plus petite que la distance entre les couleurs C et D ¹.

1.4.3. La catégorisation dans la théorie des exemplaires

Comme évoqué, lorsqu'on doit catégoriser un élément inconnu, il est intuitif de chercher parmi les éléments que nous connaissons déjà ceux qui sont les plus similaires, et d'attribuer à l'élément inconnu la même catégorie (*cf.* 1.4.1). La théorie des exemplaires s'appuie sur deux idées essentielles. La première est que nous conservons en mémoire tous les exemples rencontrés pour chaque catégorie donnée. La deuxième est que, lorsqu'on doit catégoriser un nouvel élément, on le compare aux différents exemplaires stockés en mémoire et en le rattachant à la catégorie dont les exemplaires lui ressemblent le plus.

Sur ce principe, la théorie des exemplaires permet de rendre compte du fait qu'au sein d'une même catégorie de couleur, certaines nuances sont considérées comme plus représentatives que d'autres. Une nuance de couleur sera très représentative d'une catégorie si elle est très similaire à de nombreuses nuances au sein de cette même catégorie. Plus formellement, si une catégorie C est définie en extension par un ensemble d'exemplaires connus $\{x_1, \dots, x_n\}$, alors la représentativité d'une nuance particulière x_k (avec $1 \leq k \leq n$) pour la catégorie C est mesurée par la moyenne de ses scores de similarité avec les $n - 1$ autres nuances de C . Plus un élément ressemble aux exemplaires d'une catégorie donnée, plus il sera associé à cette catégorie et considéré comme représentatif de celle-ci. Par exemple, si une nuance est proche du bleu et du vert, mais qu'elle est catégorisée comme bleue, cela signifie qu'elle est plus représentative du

1. Formellement : $[\text{Sim}(A, B) > \text{Sim}(C, D)] \Rightarrow [\mathcal{D}(A, B) < \mathcal{D}(C, D)]$

bleu que du vert, et cela implique qu'elle partage en moyenne plus de similarité avec les nuances de bleu qu'avec celles de vert. Ainsi, la théorie de la catégorisation par les exemplaires prédit que la probabilité pour qu'une nuance x soit assignée à la catégorie C est d'autant plus grande, qu'il y a beaucoup de nuances dans C qui sont similaires à x .

Cette idée est opérationnalisée par l'algorithme des k plus proches voisins : la catégorie d'un élément x est déterminée par la catégorie majoritaire parmi ses k plus proches voisins. La méthode des k plus proches voisins consiste à calculer les distances entre un élément à classer et les exemples déjà connus. Pour déterminer l'étiquette de x , il s'agit donc de trouver les k points dans l'espace colorimétrique qui en sont le plus proche (DOUVEN2023, p.6).

Le coût cognitif de la technique des k plus proche voisins est d'autant plus important que k – le nombre d'exemplaires à prendre en compte dans la catégorisation – est grand. D'où on peut se demander pourquoi ne pas se contenter d'*un seul plus proche voisin*, afin de minimiser le coût de la catégorisation ? Pourquoi ne pas baser la catégorisation d'un élément x uniquement sur son voisin le plus proche en fixant $k = 1$ afin d'avoir un modèle de la catégorisation plus économe en ressources ? Cela peut conduire à des erreurs de catégorisation si le plus proche voisin est un *cas isolé*, atypique et marginal. Même si le plus proche voisin d'un élément x inconnu appartient à une classe donnée, il est possible que la majorité de ses autres voisins proches appartiennent à une classe différente. Se fier exclusivement au plus proche voisin pour catégoriser x serait alors peu fiable. Pour obtenir une classification plus robuste, une stratégie fréquente consiste à augmenter le nombre k d'exemples pris en compte, quitte à accroître le coût cognitif de chaque catégorisation.

Nous soutenons qu'il est possible de réduire la valeur de k en imposant des contraintes sur les exemplaires et/ou sur l'organisation des catégories. En ce sens, dans la partie suivante, on propose un modèle de catégorisation ne prenant en compte qu'un seul plus proche voisin ($k = 1$). En effet, dans ce modèle, un seul plus proche voisin est cherché, et il n'existe qu'un seul exemplaire par catégorie. Un modèle de catégorisation basé sur *un seul plus proche voisin* n'est viable qu'à condition d'imposer des contraintes sur *l'organisation* des catégories dans l'espace colorimétrique. Avant de présenter en détail ce modèle, il est important de justifier *pourquoi* imposer des contraintes sur l'organisation des catégories de couleurs. Les deux hypothèses suivantes donnent un aperçu bref et partiel des justifications qu'il y a à imposer ces contraintes sur l'organisation des catégories des couleurs :

- (i) Chaque couleur regroupe des nuances perceptuellement similaires,
- (ii) La catégorisation des couleurs doit être rapide et/ou peu coûteuse.

Il est possible de rendre compte de ces deux hypothèses en admettant que les catégories des couleurs sont *optimalement organisées* dans l'espace colorimétrique. Cet espace serait organisé de manière à minimiser la similarité entre différentes catégories et à maximiser la similarité au sein d'une même catégorie¹. Cette hypothèse d'optimalité explique pourquoi, étant donné la contrainte de rapidité et d'économie énoncée dans l'hypothèse (ii), la propriété décrite par l'hypothèse (i) – l'existence d'une forte similarité perceptuelle au sein des catégories – a émergé. En d'autres termes, si l'organisation des catégories n'était pas optimale, cela entraînerait une catégorisation plus lente et plus coûteuse, ainsi que la présence de nuances perceptuellement hétérogènes au sein d'une même catégorie, ce qui contredirait les deux hypothèses (i) et (ii).

1.4.4. La catégorisation dans la théorie du prototype.

L'hypothèse que la cohérence interne des catégories est *forte*, c'est-à-dire qu'elles regroupent des éléments *homogènes*, permet une catégorisation fluide et économique grâce à la constitution d'un prototype distinctif. Ainsi l'hypothèse d'optimalité permet de *synthétiser* tous les exemplaires d'une même catégorie en un seul exemplaire appelé *prototype*. Cette théorie offre un modèle plus économique de la catégorisation en assignant à chaque catégorie un unique prototype. L'existence d'un prototype pour chaque catégorie permet de penser la catégorisation de manière *plus simple* et *moins coûteuse* que la manière par laquelle elle est pensée dans le modèle de la théorie des exemplaires exposée précédemment (1.4.3). En effet, plutôt que d'utiliser *tous les exemplaires connus* dans la catégorisation, ne seraient utilisées que les coordonnées des points prototypiques, qui sont les plus représentatifs de chaque catégorie (Rosch 1978).

Un prototype peut être vu comme l'instance qui représente le mieux la catégorie. De manière concrète, lorsqu'un enfant apprend à identifier une nouvelle couleur, le premier exemplaire qu'on lui montre devient son premier point de référence. Au fil du temps, au fur et à mesure qu'il sera

1. DOUVEN et GÄRDENFORS (2020) exposent ces différentes contraintes. En principe, si on enlève toutes les étiquettes des exemplaires et qu'on partitionne à nouveau l'espace selon ces contraintes, on devrait re-obtenir presque les mêmes clusters (catégories) (Douven 2023) Un exemple de technique de partition optimale est l'algorithme des k moyennes, qui consiste à minimiser la distance entre les points d'un même cluster. Détails dans l'appendice (1.1)

exposé à d'autres variantes de cette couleur, ce point de référence est affiné et ajusté.

Dans l'espace colorimétrique, le prototype est un point dont la position est parfois définie comme la moyenne de la position de tous les exemplaires de la catégorie¹. Pour Gärdenfors, lorsque l'on dit qu'une nuance de couleur x est « plus rouge » qu'une nuance de couleur y , c'est équivalent à dire que x est plus proche du prototype du ROUGE que y ². Plus généralement, plus un point est proche du prototype du ROUGE, plus il correspond à une nuance *représentative* de cette catégorie.

Pour catégoriser une nuance de couleur selon la théorie du prototype, il suffit de mesurer sa distance avec les prototypes de chaque catégorie plutôt que de calculer sa similarité avec tous les membres de toutes les catégories. Contrairement aux théories de la catégorisation basées sur les exemplaires, dans la théorie du prototype, le plus proche voisin d'un élément x inconnu n'est jamais une exception ou une valeur marginale, mais sera toujours un prototype maximalement représentatif de sa catégorie. Un élément est considéré comme appartenant à une catégorie si sa distance avec le prototype de cette catégorie est inférieure à sa distance avec tous les autres prototypes de toutes les autres catégories³.

1.4.4-a Propriétés géométriques des régions représentant les catégories de couleurs

Supposons que la représentativité d'une nuance pour une couleur C soit calculable par une fonction prenant toutes les valeurs réelles entre 0 et 1 notée $M_C : U \rightarrow [0; 1]$. Le domaine $\mathcal{U}$ sur lequel cette fonction est définie correspond à un espace colorimétrique où la distance entre deux points correspond à la dissimilarité perçue entre les deux nuances représentées par ces points. Si cette fonction attribue une valeur k à un point x (c'est-à-dire $M_C(x) = k$), cela signifie intuitivement que x est représentatif de la couleur C avec un degré k . Tous les exemplaires de la couleur C ont une valeur de représentativité non nulle ($M_C(x) > 0$), tandis que toutes les nuances x n'ayant pas la couleur C ont une valeur de représentativité égale à zéro ($M_C(x) = 0$).

1. GÄRDENFORS (2014, sec. 2.7) "the position of the point representing the prototype is defined to be the mean of the positions for all the exemplars". Le prototype est calculé en divisant la somme des valeurs pour chaque dimension par le nombre total d'exemples dans ce groupe. Formellement, si $|C_i|$ note le nombre d'exemplaires de la catégorie C_i , le prototype est donné par $\frac{1}{|C_i|} \sum_{x_k \in C_i} x_k$ (DOUVEN2023, p.6)

2. GÄRDENFORS (2014, sec. 7.1).

3. GÄRDENFORS (2000, pp.92-97 ; sec.4.9) : « An object represented as a vector x_i in a conceptual space belongs to the category for which the corresponding prototypical circle is the closest » Voir aussi DOUVEN (2016).

Les éléments de la catégorie C sont donc représentés par l'ensemble des x tels que $x \in \mathcal{U}$ et $M_C(x) > 0$. De plus, par définition, si p note le prototype de C , il prend la valeur maximale de l'intervalle puisqu'il est maximalelement représentatif de la catégorie ($M_C(x) = 1$).

Plusieurs études empiriques¹ suggèrent que les extensions des catégories de couleurs satisfont une propriété qui indique qu'elles correspondent à des régions n'ayant pas aucune *discontinuité*, aucun *trous*. Cette propriété s'énonce intuitivement comme suit : si un sujet juge qu'une nuance x est ROUGE, alors toutes les nuances y situées entre x et le prototype du ROUGE seront également jugées comme étant ROUGE à un degré au moins égal à celui de x . Plus généralement, si x appartient à la catégorie C et que p en est maximalelement représentatif, alors tous les mélanges intermédiaires entre x et p seront aussi dans C . Dans des termes plus formels : si p est le prototype de la catégorie C , pour tout $x \in C$, toutes les nuances y sur le segment $[p, x]$ satisferont l'inégalité :

$$0 < M_C(x) \leq M_C(y) \leq 1.$$

Puisque y satisfait $M_C(y) > 0$, la nuance représentée par ce point est dans la catégorie C . Cette propriété peut être exprimée formellement comme suit :

$$\forall x \in U, M_C(x) > 0 \implies \forall \lambda \in [0, 1], M_C(\lambda x + (1 - \lambda)p) > 0.$$

Une région qui satisfait cette propriété est dite étoilée par rapport au prototype p ² et toute région étoilée ne contient *aucun trou*³. En effet, un trou devrait être un point t satisfaisant $M_C(t) = 0$ qui se trouve entre p et un autre point x tel que $M_C(x) > 0$, ce qui est impossible car, si C est étoilé par rapport à p , M_C est strictement positif sur tout le segment $[p; x]$.

1. Hampton et al. (2005) mènent une expérience sur la frontière entre le BLEU et le VIOLET. Ils écrivent que la contrainte d'ordre a été respectée dans 5992 essais sur 6000 : "In Experiments 2 and 3, only eight such non-monotonic responses occurred, out of almost 6000 opportunities".

2. On peut l'exprimer en écrivant que le degré d'appartenance à la catégorie C est une fonction monotone de la distance dans la direction spécifique du segment $[p, x]$:

$$\forall x \in C, \forall \lambda, \lambda' \in [0, 1]^2, (\lambda < \lambda') \implies [M_C(\lambda'x + (1 - \lambda')p) \leq M_C(\lambda x + (1 - \lambda)p)]$$

Une formule équivalente est donnée en utilisant le prédicat $Btw(x, y, z)$ signifiant que y est entre x et z :

$$\forall z, y, x \in C, [Btw(p, y, x) \wedge Btw(p, z, y)] \implies M_C(z) \leq M_C(y) \leq M_C(x)$$

3. DOUVEN, DECOCK et al. (2013, p.140) : "A region R is said to be connected iff, for all points p_i and p_j in R , there is a curve [a path] connecting p_i and p_j such that the curve [the path] lies entirely in R ".

Dire qu'une région est étoilée par rapport à l'ensemble de ses points revient à dire que pour toute paire de points x et z dans C , tous les points y sur le segment reliant x à z sont également dans C . Dans des termes plus concrets, si x et y sont deux nuances de ROUGE, alors toutes les nuances intermédiaires entre x et y seront également ROUGE. Selon Gärdenfors, toutes les catégories des couleurs doivent être représentées par des régions qui vérifient ce principe de *convexité géométrique*, qui est plus exigeant que le précédent¹. Le fait d'imposer cette convexité à *toutes les régions* d'un même espace colorimétrique a une conséquence sur la *forme* des frontières entre ces régions. En effet, si la frontière entre deux régions A et B présente une courbure, alors au moins l'une des deux régions A ou B n'est *pas convexe*². Sous cette contrainte de convexité géométrique, la seule façon de séparer deux régions adjacentes est d'utiliser comme frontières des *segments de droite*. Une technique géométrique permettant de délimiter de telles frontières, tout en respectant les hypothèses de *convexité géométrique*, d'*existence des prototypes*, et d'*organisation optimale* des catégories de couleurs est mise en œuvre dans la partie suivante.

1.4.4-b Le pavage de l'espace colorimétrique

La théorie du prototype, fondée sur l'homogénéité au sein des catégories, trouve un parallèle géométrique dans les pavages de Voronoï, où la notion de similarité entre deux nuances est interprétée comme la proximité entre deux points. Tout comme dans la théorie du prototype, où une nuance de couleur est attribuée à une catégorie si elle est plus similaire à son prototype qu'à tout autre, dans les pavages de Voronoï, un point est défini comme appartenant à une région s'il est plus proche de son prototype que de tout autre prototype. Cette interprétation géométrique de la théorie du prototype, où il s'agit de trouver le point prototypique le plus proche de tout élément x à catégoriser, permet de paver l'espace colorimétrique en régions de Voronoï qui correspondent aux extensions des différentes couleurs.

La section suivante montre comment délimiter géométriquement l'extension d'une catégorie de couleur, en prenant l'exemple de la catégorie ROUGE dans un espace colorimétrique bidimen-

1. Un ensemble est convexe s'il est étoilé par rapport à *tous* ses points, ainsi, un ensemble étoilé par rapport à *un* point n'est pas nécessairement convexe.

2. « courbé » est ici intuitivement équivalent à « non-rectiligne »

sionnel¹ et en utilisant une fonction de distance euclidienne pour mesurer la similarité entre deux nuances. Mais comment circonscrire l'extension de la catégorie ROUGE dans cet espace colorimétrique ? On se fixe pour cela un premier objectif qui est de délimiter une région R contenant toutes les nuances de ROUGE, mais ne contenant aucune nuance d'ORANGE, ni de VIOLET. On admet qu'on dispose des prototypes du ROUGE, de l'ORANGE et du VIOLET respectivement notés p_r , p_o et p_p qui correspondent à trois points dans l'espace colorimétrique bidimensionnel.

Conformément aux principes précédemment exposés, pour tout point x dans l'espace colorimétrique, la distance de ce dernier avec p_r , p_o et p_p permet de savoir *de quel couleur il n'est pas*. La région R doit alors satisfaire les deux conditions suivantes :

$\forall x \in R, \mathcal{D}_E(x, p_r) \leq \mathcal{D}_E(x, p_o)$ Tous les points de la région R sont plus proches de p_r que de p_o . Cela signifie que la région R ne contient aucune nuance d'ORANGE.

$\forall x \in R, \mathcal{D}_E(x, p_r) \leq \mathcal{D}_E(x, p_p)$ Tous les points de la région R sont plus proches de p_r que de p_p . Cela signifie que la région R ne contient aucune nuance de VIOLET.

Les trois étapes suivantes (i), (ii) et (iii) expliquent comment construire cette région R .

(i) Construction de la médiatrice entre p_r et p_o Traçons le segment $[p_r; p_o]$ reliant p_r , le prototype du ROUGE, à p_o , prototype de l'ORANGE. Les points de ce segment représentent un dégradé continu du rouge à l'orange, où le point au milieu du segment représente une nuance de couleur équidistante de p_r et p_o . L'unique droite qui traverse perpendiculairement le milieu du segment $[p_r; p_o]$ est appelée médiatrice. Cette médiatrice partage le plan en deux demi-plans contenant chacun les points plus proches d'un prototype donné² :

- d'un côté, $H(p_r, p_o)$ contient tous les points plus proches de p_r que de p_o ,
- de l'autre côté, $H(p_o, p_r)$ contient tous les points plus proches de p_o que de p_r .

1. Toutes les constructions proposées dans cette partie sont réalisables dans des espaces de dimensionnalité supérieure.

2. Formellement, cette médiatrice est $B(p_r, p_o) = \{x \in \mathcal{U} \mid \mathcal{D}_E(x, p_o) = \mathcal{D}_E(x, p_r)\}$.

Pour rappel, l'objectif est d'obtenir une région qui ne contient aucune nuance d'ORANGE ni aucune nuance de VIOLET. Bien que la région $H(p_r, p_o)$ ne contienne aucune nuance d'ORANGE¹, elle a l'inconvénient de contenir au moins une nuance de VIOLET², et est donc trop vaste pour être la région cherchée. Il faut donc désunir toutes les nuances violettes incorporées dans la région $H(p_r, p_o)$. C'est ce que font les deux étapes suivantes.

(ii) Construction de la médiatrice entre p_r et p_p

Reproduisons le procédé de la première étape, mais en remplaçant le prototype de l'ORANGE (p_o) par celui du VIOLET (p_p). Il s'agit donc de construire une nouvelle médiatrice, avec p_r et p_p , pour obtenir deux nouveaux demi-plans. Parmi ces deux demi-plans, c'est $H(p_r, p_p)$ qui retient notre attention. En effet, $H(p_r, p_p)$ ne contient aucune nuance de VIOLET et corrige donc le défaut de $H(p_r, p_o)$. Toutefois, le demi-plan $H(p_r, p_p)$ présente le même travers vis-à-vis de l'ORANGE puisqu'il en contient au moins une nuance. À ce stade, nous avons donc deux régions qui excèdent chacune la région cible de deux manières distinctes. Précisons : la région $H(p_r, p_o)$ est trop vaste en ce qu'elle inclut des nuances violettes, lesquelles sont absentes de $H(p_r, p_p)$; vice versa, la région $H(p_r, p_p)$ est trop vaste en ce qu'elle inclut des nuances oranges, lesquelles sont absentes de $H(p_r, p_o)$.




Fig. 2a. Le demi-plan $H(p_r, p_o)$




Fig. 2b. Le demi-plan $H(p_r, p_p)$

(iii) Intersection de $H(p_r, p_o)$ et de $H(p_r, p_p)$

Ce non-recouvrement des excès des deux demi-plans invite à considérer leur intersection afin de déterminer une région plus petite satisfaisant toutes les conditions de la région cible. En

1. $\forall x \in H(p_r, p_o), \mathcal{D}_E(x, p_o) > \mathcal{D}_E(x, p_r)$
2. Cette hypothèse, qui peut s'écrire $\exists x \in H(p_r, p_o)$ tel que $\mathcal{D}_E(x, p_r) > \mathcal{D}_E(x, p_p)$ ou $H(p_r, p_o) \cap H(p_p, p_r) \neq \emptyset$, est ici admise sans preuve.

d'autres termes, l'ensemble des nuances communes à $H(p_r, p_o)$ et $H(p_r, p_p)$ est une région réduite qui concentre toutes les nuances du ROUGE tout en écartant toutes les nuances d'ORANGE et de VIOLET. L'intersection correspond donc à la zone où les deux se croisent, comme illustré ci-après :




Fig. 2c. Intersection de $H(p_r, p_o)$ et $H(p_r, p_p)$

Cette construction peut être encore reproduite s'il existe davantage de prototypes adjacents au prototype du ROUGE. Par exemple, si p_m est le prototype du MAGENTA et que l'on cherche à obtenir une région excluant toute nuance de VIOLET, d'ORANGE et de MAGENTA, il convient de construire un nouveau demi-plan $H(p_r, p_m)$ et de l'intersecter avec les deux précédents. Cette intersection produit une région qui exclue toute nuance d'ORANGE, de VIOLET et de MAGENTA, comme illustré sur la Fig 3b :




Fig. 3a. Le demi-plan $H(p_r, p_m)$




Fig. 3b. Intersection des 3 demi-plans
 $H(p_r, p_o) \cap H(p_r, p_p) \cap H(p_r, p_m)$

Cette construction de la région du ROUGE par intersection de demi-plans se généralise à un nombre quelconque de couleurs voisines. Ainsi, la région de Voronoï $v(p_r)$ peut être construite en intersectant tous les demi-plans issus des prototypes adjacents à p_r . Cette intersection prend

la forme d'un polygone¹ correspondant à l'extension de la catégorie ROUGE. La même méthode est applicable pour délimiter les régions des autres catégories de couleurs.

Chaque région de Voronoï peut donc être définie à partir d'une série d'intersections de demi-plans. Bien que la construction de la région de Voronoï du ROUGE exposée ci-dessus implique seulement les prototypes adjacents, les définitions courantes d'une région de Voronoï posent un ensemble contenant *tous* les prototypes noté $P = \{p_1, \dots, p_n\}$ et étendent l'intersection à *tous* demi-plans construits par les prototypes de cet ensemble. Ainsi, en montant en généralité, une région de Voronoï peut être définie comme suit :

- (1) La région $v(p_i)$ est l'intersection de tous les demi-plans $H(p_i, p_j)$ pour tout $p_j \in P \setminus \{p_i\}$:

$$v(p_i) = \bigcap_{p_j \in P \setminus \{p_i\}} H(p_i, p_j)$$

Il existe une seconde définition équivalente qui procède différemment :

- (2) La région $v(p_i)$ est l'ensemble des points plus proches de p_i que de tout autre $p_j \in P \setminus \{p_i\}$:

$$v(p_i) := \{p \in U \mid \forall p_j \in P \setminus \{p_i\}, \mathcal{D}_E(p, p_i) \leq \mathcal{D}_E(p, p_j)\}$$

Bien que la première définition se base sur une série d'intersections de demi-plans et la seconde sur une comparaison directe des distances, les deux déterminent la *même région*.

Par ailleurs, bien que ces deux définitions prennent en compte *tous* les prototypes dans P qui sont différents de p_i , il est suffisant de considérer uniquement les points prototypiques qui génèrent des régions *adjacentes* à la région générée par p_i . Cette restriction aux prototypes adjacents est plus économe parce que cela évite de considérer des points n'ayant pas d'incidence sur la forme de la région de Voronoï ciblée². Les deux pavages suivants illustrent en deux dimensions le fait que les prototypes non adjacents n'ont pas d'incidence sur la forme d'une région de Voronoï :

Dans ces deux pavages, les points oranges correspondent à l'ensemble des points qui génèrent des régions de Voronoï adjacentes à celle du point rouge. Puisque les coordonnées du point rouge

1. Dans un espace tridimensionnel, si tous les points générateurs ne sont pas tous sur un même plan, cette intersection produit un polyèdre. En dimension supérieure, elle produit un polytope

2. Ceci est utile lorsque le nombre de prototypes est très élevé, permettant ainsi une construction plus efficace de la région de Voronoï souhaitée




Fig 4. Deux pavages de Voronoï partageant les points oranges et rouge en commun.

et de tous les points orange restent les mêmes dans les deux pavages, la cellule de Voronoï du point rouge reste identique. En revanche, les autres points qui produisent des cellules non-adjacentes à celle du rouge, figurés en noir, changent de coordonnées.

Si les points dans P sont tous distincts, le pavage de Voronoï généré par P contient $|P|$ polygones¹ différents. Les polygones constituant un pavage de Voronoï sont une manière de représenter l'organisation optimale des catégories de couleurs entendue comme minimisation de la similarité entre catégories différentes et maximisation de la similarité au sein d'une même catégorie. Les points $p_i \in P$ sont appelés *points générateurs*³⁴ et l'ensemble P est appelé *ensemble générateur*. Le pavage de Voronoï généré par P est l'ensemble de toutes les cellules générées par les points dans P :

$$V(S) = \{v(p_i) \mid p_i \in P\}$$

La littérature sur les espaces conceptuels soulève souvent deux problèmes majeurs liés aux diagrammes de Voronoï classiques. Le premier problème tient à ce que les données expérimentales montrent que les prototypes ne sont pas des points *uniques* et *précisément localisés*².

1. Dans un espace à trois dimensions, les cellules de Voronoï sont des polyèdres, et les frontières des cellules sont des faces de Voronoï. Dans un espace à k dimensions dimensions, les cellules de Voronoï sont des k -polytopes.

2. Pour les catégories de couleurs, il est peu probable qu'un point unique représente idéalement toute la catégorie

Bien qu'il semble s'agir de deux problèmes distincts, la modification des diagrammes de Voronoï classiques en diagrammes créés à partir de *régions prototypiques* permet *en théorie* de les résoudre tous les deux à la fois.

1.5 Critiques et améliorations de la technique des diagrammes de Voronoï

L'idée de modéliser l'organisation des catégories de couleur par un diagramme de Voronoï, où chaque cellule correspond à l'extension d'une couleur, est élégante mais comporte des idéalités qui la rendent trop simplificatrice pour rendre compte pleinement des données empiriques .

1.5.1. Critique de l'unicité du prototype

Dans ce paragraphe nous donnons des arguments contre l'unicité du prototype et nous soutenons que l'on doit plutôt utiliser des *régions prototypiques* pour les catégories des couleurs.

Supposons qu'on ait une nuance de rouge qui correspond à un point p_i dans l'espace colorimétrique tel que cette nuance de rouge soit considérée un grand nombre de personne comme pleinement rouge. Il semble intuitivement que si on prend plusieurs nuances très proches de p_i dans l'espace colorimétrique, ces nuances seront elles aussi considérées comme pleinement rouges. On peut dès lors se demander pourquoi assigner p_i comme seul point prototypique de la catégorie ROUGE ? ¹. En d'autres termes, il semble y avoir une part d'arbitraire à fixer un unique point prototypique dans la mesure où d'autres points du voisinage immédiat de ce point fixé pourraient, eux aussi, revendiquer le même statut. La créatrice de la théorie du prototype elle-même reconnaît que les résultats expérimentaux ne plaident pas en faveur d'un prototype unique :

mieux que tous les autres. Par exemple, si une nuance prototypique p_r du ROUGE est fixée, il semble qu'une nuance qui diffère très légèrement de p_r a, elle aussi, un degré d'appartenance *maximal* au rouge et pourrait donc, elle aussi, être prise comme point prototypique.

1. DOUVEN, WENMACKERS et al. (2017) : "In Gärdenfors' version, it is assumed that there is a unique prototype for each concept. However, at least if prototypes are understood in the sense of most representative instances, then in general that assumption can at best be an idealization. Surely there is not exactly one shade of red that best represents the concept of redness. It is therefore more realistic to say that instead of one prototypical point for red, we find in color space a prototypical region for red : a region of points that can all lay equal claim to being "maximally representative" for red."

To speak of a prototype at all is simply a convenient grammatical fiction ; what is really referred to are judgments of degree of prototypicality. Only in some artificial categories is there by definition a literal single prototype [...]. For natural-language categories, to speak of a single entity that is the prototype is either a gross misunderstanding of the empirical data or a covert theory of mental representation¹

Gärdenfors, conscient de cette idéalisation, a proposé de remplacer le point générateur prototypique par un *cercle* (ou une *sphère* en 3D) prototypique. Concrètement, il suggère qu’au lieu d’un point unique p on puisse considérer une région décrite par un cercle de centre p et de rayon c_p , et définir un diagramme de Voronoï généralisé en comparant la distance d’un point x à ces aires prototypiques plutôt qu’à des points isolés.² Cette généralisation permet de rendre compte simplement du fait qu’un petit voisinage de points puisse être maximalement représentatif d’une catégorie, mais elle impose une forme spécifique aux régions prototypiques qui, selon nous, ne rend pas bien compte des données expérimentales.

Les expérimentations menées par DOUVEN, WENMACKERS et al. (2017) donnent une illustration concrète de l’idée selon laquelle le choix d’un unique prototype est arbitraire et il convient bien mieux d’utiliser des *régions prototypiques*. Les auteurs travaillent dans l’espace CIELUV (conditions d’affichage sur écran) et utilisent deux types de tâches pour estimer la prototypicalité : (i) une tâche de catégorisation binaire où les participants doivent choisir entre BLEU et VERT³ et (ii) une catégorisation graduelle où les participants déplacent un curseur de 0 (qui signifie complètement vert) à 100 (complètement bleu). Pour chaque nuance testée les réponses sont agrégées pour produire un score de typicité (proportion de réponses « bleu », ou valeur moyenne du curseur), puis les nuances sont classées selon ce score. Pour construire une représentation géométrique empirique de la région prototypique, les auteurs retiennent les k nuances les mieux notées (par exemple les 75%, 50% ou 25% des points les mieux notés) et calculent l’enveloppe convexe de ce sous-ensemble de points. De manière visuelle on peut imaginer un

1. Bien que cet extrait de Rosch (1978) ne concerne pas les couleurs mais d’autres catégories du langage naturel, nous estimons que la critique reste valable.

2. GÄRDENFORS (2000, sec. 4.9) : "One can introduce the notion of a prototypical area and then determine a generalized Voronoï tessellation by computing distances from such areas instead. This idea is modeled by assuming that the prototypical area for a concept is described by a circle with centre $p = \langle p_1, \dots, p_n \rangle$ and radius c_p ."

3. DOUVEN, WENMACKERS et al. (2017, p.708) : "a two-alternative forced-choice task"

élastique tendu autour des points : dans l'espace colorimétrique tridimensionnel cette enveloppe convexe constitue un *polyèdre* qui correspond à la *région prototypique*.




Illustration extraite de DOUVEN, WENMACKERS et al. (2017) — Régions prototypiques du BLEU et du VERT. Tous les 2×144 points sélectionnés (en haut à gauche); les 75% des points les mieux notés (en haut à droite); les 50% les mieux notés (en bas à gauche); les 25% les mieux notés (en bas à droite).

1.5.2. Accorder aux cas-limites un espace propre

Les cas-limites désignent ici les nuances de couleur pour lesquelles la plupart des gens hésitent dans la catégorisation. Dans un modèle à prototypes uniques, ils correspondent intuitivement aux points situés à égale distance entre deux prototypes. Ainsi, si x est un cas-limite entre l'ORANGE et le ROUGE, alors une translation *infinitésimale* de x vers l'un ou l'autre côté suffit pour le faire entrer respectivement dans la catégorie du ROUGE ou dans celle de l'ORANGE. Réciproquement, dans un diagramme de Voronoï classique, il est *en théorie* possible de déterminer un point x arbitrairement proche de l'arête d'équidistance entre deux cellules (par exemple celle séparant ROUGE et ORANGE), tout en demeurant à l'intérieur de la cellule de Voronoï du

ROUGE¹. Les cas limites sont situés au sein de frontières sans épaisseur.

Bien qu'au premier abord le problème de l'unicité des points prototypiques évoqué dans la section précédente (1.5.1) semble ne pas avoir de lien avec le problème des cas-limites, DOUVEN, DECOCK et al. (2013) a modifié les diagrammes de Voronoï classiques en diagrammes créés à partir de *régions prototypiques* pour résoudre les deux problèmes en même temps.

Imaginons que l'on assigne à la catégorie ROUGE deux prototypes différents. On suppose que les prototypes de toutes les autres couleurs sont connus et fixés ; notons cet ensemble Γ qui contient, donc, tous les points prototypiques à l'exception de celui de la catégorie du ROUGE. Posons deux points prototypiques pour le rouge, notés p_{rouge_1} et p_{rouge_2} en admettant qu'ils ont des positions distinctes, c'est-à-dire que $p_{\text{rouge}_1} \neq p_{\text{rouge}_2}$. On peut donc définir deux ensembles Γ_1 et Γ_2 qui ne diffèrent que par la position du prototype du ROUGE :

$$\Gamma_1 = \Gamma \cup \{p_{\text{rouge}_1}\} \quad \text{et} \quad \Gamma_2 = \Gamma \cup \{p_{\text{rouge}_2}\},$$

On obtient deux régions de Voronoï différentes pour la catégorie du ROUGE : la première au sein du diagramme de Voronoï construit avec Γ_1 et ayant p_{rouge_1} pour point générateur. La seconde au sein du diagramme de Voronoï construit avec Γ_2 et ayant p_{rouge_2} pour point générateur. Il y a flexibilité en ce que ces deux régions *ne se recouvrent pas* : il existe des nuances de couleur x qui se situent dans la première mais pas dans la seconde, et inversement ! Ces "points frontières" permettent d'exprimer la flexibilité sémantique de manière conditionnelle : si l'on raisonne avec l'ensemble Γ_1 (c'est-à-dire en prenant p_{rouge_1} comme prototype du ROUGE) — le minimiseur de la distance pour x est p_{rouge_1} , donc x tombe dans la cellule de Voronoï de p_{rouge_1} et est classé comme ROUGE. En revanche, si l'on raisonne avec Γ_2 (en prenant p_{rouge_2} comme prototype du ROUGE), le minimiseur pour x n'est plus p_{rouge_2} , donc x n'appartient plus à la cellule associée au ROUGE et n'est plus classé comme tel².

Dans ce nouveau modèle, le volume des plusieurs zones prototypiques adjacentes est corrélée positivement au volume de la zone floue entre elles (et vice versa). Nous invitons le lecteur à

1. En supposant que l'espace métrique sous-jacent est continu (par exemple $\mathbb{R}^n$ avec la distance euclidienne)

2. Formellement :

$$\arg \min_{q \in \Gamma_1} \mathcal{D}_E(x, q) = \{p_{\text{rouge}_1}\} \quad \text{et} \quad \arg \min_{q \in \Gamma_2} \mathcal{D}_E(x, q) \neq \{p_{\text{rouge}_2}\}.$$

dessiner la situation sur un papier pour *visualiser* la propriété selon laquelle plus p_{rouge_1} et p_{rouge_2} sont distants, plus médiatrices deviennent distantes et donc plus la zone de transition devient grande. Plus généralement, plus les régions prototypiques adjacentes sont volumineuses et / ou éloignées l’une de l’autre, plus le volume de la zone de transition (i.e. l’espace des cas-limites) s’accroît¹.

A. La fonction d’appartenance combinatoire

Maintenant, pour s’approcher du modèle de DOUVEN, DECOCK et al. (2013) il faut considérer que les autres catégories ont, elles aussi, deux prototypes. Dans le modèle précédent il n’y avait qu’un seul point prototypique pour toutes les autres catégories, et donc qu’un seul diagramme de Voronoï pour p_{rouge_1} et un autre pour p_{rouge_2} . Assigner à chaque catégorie plusieurs prototypes ajoute un aspect combinatoire. Supposons qu’on a m catégories et que chacune comporte exactement deux prototypes. Notons $\mathbf{P}$ l’ensemble des ensembles de prototypes, pouvant s’écrire explicitement :

$$\mathbf{P} = \{P_1, \dots, P_m\} = \{\{p_{1,1}, p_{1,2}\}, \dots, \{p_{m,1}, p_{m,2}\}\}.$$

Commençons par le dénombrement combinatoire de toutes les configurations possibles. Pour ce faire, il faut considérer toutes les suites ordonnées de m entiers $j_1, \dots, j_m$, telles que pour chaque $i \in \{1, \dots, m\}$ la valeur j_i est soit 1 soit 2. Autrement dit, $\{1, 2\}^m$ est l’ensemble de tous les m -uplets constitués uniquement des chiffres 1 ou 2.

$$\{1, 2\}^m = \{(j_1, \dots, j_m) \in \mathbb{N}^m \mid \forall i \in \{1, \dots, m\}, j_i \in \{1, 2\}\} = \prod_{i=1}^m \{1, 2\}.$$

Chaque élément de $\{1, 2\}^m$ est un *m-uplet ordonné* : l’ordre des composantes est significatif (par ex. $(1, 2) \neq (2, 1)$). On peut maintenant exprimer l’ensemble des configurations ordonnées

1. DOUVEN, DECOCK et al. (2013, p.154; Conjecture 6.1) montre dans le cas uni-dimensionnel que l’intervalle séparant deux prototypes d’une même catégorie s’allonge, plus la *zone de flou* — c’est-à-dire l’ensemble des points dont l’appartenance catégorielle varie selon lequel des deux prototypes on prend — s’agrandit. Plus précisément, si on a deux paires de prototypes (a_1, a_2) et (b_1, b_2) la longueur de la zone floue est $\frac{\mathcal{D}_E(a_1, a_2) + \mathcal{D}_E(b_1, b_2)}{2}$. Cette observation se transpose en dimension supérieure. Bien que nous n’ayons pas de démonstration rigoureuse en dimension supérieure, nous présentons dans [ce dossier github](#) quelques résultats qui corroborent cette idée.

(comprenant exactement un unique point $p_{i,j} \in P_i$ pour tout $i \in \{1, \dots, m\}$) :

$$\Pi(\mathbf{P}) := \prod_{i=1}^m P_i = \{(p_{1,j_1}, \dots, p_{m,j_m}) \mid (j_1, \dots, j_m) \in \{1, 2\}^m\}.$$

Cet ensemble contient les 2^m combinaisons possibles produisant chacune un diagramme de Voronoï. Pour l'une de ces combinaisons $\mathbf{p} = \langle p_1, \dots, p_m \rangle \in \Pi(\mathbf{P})$ on note $V_i(\mathbf{p})$ la cellule de Voronoï du prototype p_i dans le diagramme engendré par $\{p_1, \dots, p_m\}$,

$$V_i(\mathbf{p}) := \{x \in \mathbb{R}^2 \mid \|x - p_i\| \leq \|x - p_j\| \quad \forall j \neq i\}.$$

Dans ces conditions, comment peut-on exprimer à nouveau la situation précédente dans laquelle on a un cas-limite x et deux prototypes du ROUGE tels que si on considère le premier, le point x est rouge tandis que si on considère le second, x n'est pas rouge ? Supposons que l'indice $r \in \{1, \dots, m\}$ corresponde au rouge, i.e. que $P_r = \{p_{r,1}, p_{r,2}\}$ désigne l'ensemble qui contient les deux points prototypiques du rouge.

La différence par rapport à la situation précédente tient à ce qu'il y a 2^m diagrammes de Voronoï différents. L'ensemble $\Pi(\mathbf{P})$ des configurations possibles peut être divisé en deux, en considérant d'un côté les configurations dans lesquelles on trouve $p_{r,1}$ et d'un autre côté celles où on trouve $p_{r,2}$. Le premier sous-ensemble produit des diagrammes de Voronoï où c'est $p_{r,1}$ qui génère la cellule du ROUGE et le second produit des diagrammes où la région du ROUGE revient à $p_{r,2}$. Formellement :

$$\text{Config}_{r,1} = \{\mathbf{p} \in \Pi(\mathbf{P}) \mid p_r = p_{r,1}\}, \quad \text{Config}_{r,2} = \{\mathbf{p} \in \Pi(\mathbf{P}) \mid p_r = p_{r,2}\},$$

Avec cette notation, la phrase « si on prend $p_{r,2}$, le point x n'est pas rouge » se formalise par la formule :

$$\forall \mathbf{p} \in \text{Config}_{r,2}, \quad x \notin V_r(\mathbf{p}).$$

Cela signifie que x est toujours capturé par un prototype rival dans toutes les configurations où le prototype rouge est $p_{r,2}$, le minimiseur de distance n'étant jamais $p_{r,2}$, le point x n'acquiert jamais l'étiquette ROUGE. De même, « si on prend $p_{r,1}$, le point x est rouge » peut s'écrire :

$$\forall \mathbf{p} \in \text{Config}_{r,1}, \quad x \in V_r(\mathbf{p}).$$

Si ces deux formules sont vraies, puisque $|\text{Config}_{r,1}| = |\text{Config}_{r,2}| = \frac{2^m}{2}$ et que le nombre total de configurations est 2^m , on peut dire que dans la moitié des diagrammes de Voronoï le point x est dans la cellule ROUGE et dans l'autre moitié, il ne l'est pas.

Notons que cette situation est un cas extrême qui ne doit pas occulter l'étendue des possibilités. Il peut aussi y avoir des points qui tombent *parfois* dans la cellule ROUGE en prenant $p_{r,1}$ et *parfois* dans la cellule ROUGE avec $p_{r,2}$. Si on confond *tous* les diagrammes de Voronoï, un point y peut être dans la cellule ROUGE pour un nombre $s \in \llbracket 0; 2^m \rrbracket$ de ces diagrammes. L'une des difficultés du modèle tient aussi à ce qu'un point $z \neq y$ peut tomber le même nombre de fois dans la cellule du ROUGE $s \in \llbracket 0; 2^m \rrbracket$ qu'un autre point y mais *sans qu'il s'agisse des mêmes cellules* pour l'un et pour l'autre.

Le dernier pas à faire pour arriver au modèle de DOUVEN, DECOCK et al. (2013) consiste à considérer l'ensemble de tous les diagrammes de Voronoï comme *un bloc* et donc comme devant être traités de manière agrégées. D'une certaine manière, on pourrait dire que lorsqu'un sujet humain opère une catégorisation relative à une nuance de couleur, il n'a accès qu'à un *score globalisé* obtenu en confondant tous les diagrammes de Voronoï. Pour ce cas particulier, la fonction d'appartenance qu'il propose peut être vue comme donnant un score d'appartenance général qui mélange et fait la moyenne des deux scores obtenus avec $\text{Config}_{r,1}$ et $\text{Config}_{r,2}$. En effet, le numérateur $|\{\mathbf{p} \in \Pi(\mathbf{P}) \mid x \in V_r(\mathbf{p})\}|$ comptabilise le nombre total de diagrammes qui classent x comme ROUGE.

Le degré d'appartenance de x est alors donné par la proportion des diagrammes (l'ensemble total $\Pi(\mathbf{P})$) qui attribuent x à la catégorie ROUGE, qui vaut

$$\frac{|\{\mathbf{p} \in \Pi(\mathbf{P}) \mid x \in V_r(\mathbf{p})\}|}{|\Pi(\mathbf{P})|} = \frac{2^{m-1}}{2^m} = \frac{1}{2}.$$

En agrégeant ainsi toutes les configurations possibles, x a un degré d'appartenance au ROUGE égal à 0,5.

En montant en généralité en supposant que chaque P_i contient n points, le degré d'appartenance d'un point x arbitraire au concept C_i est alors

$$M_{C_i}(x) = \frac{1}{|\Pi(\mathbf{P})|} \sum_{\mathbf{p} \in \Pi(\mathbf{P})} \mathbf{1}_{x \in V_i(\mathbf{p})} = \frac{|\{\mathbf{p} \in \Pi(\mathbf{P}) \mid x \in V_i(\mathbf{p})\}|}{n^m}.$$

Pour qu'un x ait un degré d'appartenance maximal il faut que $\forall \mathbf{p} \in \Pi(\mathbf{P}) \ x \in V_r(\mathbf{p})$ et pour que son degré d'appartenance soit 0 il faut que $\forall \mathbf{p} \in \Pi(\mathbf{P}) \ x \notin V_r(\mathbf{p})$

Cette fonction M_{C_i} est une fonction en escalier (constante par morceaux) à valeurs rationnelles : pour tout x , $M_{C_i}(x) \in \{0, \frac{1}{n^m}, \dots, 1\}$.

Intuitivement, en ajoutant des prototypes dans chaque P_i , on augmente le nombre de configurations possibles et on multiplie les niveaux de valeurs que peut prendre la fonction en escalier. Par exemple si on ajoute un point à chaque P_i on passe de n^m à $(n+1)^m$ combinaisons possibles, ce qui ajoute beaucoup de diagrammes de Voronoï supplémentaires dont les frontières découpent plus finement le plan : les cellules atomiques deviennent plus petites et la hauteur des marches du graphe de la fonction diminue, de sorte que la fonction combinatoire paraît visuellement de plus en plus lisse. Donnons un exemple en prenant 4 régions prototypiques et initialement 2 prototypes par région ; on a alors $|\Pi(\mathbf{P})| = n^m = 2^4 = 16$ combinaisons et ses valeurs possibles sont des rationnels de la forme $k/16$ avec $k \in \{0, \dots, 16\}$. Le pas minimal est donc $\frac{1}{16}$. Si l'on ajoute pour chaque ensemble P_i le point milieu des deux prototypes initiaux, on passe à $n' = 3$ prototypes par région et $|\Pi(\mathbf{P})| = (n')^m = 3^4 = 81$. Avec cet ajout, la fonction, le pas minimal de la fonction $M_{C_i}(x)$ devient $\frac{1}{81}$. Entre $\frac{1}{16}$ et $\frac{1}{81}$ la hauteur des marches a donc été réduite d'un facteur $\frac{16}{81}$, et la fonction paraîtra nettement plus lisse à l'œil, bien qu'elle reste formellement une fonction en escalier.¹

A mesure que l'on ajoute des points dans P_i , la taille des marches tend vers 0, on obtient ainsi une suite de fonction combinatoire qui approche la fonction continue qui est décrite dans la section suivante.

Fonction d'appartenance continue

Introduisons maintenant les zones prototypiques continues. Pour chaque indice i , notons $r_i \subset \mathbb{R}^2$ la zone prototypique mesurable associée au concept C_i . Les ensembles finis P_i utilisés précédemment peuvent être vus comme des approximations discrètes (ensembles de points) de

1. Bien que les valeurs possibles de $M_{C_i}(x)$ appartiennent à $\{0, \frac{1}{|\Pi(\mathbf{P})|}, \dots, 1\}$, cela n'implique pas que chaque fraction $\frac{k}{|\Pi(\mathbf{P})|}$ soit effectivement réalisée pour un point x donné : l'existence d'un tel x dépend de conditions géométriques sur la configuration des prototypes. En revanche, on peut imposer certaines hypothèses qui font que lorsqu'on augmente le nombre de points dans les ensembles P_i les valeurs effectivement atteintes par $M_{C_i}(x)$ tendent à devenir plus nombreuses et donc la grille de valeurs devient dense dans $[0, 1]$.

ces zones r_i . On définit l'espace de configurations continu

$$\Pi(\mathbf{P}) := \prod_{i=1}^m r_i,$$

muni de la mesure produit de Lebesgue μ . On a $\mu(\Pi(\mathbf{P})) = \prod_{i=1}^m \text{vol}(r_i)$, qui est fini dès que chaque r_i est bornée et supposée de mesure strictement positive.

Fixons $a \in \mathbb{R}^2$ et un indice i . Posons

$$S_{a,i} := \{\mathbf{p} \in \Pi(\mathbf{P}) \mid \|a - p_i\| < \min_{j \neq i} \|a - p_j\|\}.$$


La mesure de $S_{a,i}$ s'écrit

$$\mu(S_{a,i}) = \int_{\Pi(\mathbf{P})} \mathbf{1}_{\mathbf{p} \in S_{a,i}} d\mu(\mathbf{p}),$$


et la fonction d'appartenance graduelle continue est définie par

$$M_{C_i}(a) := \frac{\mu(S_{a,i})}{\mu(\Pi(\mathbf{P}))}.$$

Si on densifie de manière appropriée les ensembles P_i , les fonctions combinatoires $M_{C_i}^{(n)}$ convergent vers la fonction continue M_{C_i} ¹



(a) Combinatorial membership function



(b) Smooth membership function

De plus, cette fonction d'appartenance continue a la forme d'une courbe en forme de S, forme préconisée en général dans le cas des couleurs ou encore dans d'autres cas².

1. https://github.com/GwenTsang/conceptual_spaces/blob/main/chapter_1/membership/Compare_densified_combinatorial_graded_membership_to_continuous_graded_membership.ipynb

2. DOUVEN (2016) : "Hampton does note as a possible drawback of this suggestion that it yields a linear membership function, where on the grounds of previous empirical work (e.g., McCloskey & Glucksberg, 1978) one would expect an S-shaped membership function instead"

Au-delà des couleurs : le défi de la sémantique lexicale

Retraçons rapidement le chemin parcouru dans le premier chapitre. En premier lieu, nous avons introduit les espaces colorimétriques CIELAB et CIELUV. Partant de là, nous avons détaillé les étapes de construction d'un espace conceptuel des couleurs, depuis la collecte de données de similarité (1.4.1) jusqu'à leur projection dans un espace de faible dimensionnalité via le multidimensional scaling (1.4.2). Le cœur du chapitre a porté sur la modélisation de la catégorisation. En exposant les théories des exemplaires (1.4.3) et du prototype (1.4.4), nous avons montré comment la théorie des espaces conceptuels s'appuie sur l'hypothèse d'une organisation optimale de ces catégories. C'est dans ce cadre que nous avons présenté la technique des pavages de Voronoï (1.4.4b) comme une méthode parcimonieuse pour partitionner l'espace en régions distinctes, correspondant aux différentes catégories de couleurs. Toutefois, nous avons vu qu'une telle partition peine à capturer la flexibilité sémantique et les cas-limites. Cette limite nous a conduits à des modèles plus sophistiqués où les prototypes ne sont plus des points uniques, mais des régions prototypiques (1.5.1).

L'application des espaces conceptuels aux couleurs illustre la puissance prédictive et explicative de la théorie des espaces conceptuels. Le succès de cette modélisation repose sur des piliers solides : un espace de faible dimensionnalité (comme CIELAB), des dimensions directement ancrées dans la perception (teinte, luminosité), et la possibilité de valider les structures géométriques par des données psychophysiques robustes (qui suggèrent que les termes de bases des couleurs (rouge, vert, bleu) correspondent à des régions convexes).

Toutefois, ce succès même nous oblige à poser une question critique : s'agit-il d'un modèle spécialisé dans les modalités sensorielles, ou bien son pouvoir explicatif peut-il s'étendre à des domaines plus abstraits de la sémantique du langage naturel ? Peut-elle représenter avec le même succès les certains concepts dont les dimensions ne sont ni sensorielles, ni en faible nombre, ni facilement interprétables ?

Comment construire un espace sémantique pour des mots comme "lit", "rêve" ou "mémoire" ? Quelles en seraient les dimensions, et seraient-elles encore interprétables ? L'idée même de "région" a-t-elle encore un sens lorsque les concepts sont définis par des relations associatives

plutôt que par des propriétés perceptuelles continues ?

C'est précisément ce défi que nous proposons d'affronter dans le chapitre suivant. En nous tournant vers le phénomène des distorsions de la mémoire, étudié à travers le paradigme DRM, nous mettrons à l'épreuve la capacité du modèle géométrique à rendre compte de la similarité sémantique. Il ne s'agira plus seulement de catégoriser des stimuli, mais d'expliquer comment la proximité dans un espace sémantique abstrait peut induire la création de faux souvenirs, nous forçant ainsi à adapter, et peut-être à réinventer, les outils de la théorie des espaces conceptuels.

Chapitre 2

Distorsions de la mémoire basées sur la similarité

Le paradigme DRM, nommé d'après le nom de ses fondateurs « Deese-Roediger-McDermott » est un cadre expérimental très utilisé pour étudier les distorsions de la mémoire, comme les intrusions de faux souvenirs, ou les fausses reconnaissances. Dans l'expérience originale de Deese (1959), les participants étudient des listes de douze mots, tous associés à un mot non présenté. Après que les participants aient lu ces listes, ils testent leur mémoire dans un rappel libre immédiat. Les résultats révèlent que, lors de ce rappel libre, les sujets sont enclins à faussement reconnaître le mot leurre.

C'est avec l'article "*Creating False Memories : Remembering Words Not Presented in Lists*" de ROEDIGER et McDERMOTT (1995) que le paradigme DRM a pris sa forme actuelle. En plus des tâches de rappel libre utilisées par Deese pour mesurer l'impact des distorsions mnésiques, Roediger et McDermott ont ajouté des tâches de reconnaissance. Là où Deese cherche à ce que les participants *citent faussement* le mot relié non présenté lors de la tâche de rappel libre, Roediger et McDermott mettent en place un protocole dont le but est que les participants *reconnaissent faussement* le mot leurre critique parmi des mots présentés. Cette expérience se déroule schématiquement en trois temps : l'exposition, le maintien en mémoire et, finalement, les tâches de reconnaissances, détaillées ci-dessous.

Tout d'abord, les participants perçoivent visuellement ou auditivement une série de listes de mots. Par exemple la liste :

lit ; repos ; éveillé ; fatigué ; rêve ; veillée ; sommeiller ; couverture ; somme ; sommeil ; ronfler ; petit somme ; paix ; bâillement ; endormi ¹

Toutes les listes utilisées sont construites de manière à ce que tous les mots soient sémantiquement reliés à un autre mot, sans que les participants en soient informés. Pour cet exemple spécifique, l'ensemble de la liste est associé au verbe « dormir ». Après l'exposition, on demande

1. Roediger et McDermott (1995, p.807) : "bed ; rest ; awake ; tired ; dream ; wake ; night ; blanket ; doze ; slumber ; snore ; pillow ; peace ; yawn ; drowsy".

aux participants une tâche de rappel libre : de rappeler autant de mots que possible de la liste et de citer tous les mots qui leur passent par l'esprit¹.

Dans une dernière étape, les participants sont soumis à une tâche de reconnaissance : des mots leur sont présentés, et ils doivent déterminer s'ils appartiennent ou non à la liste qu'ils ont précédemment lue. Dans cette épreuve, les participants sont confrontés à une tâche de reconnaissance avec trente-deux mots. Parmi ces trente-deux mots, il y a deux mots originellement présents dans la liste, six mots qui y sont fortement reliés, douze mots qui y sont faiblement reliés et douze distracteurs, qui n'y sont pas du tout reliés. Les six mots associés à ceux de la liste sont désignés comme des « leurres » sémantiquement reliés. Le mot le plus fortement associé est appelé le « leurre critique » (*critical lure*), désignation très souvent utilisée dans les études sur les faux souvenirs.

2.1.2. Résultats de l'expérience de ROEDIGER et McDERMOTT (1995)

L'article de ROEDIGER et McDERMOTT (1995) contient plus précisément deux expériences : dans la première, les participants sont exposés à des listes de douze mots et à des listes de quinze mots dans la seconde. Ainsi les résultats révèlent que plus la liste est longue, plus le rappel des leurres est important : avec une liste de douze mots, environ 40% des participants reconnaît faussement les mots leurres critiques, et cette proportion monte à 55% avec une liste de quinze mots².

Par ailleurs, la seconde expérience ajoute une tâche supplémentaire. Lorsque les participants répondent « oui, le mot était dans la liste », ou au contraire « non, il n'y était pas » au cours de l'épreuve de reconnaissance, il leur est demandé de spécifier s'ils *s'en souviennent* (*remember*), ou bien s'ils le savent (*know*). Les participants doivent donc évaluer si leur réponse est donnée sur la base d'un *souvenir* spécifique, ou bien plutôt d'une *connaissance*. L'hypothèse à tester est que la reconnaissance des mots effectivement présents dans la liste s'accompagne d'une

1. HEGE et DODSON (2004, p.13) parlent d'instructions de rappel *inclusives* (dans lesquelles il n'est pas demandé aux participants de se concentrer uniquement sur les mots de la liste) par opposition aux instructions de rappel *exclusives*.

2. ROEDIGER et McDERMOTT (1995) : "In Experiment 2, with 15-word lists, false recall increased, occurring on 55% of the occasions". Voir aussi LANGEVIN et al. (2009, p.708) : "(...) plus le nombre d'associés présentés est important, plus le taux de FR* est élevé".

réponse « *remember* », tandis que la reconnaissance des leurres suscite une réponse « *know* ». Cette hypothèse vise d'abord à tester l'existence de deux modes distincts de récupération de l'information : « *remember* » réfère plutôt à une reconnaissance fondée sur un souvenir authentique, tandis que « *know* » renvoie à une reconnaissance basée sur la familiarité ou la proximité sémantique¹. Les résultats ne vont pas dans le sens de cette hypothèse, puisque les leurres recueillent autant d'évaluations « *remember* » (48%) que les mots effectivement présentés (49%). Ces résultats vont plutôt dans le sens de l'idée que les sujets ne distinguent pas les informations provenant d'une source *externe* des informations provenant d'une source *interne*.

Deese, Roediger et McDermott estiment que la force associative des mots de la liste vis-à-vis des mots leurres peut servir de bon prédicteur du taux de fausses reconnaissances. C'est en effet ce qui est mis en exergue par DEESE (1959b, p.22) qui trouve une forte corrélation ($r = +.87$) entre cette force associative et le taux de faux souvenirs; il conclue en écrivant :

the probability of occurrence of a particular word as an intrusion in recall is proportional to the average association strength of that word to the words on the list

ROEDIGER, WATSON et al. (2001) proposent d'examiner de plus près cette corrélation mise en évidence par Deese². Ils trouvent la même corrélation positive assez forte entre le taux de fausses reconnaissances et un certain type de force associative, appelée "backward associative Strength" (*BAS*), ($r=.73$). La *BAS* correspond à la probabilité de citer un mot en réponse à un autre dans une tâche d'association libre. Expliquons plus en détail comment cette force associative *BAS* est mesurée expérimentalement.

1. ROEDIGER et McDERMOTT (1995) : "A remember experience is defined as one in which the subject can mentally relive the experience (perhaps by recalling its neighbors, what it made them think of, what they were doing when they heard the word, or physical characteristics associated with its presentation). A know judgment is made when subjects are confident that the item occurred on the list but are unable to reexperience (i.e., remember) its occurrence. In short, remember judgments reflect a mental reliving of the experience, whereas know judgments do not."

2. ROEDIGER, WATSON et al. (2001, p.387) : "In fact, Deese (1959b) reported that the correlation between a list's mean BAS and the probability of recall of its associated critical item was .87".

LANGEVIN et al. (2009, p.707) : "(...) plus les items sont fortement associés au leurre critique, plus ils sont proches dans le réseau de connaissances, plus ils sont facilement activés, et plus les FR sont induites"

2.2. Mesurer la force associative entre deux mots

La mesure de la similarité sémantique entre deux mots w_i et w_j quelconques a historiquement reposé sur deux approches. La première consiste à demander directement à des participants d'évaluer la similarité entre les mots (ROMNEY et al., 1993). La seconde approche s'appuie sur des données issues de tâches d'association verbale, où les participants doivent produire les premiers mots qui leur viennent à l'esprit en réponse à un mot stimulus (Douglas L. NELSON et al., 1998). Imaginons qu'on cherche à établir une hiérarchie de mots associés pour le mot "abeille". Une procédure expérimentale simple est la suivante : donnez le mot "abeille" à un échantillon important de participants et demandez-leur d'écrire le premier mot qui leur vient librement à l'esprit. Cette procédure est appelée *tâche d'association libre* et le paragraphe ci-dessous montre comment les résultats obtenus permettent de quantifier la force associative entre deux mots.

Définissons $A(w_i \rightarrow w_j)$ comme la probabilité de citer le mot w_j en réponse au mot w_i . Cette probabilité est calculée en divisant le nombre de fois où w_j a été cité en réponse à w_i par le nombre total de réponses à w_i . Imaginons que chaque participant donne un seul mot associé ; alors, s'il y a n participants au total, et que k est le nombre de participants ayant cité w_j en réponse à w_i , alors $A(w_i \rightarrow w_j) = \frac{k}{n}$. Plus concrètement, pour le mot « abeille », si dans un échantillon de 100 participants ($n = 100$), 48 ont cité le mot "miel" en réponse au mot "abeille" ($k = 48$), alors la probabilité d'association libre $A("abeille" \rightarrow "miel")$ est de 48%. Plus généralement, si $Count(w_i \rightarrow w_j)$ est le nombre de fois où w_j a été cité en réponse à w_i , et R_{w_i} est l'ensemble de tous les mots cités par tous les participants au cours de toutes les tâches d'association libre, alors la définition précédente peut être formulée comme suit :

$$A(w_i \rightarrow w_j) = \frac{Count(w_i \rightarrow w_j)}{\sum_{w_k \in R_{w_i}} Count(w_i \rightarrow w_k)}$$

où le dénominateur $\sum_{w_k \in R_{w_i}} Count(w_i \rightarrow w_k)$ représente le nombre total de réponses au mot w_i (c'est-à-dire le nombre total de mots cités par l'ensemble des participants en réponse à w_i). Ainsi, cette formule calcule la force de l'association $w_i \rightarrow w_j$ en rapportant le nombre de fois où cette association est observée (le numérateur) au nombre total de réponses (le dénominateur)¹.

1. Douglas L. NELSON et McEVoy (2000, p.888) : "Indiscrete tasks, only a single response is produced for each normed word or cue, with strength of association traditionally measured by counting the number of people who

Si tous les participants ont cité le mot w_j en réponse à w_i , alors $A(w_i \rightarrow w_j) = 1$ et moins il y a de participants qui citent w_j en réponse à w_i , plus $A(w_i \rightarrow w_j)$ sera proche de 0.

Notons l'ensemble des mots d'une liste DRM par $\mathcal{L} = \{w_1, \dots, w_m\}$ et w_{lore} le mot-leurre critique associé à cette liste. On peut alors calculer la somme des forces associatives moyennes des mots de la liste $\mathcal{L}$ à l'égard du mot-leurre w_{lore} en additionnant toutes les forces associatives : $\sum_{w_i \in \mathcal{L}} A(w_i \rightarrow w_{lore})$.

Comme évoqué, de nombreuses recherches¹ ont montré que plus cette somme est élevée, plus la probabilité d'observer des fausses reconnaissances du mot-leurre est grande, toutes choses étant égales par ailleurs. En fait, les listes de DRM sont construites de telle sorte que les mots de chaque liste ont une forte association avec le mot-leurre critique correspondant (cf. 2.3.5). Ainsi, les données issues des tâches d'associations libres sont fréquemment utilisées pour *concevoir* les listes de mots utilisées dans les expériences DRM.

2.3. La relation étroite entre force associative et degré de similarité

2.3.1. WAS pour la force associative et LSA pour le degré de similarité

Il est possible de construire un Espace d'Association de Mots (WAS) à partir de données sur les associations libres entre n mots. Pour ce faire, il faut d'abord partir d'une matrice carrée de $n \times n$. Chaque élément (i, j) de cette matrice représente la probabilité qu'un sujet cite le mot w_j en réponse au mot w_i , c'est-à-dire $A(w_i \rightarrow w_j)$.

L'application de la technique du *multidimensionnal scaling* (MDS) à cette matrice permet de représenter les mots dans un espace où leur proximité reflète la force de leurs associations mutuelles. Dans cet espace, plus les mots partagent un grand nombre d'associés communs ou sont fortement associés aux mêmes mots, plus leur proximité est grande. Cependant, les espaces construits à partir des données d'association correspondent-ils exactement aux « espaces conceptuels » traditionnels ? Deux différences majeures de prime abord. D'une part, la distance (resp. la proximité) entre deux mots ne représente pas leur dissimilarité (resp. leur similarité) sémantique, et d'autre part les dimensions de cet espace, souvent bidimensionnel, ne sont pas

produce each response. This count is then divided by the sample size to determine response probability".

1. Entres autres DEESE (1959b), ROEDIGER, WATSON et al. (2001) et GALLO et ROEDIGER (2002)

interprétables.

Les espaces obtenus par l'analyse sémantique latente (LSA) reposent sur la *cooccurrence* de mots dans des contextes similaires pour évaluer leur proximité sémantique. L'analyse sémantique latente (LSA) est une technique qui détermine la proximité sémantique des mots sur la base de leur cooccurrence dans des contextes similaires au sein d'un corpus donné. Étant donné un corpus de textes dont l'ensemble des mots est noté V , l'analyse sémantique latente permet de représenter chaque mot $w \in V$ sous la forme d'un vecteur $\vec{w} \in \mathbb{R}^m$, où m est la dimensionnalité de l'espace sémantique de la LSA. De manière schématique, la représentation vectorielle est déterminée par les mots qui cooccurrent le plus souvent avec w ou qui apparaissent dans des contextes similaires¹. Par exemple, les mots « dormir » et « lit » apparaissent souvent à proximité les uns des autres dans les textes. Lorsque ces textes sont traités à l'aide de la LSA, les vecteurs représentant ces mots devraient produire un score de similarité sémantique élevé, indiquant leur forte relation sémantique. De même, les mots « sommeil » et « repos » peuvent être utilisés de manière interchangeable dans certains contextes, ce qui suggère que leurs contextes d'utilisation sont similaires. Par conséquent, leurs vecteurs dérivés de LSA devraient également présenter un score de similarité élevé, reflétant leur relation sémantique.

2.3.2. Les espaces d'association de mots sont un bon indicateur des intrusions de mots-leurres.

Lequel de l'espace LSA ou de l'espace WAS rend le mieux compte de la probabilité d'intrusion d'un mot-leurre compte tenu des mots d'une liste DRM ? Pour répondre à cette question, STEYVERS et al. (2005) utilisent des données d'association libre collectées par Douglas L. NELSON et al. (1998) et appliquent des techniques de réduction de la dimensionnalité² aux matrices d'association obtenues. Ils utilisent également une analyse sémantique latente (LSA) réalisée par Landauer et Dumais (1997) sur la base de corpus encyclopédiques.

Leur objectif est de déterminer lequel des espaces obtenus par une LSA ou le WAS peut le mieux rendre compte du taux d'intrusion lors du rappel libre dans les expériences de DEESE

1. Les modèles LSA s'inscrivent dans l'hypothèse distributionnelle selon laquelle les mots utilisés et/ou apparaissant dans les mêmes contextes tendent à avoir des significations similaires.

2. Ils disent utiliser deux techniques de réduction de dimensionnalité pour la matrice d'association : la décomposition en valeurs singulières (SVD) et le multidimensionnal scaling (MDS).

(1959a)). Les résultats de Deese peuvent être présentés comme suit : pour une liste de mots $w_1, \dots, w_{12}$, un certain pourcentage de participants cite le mot-leurre w_L pendant la phase de rappel libre. A l'instar du tableau présenté dans l'annexe C, les résultats de Deese se présentent sous la forme d'un tableau dont chaque ligne correspond à une liste DRM différente. Ce tableau a quatorze colonnes : les douze premières colonnes contiennent les douze mots de la liste, la treizième colonne contient le mot-leurre et la quatorzième colonne le taux d'intrusion obtenu en moyenne lors du rappel libre.

Les deux espaces LSA et WAS proposés par STEYVERS et al. (2005) permettent à chaque liste particulière $w_1, \dots, w_{12}$ et au leurre associé w_L d'être représentés par treize vecteurs distincts dans ces deux espaces, ce qui nous permet de comparer le pouvoir prédictif des deux espaces, LSA et WAS, en procédant comme suit. Dans la suite de ce chapitre, " w_i " sera utilisé pour désigner à la fois le *mot* à la fois le *vecteur* qui le représente, tout en précisant s'il est question du premier ou du second ¹.

Cette fonction f est utilisée pour prédire le taux d'intrusion moyen de ce mot-leurre, qui sera observé avec cette liste lors de la phase de rappel libre. Cette fonction f doit être définie de manière à ajuster au mieux les résultats sur les taux d'intrusion moyens. Cette fonction f est utilisée pour corrélérer le taux d'intrusion du mot-leurre avec la proximité moyenne des mots de la liste par rapport à ce mot-leurre. Intuitivement, pour prédire un taux d'intrusion plus élevé pour des listes fortement liées (p. ex. : *femme, poupée, robe*) que pour des listes faiblement liées (p. ex. : *garçon, derrière, soirée, ride*), il serait possible de prendre en compte la moyenne des distances entre les vecteurs des mots de la liste et le vecteur du leurre, ou la moyenne des similarités cosinus entre les vecteurs des mots et le mot leurre. Si une liste de mots $w_1, \dots, w_{12}$ liée au mot-leurre w_L génère un taux d'intrusion plus élevé que la liste $w'_1, \dots, w'_{12}$ avec le mot-leurre w'_L , cela devrait se refléter proportionnellement dans la différence entre la prédiction $f(w_1, \dots, w_{12}, w_L)$ et la prédiction $f(w'_1, \dots, w'_{12}, w'_L)$. Plus la différence entre le taux d'intrusion de w_L causé par la liste $w_1, \dots, w_{12}$ est différente du taux d'intrusion de w'_L causé par la liste $w'_1, \dots, w'_{12}$, plus $f(w_1, \dots, w_{12}, w_L)$ devrait être différent de $f(w'_1, \dots, w'_{12}, w'_L)$. L'idée de STEYVERS et al. (2005) est donc de se demander si la fonction f fournit une meilleure prédiction des vraies

1. Si un w apparaît comme argument d'une fonction il s'agit évidemment du vecteur. Pour une notation plus lourde mais moins équivoque, pour tout mot $w \in V$, son vecteur associé peut être noté $\mathbf{v}(w)$.

données lorsque ses paramètres sont des vecteurs dans WAS ou des vecteurs dans LSA ?

En détail, STEYVERS et al. (2005) testent cette corrélation pour deux LSA et trois espaces WAS. Leurs résultats sont illustrés par cinq courbes dans un graphique. Trois courbes représentent la corrélation entre les prédictions et les résultats obtenus par Deese pour les espaces WAS, et deux courbes représentent la corrélation entre les prédictions et les résultats obtenus par Deese pour l'espace LSA. En arrondissant les corrélations en valeurs entières, les prédictions avec des vecteurs dans l'espace WAS ont une corrélation $r = 0,6$ tandis que les prédictions avec des vecteurs dans l'espace LSA ont une corrélation $r = 0,2$. En d'autres termes, STEYVERS et al. (2005, p.7) concluent que WAS a un pouvoir prédictif d'intrusion en rappel libre nettement supérieur à celui de LSA. Certains espaces LSA plus récents pourraient produire de meilleurs scores de corrélation que celui utilisé par STEYVERS et al. (2005) Dans les paragraphes suivants, on donne quelques arguments dans ce sens.

2.3.3. Evaluer la porosité entre force associative et degré de similarité

Si la *force associative* moyenne des mots de la liste vis-à-vis du mot leurre (MBAS) est corrélée positivement avec le taux de fausses reconnaissances, la *similarité* moyenne des mots de la liste avec le leurre est, elle aussi, corrélée positivement avec ce même taux¹. Ces deux variables ont donc une relation monotone avec le taux d'intrusion et le taux de fausses reconnaissances².

C. J. BRAINERD, M. CHANG et BIALER (2020) suggèrent que la force associative moyenne des mots de la liste vis-à-vis du mot leurre n'est corrélée positivement aux fausses reconnaissances *que* lorsque les mots de la liste sont *similaires* au mot leurre.

Par exemple, bien que A ("marteau" → "clou") et/ou A ("chat" → "souris") soient élevés, le premier mot est assez peu susceptible d'être *confondu* avec le second, notamment parce que les deux termes n'ont pas un très bon score de similarité³.

1. PETILLI et al. (2024, p.4) : "similarity metric is a reliable predictor of BAS, where higher similarity between words in a semantic space is associated with increased human-rated associative strength between studied items and the critical lure".

2. C. J. BRAINERD, M. CHANG, BIALER et LIU (2023, p.11) : "(...) unspecified monotonic relation between the strength of their causal variable and false memory".

3. Ces mots ne sont pas similaires sémantiquement en ce sens qu'ils ne sont pas substituables l'un à l'autre. Ces mots sont également dissimilaires quant à leur nombre de lettre, à leur morphologie / orthographique et à leur phonologie.

Dans l'autre sens, deux mots très similaires sémantiquement, et tous deux d'usage fréquent dans le langage, sont très souvent associés l'un à l'autre. Autrement dit, pour n'importe quelle paire de mots w_i et w_j , il semble y avoir une corrélation positive entre leur degré de similarité et le degré auquel ils sont associés : plus $Sim(w_i, w_j)$ est élevé, plus il y a de probabilité que $A(w_i \rightarrow w_j)$ et/ou $A(w_j \rightarrow w_i)$ soient élevés. En témoigne le fait que les listes DRM sémantiques contiennent souvent des mots *synonymes* du leurre critique. La relation de synonymie implique souvent à la fois une forte similarité et une force associative élevée. Si w_i et w_j sont synonymes, on peut s'attendre à ce qu'ils soient proches à la fois dans WAS et dans un espace basé sur une LSA.

Pour examiner la *corrélation* entre la force associative et le degré de similarité, proposons de déterminer deux sous-ensembles. Tout d'abord, considérons l'ensemble des mots d'une liste DRM en notant $\mathcal{L} = \{w_1, \dots, w_m\}$. Le nombre de mots dans la liste $\mathcal{L}$ est noté $|\mathcal{L}|$. Considérons V un large lexique de mots. Cela étant, déterminons deux sous-ensembles de V . Le premier sous-ensemble, noté A_σ , contient l'ensemble des mots dont la force associative moyenne avec tous les mots de $\mathcal{L}$ dépasse un seuil $\sigma \in [0; 1]$. Le second sous-ensemble, noté B_σ , contient l'ensemble des mots dont le degré de similarité moyen avec tous les mots de $\mathcal{L}$ dépasse ce même seuil σ :

$$\begin{array}{cc} A_\sigma & B_\sigma \\ \{w_i \in V \mid \sum_{w_j \in \mathcal{L}} A(w_j \rightarrow w_i) > \sigma \cdot |\mathcal{L}|\} & \{w_i \in V \mid \sum_{w_j \in \mathcal{L}} Sim(w_j, w_i) > \sigma \cdot |\mathcal{L}|\} \end{array}$$

Il s'agit dans les deux cas de tester tous les mots dans V pour ne garder que ceux qui dépassent le seuil avec tous les mots dans $\mathcal{L}$. Plus le seuil est proche de 1, plus il est difficile pour un mot d'être inclus dans l'ensemble. Inversement, plus le seuil σ est proche de 0, plus ces ensembles contiennent de mots. S'il y a n mots dans A_σ , ceux-ci correspondent aux n mots les plus fortement associés à $\mathcal{L}$ ou les n plus proches voisins de $\mathcal{L}$ dans un espace de similarité. Cela se vérifie de la même manière avec l'ensemble B_σ pour les mots les plus fortement associés ou similaires en moyenne aux mots dans $\mathcal{L}$. Pour évaluer la corrélation entre la force associative et le degré de similarité, il faut donc évaluer à quel point les mêmes mots apparaissent dans les deux ensembles. Il semble plus intéressant de comparer si les mêmes mots apparaissent dans les deux ensembles A_σ et B_σ en utilisant un seuil σ élevé, situation dans laquelle seuls les mots fortement liés ou similaires sont inclus. En effet, si $\mathcal{L}$ est une liste DRM sémantique, elle a

été conçue pour *tendre* vers certains mots leurre reliés. L'idée est que moins il reste de mots dans les ensembles à un seuil élevé, plus il y a de chances que ces mots incluent le mot leurre, apparaissant à la fois dans A_σ et B_σ . Si les mêmes mots apparaissent dans les deux ensembles avec un seuil élevé, cela indique une convergence entre le réseau associatif et le réseau de la similarité sémantique qui sous-tend les fausses reconnaissances dans les expériences DRM. Définissons un seuil σ_{max} :

$$\sigma_{max} = \max \left\{ \sigma \in [0, 1] : \left\{ w_i \in V : \sum_{w_j \in \mathcal{L}} \text{Sim}(w_j, w_i) > \sigma \cdot |\mathcal{L}| \right\} \neq \emptyset \right\}$$

Autrement dit, l'ensemble devient vide pour toute valeur de σ supérieure à σ_{max} . Si l'ensemble $B_{\sigma_{max}}$ contient un seul élément, il s'agit du mot le plus similaire à tous les mots de la liste $\mathcal{L}$. Si l'ensemble $B_{\sigma_{max}}$ contient plusieurs éléments, c'est qu'il y a au moins deux mots qui ont exactement le même score de similarité moyen avec les mots de la liste $\mathcal{L}$ ¹.

2.3.4. Spatialisation des relations associatives et de similarité

Comme évoqué, les mots d'une liste DRM peuvent être représentés par des points, en quel cas la liste $\mathcal{L}$ correspond à un cluster de points. Si la similarité est interprétée en termes de distance, cela signifie que plus une liste $\mathcal{L}$ est associée à un seuil σ_{max} élevé, plus le mot leurre w_j est *proche* de tous les mots de la liste. Il nous semble en fait y avoir deux paramètres *distincts* qui augmentent la valeur de σ_{max} : d'une part la densité interne du cluster formé par les mots de la liste, d'autre part la centralité du mot leurre. Une valeur de σ_{max} élevée suggère que les points qui représentent les mots de la liste $\mathcal{L}$ forment un cluster dense et petit² et/ou que les mots de la liste sont regroupés autour du point correspondant au mot leurre. *Isolons* ces deux paramètres.

Pour évaluer la taille globale du cluster, considérons $\mathcal{L}^+ = \mathcal{L} \cup \{w_L\} = \{w_1, \dots, w_m, w_L\}$ un ensemble contenant les mots de la liste DRM et le mot leurre critique. La *taille / densité* globale du cluster formé par les mots dans $\mathcal{L}^+$ peut être mesurée par la moyenne des similarités

1. Ces mots satisfont l'équation $\arg \max_{w \in V} \sum_{w_j \in \mathcal{L}} \text{Sim}(w_j, w)$.

2. Si le mot leurre est au milieu de deux mots w_i et w_j , alors les distances du leurre à w_i et à w_j seront petites si w_i et w_j sont eux-mêmes proches. Cela montre que la maximisation de la similarité du mot leurre avec les mots de la liste n'est pas indépendante de la maximisation de la similarité entre les mots de la liste.

entre paires distinctes de mots :

$$M_{\text{Sim}}(\mathcal{L}^+) = \frac{2}{|\mathcal{L}^+|(|\mathcal{L}^+| - 1)} \sum_{\substack{w_i, w_j \in \mathcal{L}^+ \\ i < j}} \text{Sim}(w_i, w_j).$$

Plus la valeur de $M_{\text{Sim}}(\mathcal{L}^+)$ est élevée, plus les mots sont proches les uns des autres, indiquant spatialement un cluster dense. Pour évaluer la centralité du point correspondant au mot leurre, on peut définir une fonction $\text{Centre}(\mathcal{L})$ qui renvoie les coordonnées du point représentant la moyenne de la position de tous les points de l'ensemble :

$$\text{Centre}(\mathcal{L}) := \frac{1}{|\mathcal{L}|} \sum_{w_j \in \mathcal{L}} w_j.$$

Il suffit ensuite de mesurer la distance ou la similarité du vecteur du mot leurre avec $\text{Centre}(\mathcal{L})$; plus cette distance est petite, plus il est central.

Bien que partielle, cette approche donne un aperçu de celle de PETILLI et al. (2024). Ces derniers proposent que la similarité sémantique entre les mots d'une liste DRM et le centroïde de cette liste sont directement corrélés à la probabilité de fausse reconnaissance¹. Ainsi, pour maximiser l'effet de fausse reconnaissance, le leurre critique doit être positionné aussi près que possible de ce centroïde. Suivant ce principe il devient possible de *générer* computationnellement des listes DRM en partant d'un espace dans lequel les mots sont représentés par des vecteurs. L'article de PETILLI et al. (2024) propose précisément un logiciel ouvert permettant de générer des listes DRM correspondant à des clusters de points maximalemt petits dans l'espace *FastText*².

Bien que ces méthodes offrent des voies pour prédire le taux de fausses reconnaissances produit par une liste, cela ne permet pas d'expliquer ce qui se produit psychologiquement lors de l'intrusion du mot leurre critique. En fait, la valeur de $\text{Sim}(w_i, w_j)$ comme renvoie à une *similarité globale* entre les mots w_i et w_j . Dans ce qui suit, nous proposons d'analyser la notion de *similarité* : y a-t-il des facteurs qui *sous-déterminent* le degré de similarité global entre deux mots ? En effet, dans le langage courant, il semble naturel de dire que deux mots sont similaires *sur une certaine dimension, sous une certaine modalité, etc.*

1. PETILLI et al. (2024) : “Specifically, the higher the (semantic) similarity between the new words and the centroid of their lists, the higher the probability of false recognition”

2. Les auteurs ont déposé leur logiciel en ligne : <https://osf.io/gsrifu>.

2.3.5. Que la similarité globale peut être décomposée en similarités locales (ex. sémantique, orthographique, phonologique, émotionnelle, etc.)

PETILLI et al. (2024, p.21) montrent que la *proximité* entre deux mots dans l'espace peut être due aussi bien à une similarité *sémantique* qu'à une similarité *orthographique*, ou encore même à une similarité *visuelle*. Ils proposent une visualisation en deux dimensions des points représentant les mots de plusieurs listes DRM identifiées par leur méthode. Ci-dessous deux graphiques issus de leur article qui représentent deux listes DRM sous forme de clusters de points densément rapprochés dans l'espace *FastText* :




Fig. (a) et (b). Visualisation 2D de deux clusters de mots dans l'espace *FastText*. La proximité des points reflète la similarité cosinus entre les vecteurs correspondants. Les points bleus représentent la liste DRM et les points rouges les distracteurs. Extrait de PETILLI et al. (2024).

De plus, au sein des listes DRM qui partagent une similarité sémantique, il semble possible d'identifier des sous-catégories distinctes. Par exemple, M. CHANG et C. BRAINERD (2021, p.9) différencie les listes DRM *émotionnellement similaires* des listes de mots *émotionnellement neutres*. Donnons un exemple pour chacune des listes. D'abord une liste DRM sémantique dont les mots sont de la même tonalité émotionnelle et tous reliés au leurre critique « cry » :

“tears, sad, tissue, sorrow, eyes, weep, sob, bawl, frown, unhappy, upset, down”.

Et une autre liste DRM sémantique neutre, dont tous les mots sont reliés à « chair » :

“table, sit, leg, seat, couch, desk, sofa, cushion, sitting, stool, bench, rocking”.

Si le degré de *similarité globale* est sous-déterminé par des *similarités locales*, alors il est possible d’intervenir sur la première en faisant varier la seconde. Disons tout de suite là où nous voulons en venir : si les mots $w_1, \dots, w_{12}$ sont *sémantiquement* similaires avec le mot leurre w_L , alors en *orientant l’attention des participants* vers les propriétés phonologiques ou orthographiques de $w_1, \dots, w_{12}$ cela diminuera le degré de similarité et/ou la force associative entre cette liste et ce mot leurre et résultera *in fine* en une diminution du taux de faux souvenirs.

Une première hypothèse serait donc que la similarité globale soit modulée par les divers degrés des similarité locales : le degré de similarité morpho-orthographique (pour les mots lus), phonétique (pour les mots entendus), et les similarités sémantiques entre les mots. La deuxième hypothèse est que l’importance relative de ces domaines de similarité peut changer selon que l’attention du sujet est dirigée vers les aspects sémantiques ou orthographiques de A et B . Ces deux similarités locales sont susceptibles de faire varier la similarité globale (2.5.3). Il est ainsi possible d’intervenir sur la similarité globale en intervenant (positivement ou négativement) sur les deux *poids* correspondants à la similarité sémantique et à la similarité orthographique. La troisième hypothèse est celle d’une transitivité des corrélations. D’une part, si une similarité locale est corrélée *positivement* à la similarité globale et que la similarité globale est corrélée positivement au taux de fausses reconnaissances, alors, cette similarité locale est elle aussi corrélée positivement avec ce même taux¹. D’autre part, si une similarité locale est corrélée *négativement* à la similarité globale et que la similarité globale est corrélée positivement au taux de fausses reconnaissances, alors, cette similarité locale est elle aussi corrélée négativement avec ce même taux². Pour tester expérimentalement ces hypothèses, il faut comparer le taux de faux souvenirs induits par une même liste DRM dans différentes conditions attentionnelles orientant les participants, soit vers le contenu sémantique, soit vers la forme orthographique/phonologique

1. Cela s’appréhende mieux en interprétant "corrélation positive" par "relation de proportionnalité" : si la similarité A est proportionnelle à la similarité B , et que la similarité B est proportionnelle au taux de faux souvenirs C , alors la similarité A est proportionnelle au taux de faux souvenirs C : $[(A \propto B) \wedge (B \propto C)] \Rightarrow A \propto C$

2. Si la similarité A est inversement proportionnelle à la similarité B , et que la similarité B est proportionnelle au taux de faux souvenirs C , alors la similarité A est inversement proportionnelle au taux de faux souvenirs C : $[(A \propto 1/B) \wedge (B \propto C)] \Rightarrow A \propto 1/C$

des mots. Un plus faible taux de faux souvenirs en condition orthographique/phonologique par rapport à la condition sémantique irait dans le sens de ces hypothèses. La partie suivante expose précisément de telles expériences et montre que le cadre DRM est idéal pour intervenir sur des paramètres ciblés augmentant ou diminuant la probabilité des fausses reconnaissances.

2.4. Traitement relationnel et traitement distinctif

De nombreuses études (MCCABE et al. (2004), Mark J. HUFF et BODNER (2013), Mark J. HUFF et BODNER (2019), SMITH et al. (2022)) ont tenté d'identifier les facteurs susceptibles d'influencer le taux de fausses reconnaissances. Mark J. HUFF et BODNER (2013) distingue deux manières de traiter les informations sur les mots de la liste : *relationnelle* et *distinctive*. Pour lui, le fait de « se souvenir de A et de B » peut être réalisé à la fois de manière distinctive ou relationnelle, avec un continuum entre les deux¹. Huff a testé expérimentalement l'impact de ces deux types d'encodage sur les fausses reconnaissances. L'idée de ces expériences était de comparer l'impact d'un traitement *spécifique* aux mots, qui oriente l'attention des sujets vers ce qui *distingue les mots*, avec celui d'un encodage relationnel, favorisant le traitement des *similarités* entre les mots².

Le traitement relationnel encode une ou plusieurs dimensions de similarité entre un ensemble d'éléments tandis que le traitement spécifique à un élément implique des informations propres à cet élément³. Quelles sont les *conséquences* du traitement relationnel ? Dans celui-ci, les participants sont souvent invités à identifier et à traiter les points communs entre les éléments à mémoriser, comme les classer par catégories⁴. Cela augmente la superposition des caracté-

1. SMITH et al. (2022) "(...) item-specific encoding and relational encoding likely operate on a continuum of our processing in which tasks may be more likely to promote one processing type or another".

2. Mark J. HUFF et BODNER (2013, p.1248) : « The item-specific group was further instructed that for each word, they should 'think of a unique characteristic of each word that differentiates it from the other words on the list'. The relational group was further instructed to (...) "concentrate on what the words in that list have in common and associate them together" « .


3. HUNT et al. (2011, p3) : "Relational processing encodes some dimension(s) of similarity among a set of items, e.g., spatial/temporal and semantic, whereas item-specific processing entails information specific to individual items".

4. NAIRNE (2006, p.36) : "(...) In relational processing, typically participants are asked to process commonalities among to-be-remembered items, such as sorting the items into categories".

ristiques entre les traces mémorielles encodées¹ en raison de l'encodage des caractéristiques communes, mais cela fournit également un indice de récupération : les participants savent que les éléments à rappeler proviennent d'une catégorie particulière.


2.4.1. Résultats des expériences comparant traitement relationnel et spécifique

Quel a été l'impact de ces consignes sur le taux de reconnaissance correcte (HR) et le taux de fausse reconnaissance (FA) ? Premièrement l'encodage item-spécifique et l'encodage relationnel ont augmenté les scores de rappels/reconnaissances corrects par rapport à la simple lecture. Deuxièmement, dans ces trois expériences, les faux souvenirs sont plus faibles dans le groupe item-spécifique que dans le groupe relationnel²



1. NAIRNE (2006, p.36) : "(...) commonalities is likely to increase the amount of feature overlap across encoded traces because common features are encoded, but it can produce a very salient retrieval cue as well : participants know that the to-be-remembered items come from a particular category".

2. MCCABE et al. (2004, p.1077) : "[This] confirms the hypothesis that item-specific encoding leads to less false remembering than does relational encoding [.64 vs. .84]". Mark J. HUFF et BODNER (2013, p.1249) : "(...) the item-specific group was less likely to falsely recognize CIs [Critical Item(s)] than the relational group (.52 vs. .73) (...)". Mark J. HUFF et BODNER (2019, p.1497) : "As expected, relative to the read group, correct recall was greater following item-specific encoding (.64 vs. .71) (...)".



Graphiques X(a) et X(b) comparant les résultats des trois groupes "item-spécifique", "relationnel" et "contrôle". L'axe vertical du premier graphique reflète à quel point les participants réussissent à discriminer les mots anciens des mots nouveaux¹. L'axe vertical du second graphique correspond au taux de fausses reconnaissances pour tous les mots leurres reliés aux mots de la liste. La valeur de monitoring λ reflète la tendance des réponses du groupe : une valeur λ élevée (*resp.* faible) signifie que la tendance du groupe est de répondre "nouveau" (*resp.* ancien) aux mots leurres lors de la phase de reconnaissance². Extrait de Mark J. HUFF et BODNER (2019).

Ces résultats soulèvent deux interrogations. D'une part, qu'est-ce qui distingue précisément le fonctionnement cognitif des participants dans ces différentes conditions ? D'autre part, *comment* l'encodage distinctif permet-il de réduire le taux de fausses reconnaissances ? Deux hypothèses principales ont été avancées pour expliquer l'avantage du traitement distinctif mis en évidence dans ces expériences. Ces deux hypothèses sont les suivantes :

- Les participants rejettent le leurre critique *parce qu'ils* emploient une heuristique de distinctivité (2.3.1);
- Les participants rejettent le leurre critique *parce qu'ils* n'ont pas encodé suffisamment

1. Il semble que l'axe vertical du premier graphique corresponde à la valeur d' , calculée en soustrayant le z-score du taux de fausses reconnaissances (FR) au z-score du taux de bonnes reconnaissances (HR pour *Hit Rate*). Il semble que « signal » fait référence à l'information cible que les participants tentent de retrouver. Dans cette analogie, le « bruit » désigne l'information non pertinente ou distrayante susceptible d'interférer avec la détection du signal. Dans le contexte DRM, le bruit correspond aux mots nouveaux non présentés dans la liste initiale.

2. Mark J HUFF et al. (2020, p.5) : la valeur de monitoring λ est donnée par le z-score du taux de rejets corrects des mots nouveaux (CR).

d'informations sur ce leurre critique (2.3.2).

2.4.2. L'appauvrissement du traitement relationnel

Selon l'hypothèse de l'appauvrissement du traitement relationnel (*impoverished relational encoding account*), le bénéfice du traitement distinctif contre les fausses reconnaissances s'explique par le fait qu'en mettant l'accent sur les propriétés distinctives de chaque mot, il réduit la quantité d'informations encodées à propos du leurre sémantiquement relié, et donc la probabilité de le reconnaître à tort :

(...) we define the impoverished relational-encoding account as the notion that studying distinctive information interferes with the encoding of relational or associative information.¹

Puisque les différents mots de la liste sont tous sémantiquement reliés, ce traitement distinctif signifie traiter les différences dans un contexte de similarité². Ce bénéfice du traitement distinctif contre les fausses reconnaissances pourrait s'expliquer par le fait qu'en mettant l'accent sur les propriétés distinctives de chaque mot, il réduit la quantité d'informations encodées à propos du leurre sémantiquement relié, et donc la probabilité de le reconnaître à tort. Le traitement spécifique, en mettant l'accent sur les propriétés distinctives de chaque mot, pourrait réduire la quantité d'informations encodées à propos du mot critique non présenté. Cela expliquerait qu'il soit moins probable de reconnaître à tort le mot leurre en adoptant un encodage distinctif des mots de la liste³.

Suivant Mark J. HUFF, BODNER et FAWCETT (2015), l'hypothèse de l'appauvrissement du traitement relationnel peut être envisagée soit au niveau des *mots individuels*, soit au niveau de la *liste entière*. Dans le premier cas, cela signifie qu'après un traitement spécifique, l'association de chaque mot de la liste avec le leurre est affaiblie. Dans le second cas, cela veut dire que la cohérence thématique de la liste est diminuée.

1. HEGE et DODSON (2004)

2. HUNT et al. (2011) : "(...) encoding of differences within a context of similarity".

3. Mark J. HUFF et BODNER (2013) : "The item-specific group showed less encoded memory information for critical items (CIs) than the relational group".

2.4.3. L'heuristique de la distinctivité

L'*heuristique de la distinctivité* est une stratégie que les participants mettent en œuvre pour distinguer les mots "anciens" (qu'ils estiment réellement présentés) des mots "nouveaux" (qu'ils estiment non présentés). Cette stratégie consiste schématiquement à donner un *poids élevé* aux informations *contextuelles* dans cette décision. Un mot présenté lors du test de reconnaissance peut évoquer, non seulement une sensation de familiarité, mais aussi le rappel de détails *spécifiques* et *uniques* : par exemple, le contexte de la présentation, des pensées spécifiques évoquées lors de l'encodage, des images mentales, etc¹. Les participants qui mettent en œuvre l'heuristique de la distinctivité se fient moins à un sentiment de familiarité qu'aux détails *contextuels* liés à l'encodage initial des informations.

L'heuristique de la distinctivité est donc liée à l'idée d'un contrôle de la source (*source monitoring*)². Dans cette heuristique, un mot n'est rapporté comme « ancien » que s'il est associé au souvenir de détails spécifiques issus de l'encodage. La présence de ces détails sert de preuve que le mot faisait partie de la liste originale, tandis que leur absence indique qu'il n'en faisait probablement pas partie. Ainsi, l'utilisation de l'heuristique de la distinctivité peut être vue comme un processus de vérification qui admet deux issues possibles. Premièrement, si un mot suscite à la fois une sensation de familiarité et le rappel de détails uniques, il sera classé comme "ancien". Deuxièmement, si un mot ne rappelle pas de détails uniques, même s'il provoque une sensation de familiarité, il sera classé comme "nouveau"³.

L'efficacité de cette heuristique de distinctivité dépend fortement de la manière dont les informations ont été initialement encodées. En effet, bien que l'absence de souvenirs contextuels

1. LANGEVIN et al. (2009) explique qu'une mémoire des *faits* (dont le contenu est purement informationnel) est mise en opposition à une mémoire des *sources* sources, contenant par exemple la localisation dans l'espace des objets, des mots, les conditions expérimentales, la valeur émotionnelle, etc.

2. HEGE et DODSON (2004, p.20) : "(...) the distinctiveness heuristic is consistent with retrieval strategies that are involved in attributing items to a particular source". Mark J. HUFF et BODNER (2019, p.1494) : "[distinctiveness] heuristic refers to a testbased monitoring process wherein memory items are reported only when accompanied by the recollection of distinctive details from the encoding task".

3. Une esquisse de version plus élaborée de ce modèle pourrait inclure l'attribution d'un poids w compris entre 0 et 1 à la familiarité sémantique. Lors de la prise de décision, ce poids serait mis en balance avec un poids de $1 - w$ attribué aux informations contextuelles.

spécifiques¹ puisse aider à distinguer les mots réellement présentés des leurres lors de la tâche de reconnaissance, il semble nécessaire que les conditions expérimentales aient favorisé l'encodage de tels souvenirs contextuels pour que cette stratégie soit opérante.

2.4.4 Expériences visant à départager l'hypothèse de l'appauvrissement du traitement relationnel et l'hypothèse de l'heuristique de la distinctivité

De *nombreux* paramètres sont supposés permettre d'influencer le caractère relationnel ou distinctif du traitement des mots d'une liste DRM.

Par exemple, GUNTER et al. (2007) cherchent à augmenter le *caractère distinctif* de l'encodage des mots en demandant aux participants une tâche de résolution d'anagrammes. En effet, selon ces deux auteurs, la génération d'anagrammes encourage le traitement distinctif, et permet *in fine* aux participants de mieux se souvenir des mots de la liste. La première expérience menée par GUNTER et al. (2007) oppose un groupe de participants en condition "lecture simple" à un groupe en condition "résolution d'anagrammes". Les résultats sont conformes aux attentes des auteurs : le taux de reconnaissances correctes (HR*) est plus élevé dans le groupe anagramme que dans le groupe lecture simple (0,85 contre 0,79). Le taux de fausses reconnaissances (FR*) est plus faible dans le groupe anagramme par rapport au groupe lecture (0,44 contre 0,68). Finalement, cette expérience montre que la résolution d'anagrammes sur une partie des mots de la liste réduit le taux de faux souvenirs en augmentant simultanément le taux de reconnaissances correctes.

Les deux hypothèses précédentes, selon GUNTER et al. (2007) soulèvent deux explications alternatives : la résolution d'anagrammes pour certains items de la liste a-t-elle diminué l'encodage relationnel (2.4.2) ? Ou bien, la résolution d'anagrammes pour certains items permet-elle aux participants d'encoder de manière épisodique certaines caractéristiques des items de la liste, de telle sorte qu'ils adoptent ensuite un critère de décision plus strict (un seuil plus élevé) lors de la phase de reconnaissance (2.4.3) ?

GUNTER et al. (2007) proposent, dans leur deuxième expérience, une méthodologie astu-

1. LANGEVIN et al. (2009, p.717) : "Pour préciser les liens entre mémoire de source et processus de jugement, (. . .) plus les épisodes stockés en mémoire contiennent de caractéristiques distinctives, plus les processus de jugement opèrent de manière efficiente".

cieuse visant à intervenir sur la stratégie utilisée lors de la tâche de reconnaissance, sans pour autant influencer les informations encodées sur les items de la liste. Tout comme dans leur première expérience, les participants sont invités à générer des anagrammes pendant la phase d'étude. Cependant, lors de la phase de test, l'échantillon est scindé en deux groupes recevant des consignes différentes : le premier groupe est incité à fonder sa reconnaissance sur les caractéristiques distinctives encodées pendant la génération des anagrammes, alors que le second groupe est encouragé à baser sa reconnaissance sur le thème sémantique unissant les mots de la liste. L'hypothèse est qu'avec cette consigne, les participants, bien qu'ayant encodé distinctivement les différents mots de la liste, emploieront une stratégie relationnelle pour juger si les mots étaient présents dans la liste. Les informations encodées sont distinctives dans les deux groupes, mais la stratégie de reconnaissance est supposée différente dans les deux groupes.

L'importance accordée aux caractéristiques distinctives des mots de la liste sera moindre dans la décision de reconnaissance du leurre critique, au profit d'une pondération plus importante des caractéristiques relationnelles des mots de la liste¹.

En manipulant les consignes lors de la phase de test, les auteurs peuvent examiner si l'effet de réduction des fausses reconnaissances observé avec la génération d'anagrammes est principalement dû à une modification des processus d'encodage (en diminuant le traitement relationnel), ou à l'adoption d'une stratégie de reconnaissance basée sur la distinctivité. Si les résultats montrent que le groupe "consigne relationnelle" présente un taux de fausses reconnaissances (FR*) plus élevé que le groupe "consigne distinctive", malgré un encodage distinctif dans les deux cas, cela suggérerait que la stratégie de reconnaissance joue un rôle clé dans la réduction des faux souvenirs, indépendamment de la nature de l'encodage initial.

2.5. Tentatives de modélisations avec des espaces conceptuels

2.5.1. Réadapter un modèle existant avec des espaces conceptuels

Minyu CHANG et JOHNS (2023) proposent un modèle permettant d'expliquer cette différence du taux de fausses reconnaissances. Leur modèle s'appuie principalement sur trois hypothèses.

1. GUNTER et al. (2007, p.1087) : "Under meaning instructions, the distinctiveness heuristic should be "turned off" (. . .)"

La première hypothèse est que les *vecteurs* qui servent à représenter les mots *incorporent* leurs *propriétés*¹. En simplifiant, cela signifie que si l'on réduit correctement la dimensionnalité de ces vecteurs, on peut obtenir des dimensions *interprétables* qui correspondent aux propriétés sémantiques, orthographiques, phonologiques, morphologiques, etc.

Ainsi, deux mots qui sont sémantiquement *proches*, mais orthographiquement *différents*, sont représentés par des points *proches* dans certaines dimensions, mais *éloignés* dans d'autres. La deuxième hypothèse est que *mémoriser* un mot consiste à enregistrer ses propriétés dans la mémoire à court terme. Cette mémoire est représentée par une matrice ayant un nombre de cases limitées². Ainsi, dans ce cadre, mémoriser un mot consiste à placer le vecteur représentant ce mot dans cette matrice.

Enfin, la troisième hypothèse admet que, lorsqu'on demande à un participant : "le mot w_i faisait partie de la liste présentée?", le vecteur du mot w_i est comparé aux éléments stockés dans la matrice mémorielle. Autrement dit, pour déterminer si w_i faisait partie de la liste DRM, le participant *mesure la similarité* entre w_i et les traces dans la matrice mémorielle. Le résultat de cette mesure de similarité débouche sur une réponse grâce à un *seuil de décision*. Ce seuil permet de distinguer les réponses affirmatives ("oui, le mot w_i a été présenté") des négatives ("non, ce mot est nouveau"). Si la similarité du mot w_i et les traces dans la matrice mémorielle *dépasse* ce seuil, alors w_i est reconnu comme un mot de la liste. À l'inverse, si la similarité est inférieure à ce seuil, le mot w_i est jugé comme *nouveau*³. Même s'il y a un *faible degré de similarité* entre w_i et les traces dans la matrice mémorielle, si le seuil de décision est bas, le mot w_i sera tout de même jugé *ancien*. Inversement, même s'il y a un *fort degré de similarité* entre w_i et les traces dans la matrice mémorielle, si le seuil de décision est *suffisamment élevé*, le mot w_i sera jugé *nouveau*. Les sections (2.5.2) à (2.5.5) qui suivent reprennent le modèle de Minyu CHANG et JOHNS (2023) afin d'essayer de l'adapter au cadre des espaces conceptuels.

1. Minyu CHANG et JOHNS (2023) : "the current study used word vectors that were retrieved from the word2vec model; hence, the features are represented with continuous rather than categorical values".

2. REID *et al.* (2023) : "each study word is copied to a unique row in a memory matrix, M . Thus, memory is an $m \times d$ matrix, where m is the number of items studied and d is the dimensionality of the word vectors". Un modèle utilisant une telle matrice mémorielle est exposé dans la section (3.2).

3. Minyu CHANG et JOHNS (2023) : "Thus, if I is above C , then the probe will be recognized as "old," and if I is below C , the probe will be recognized as "new". REID *et al.* (2023) : "If the item was more familiar than a recognition threshold, the item was judged to be old; else it was judged as new".

2.5.2. L'indétermination comme élargissement d'une région dans un espace conceptuel ?

Comme évoqué, les domaines d'un espace conceptuel sont constitués de différentes dimensions généralement définies sur des intervalles de nombres réels. À s'en tenir à une définition géométrique du *point*, tout intervalle $[a; b] \subset \mathbb{R}$ en contient une *infinité*. De plus, il est *mathématiquement* possible de partitionner cet intervalle $[a; b]$ en autant de sous intervalles qu'on veut. Concrètement, cela signifie par exemple qu'on peut choisir un entier n arbitrairement grand puis qu'on peut exprimer la propriété ROUGE comme une union disjointe de n sous-gammes de rouge :

$$Rouge = Rouge_1 \cup \dots \cup Rouge_n$$

Dans la mesure où notre système cognitif fonctionne avec des ressources limitées (attention, mémoire de travail, vitesse de traitement, etc.), il est clair que l'idée d'un partitionnement infini est une totale idéalisation. Mémoriser des milliers de concepts distincts pour les couleurs, les formes, les sons, etc., serait non seulement très coûteux mais semble également assez inutile en pratique¹. Par conséquent, ce qui est considéré comme « points » dans l'espace conceptuel correspond en réalité à des régions suffisamment petites pour être traitées comme indivisibles². Autrement dit, toute représentation mentale d'un concept s'identifie toujours à une région de l'espace — région qui peut être très petite lorsque le concept est finement discriminé. Par ailleurs, il semble que plus la granularité d'un concept augmente, plus ses frontières deviennent difficiles à maintenir nettes : elles ont tendance à s'élargir et à se mêler aux régions conceptuelles voisines.

Charles Jon BRAINERD et REYNA (2005) ont introduit la notion de « gist » qui désigne la *signification globale* ou le *thème commun* unissant les mots d'une liste DRM. Selon eux, lors de la mémorisation des mots de la liste DRM, ce *gist* est stocké *séparément* des traces *littérales* qui concernent les détails de surface de chaque mot. Ils postulent que lors de la mémorisation d'une

1. Par exemple, de nombreux fruits (bananes, prunes, mangues, abricots, raisins, etc.) sont verts quand ils ne sont pas assez mûrs. Pour la plupart des usages visuels courants, une petite palette de catégories de « vert » suffit à distinguer un fruit mûr d'un fruit non-mûr. Cette idée semble généralisable à de nombreux contextes de communication.

2. OSTA VÉLEZ (2020, p.146) : “(. . .) assume that X and Y are small regions so that we can identify them with points in a conceptual space”.

liste de mots sémantiquement liés, les participants tendent à retenir le gist global, c'est-à-dire le *thème commun* de cette liste¹. Ces deux auteurs parlent de « traces gist », suggérant que le gist ne correspond pas à un mot en particulier, mais plutôt à un renforcement des *traits sémantiques communs* à tous les mots de la liste. Brainerd et Reyna proposent toutefois un passage suggérant que le *gist* d'une liste de mots est sémantiquement analogue à un mot unique dont la signification serait suffisamment générale pour englober tous les mots individuels de la liste DRM :

Un phénomène (. . .) significatif pour les fausses reconnaissances, est que les traces de cibles peuvent varier dans leur degré de spécificité par rapport à une cible. Supposons par exemple que les mots « Marguerite », « Collie », « Mistigri » et « Python » figurent sur dans une liste. Ces mots conduiraient probablement les sujets à accéder aux concepts « vache », « chien », « chat » et « serpent », qui sont des significations spécifiques à chaque mot. Cependant, les sujets pourraient également accéder à des concepts tels que « animal domestique » ou « animal de la jungle », qui sont moins spécifiques, ou même simplement « animal »²

Ce passage suggère que la propriété « être un animal » est *analytiquement* contenue dans « chat », « chien », etc., et qu'elle est obtenue par l'intersection des significations de ces mots. De même, la propriété « rouge » serait trouvée dans l'intersection des significations de « *fraise* », « *framboise* » et « *cerise* »³. Dans ces deux exemples, il y a une relation d'*inclusion* entre les mots de la liste et le mot représentant le *gist* de la liste. Ce *gist* pourrait être modélisé dans un espace conceptuel comme une *région* englobant les régions correspondant aux mots individuels de la liste DRM. Ces *intersections* et ces *relations d'inclusion* entre concepts semblent tout à fait représentables dans la théorie des espaces conceptuels, où la perte de spécificité consisterait

1. LANGEVIN et al. (2009, p.703)

2. Charles Jon BRAINERD et REYNA (2005) "An interesting by-product, which is significant in false memory, is that gist traces of targets may vary in their degree of specificity with respect to a target. For instance, suppose that the words Hereford, collie, tiger, and python appear on some study list. These words would likely cause subjects to access the concepts "cow," "dog," "cat," and "snake," which are meanings that are specific to each word. However, subjects might also access concepts such as "farm animal" and "jungle animal," which are less specific, or simply "animal" (. . .)".

3. LANGEVIN et al. (2009, p.702) donnent encore l'exemple de la propriété "jaune" contenue dans l'intersection des mots de la liste : "soleil, citron, canari, or, tournesol, jonquille, paille, œuf".

en un élargissement et une fusion des régions individuelles en une région *gist* globale.

Cependant, il n'est possible de *mesurer* la taille de l'intersection entre deux régions correspondant à deux concepts seulement si ces deux régions sont définies dans les mêmes dimensions. Bien que pour deux concepts définis sur les mêmes domaines sensoriels (e.g. la couleur), une telle mesure semble assez opérationnelle, pour des mots comme « dormir » et « lit », ou encore « chameau » et « désert », il paraît plus difficile d'identifier des dimensions communes interprétables.

2.5.3. L'interprétabilité des vecteurs


Pour distinguer le traitement relationnel (axé sur les propriétés communes) du traitement distinctif (centré sur les traits uniques), il est nécessaire de disposer d'un modèle de représentation sémantique permettant d'isoler ces caractéristiques. L'objectif consiste alors à construire des domaines $\delta_1, \dots, \delta_n$ qui soient à la fois indépendants (non corrélés) et interprétables, de sorte que le vecteur associé à un mot w_i puisse être exprimé comme une combinaison — ou une composition — de ces « atomes sémantiques ». Une approche simple et répandue illustre ce principe à travers des analogies linéaires :

$$w_{\text{actor}} - w_{\text{man}} + w_{\text{woman}} \approx w_{\text{actress}}.$$

On pourrait donc espérer qu'il existe, dans des modèles comme Word2Vec ou GloVe, une direction unique facilement isolable correspondant à la transformation « masculin → féminin » applicable à tous les noms qui possèdent un féminin. En pratique, une telle direction globale n'existe pas : les embeddings sont distribués et les informations sémantiques sont entremêlées sur de nombreuses dimensions, ce qui empêche d'obtenir systématiquement une seule direction simple pour « féminiser » un nom.

A notre connaissance, les vecteurs classiques (GloVe, Word2vec) ne sont pas décomposables en parties, on ne peut pas extraire à partir du vecteur d'un mot des *aspects* spécifiques de ce mot.

Il est possible d'utiliser des "sparse embeddings" pour favoriser l'interprétabilité (par opposition à ceux de GloVe, Word2vec, etc. qui sont qualifiés de "denses embeddings"). Les vecteurs sparses sont de très haute dimensionnalité mais ils contiennent principalement des zéros (les valeurs non nulles sont clairsemées). Le schéma ci-dessous compare les vecteurs sparses et denses. :



SPINE et SINr sont deux méthodes différentes pour construire des vecteurs sparses¹. Avant toute chose, il convient d'expliquer *pourquoi* les vecteurs sparses seraient plus en lien avec la théorie des espaces conceptuels que les vecteurs denses.

Selon PROUTEAU (2024), cofondateur de SINr, un modèle d'embeddings — c'est-à-dire un espace où les mots sont représentés par des vecteurs — doit décomposer chaque mot en *traits sémantiques* pour être à la fois interprétable et plausiblement cognitif. Il rappelle certains résultats expérimentaux qui montrent que lorsqu'un mot est utilisé « seule une petite partie de ses traits sémantiques » est activée pour les locuteurs². Or, dans les vecteurs denses, les traits sémantiques sont fortement enchevêtrés : chaque dimension reflète une combinaison de nombreuses caractéristiques et il devient, de ce fait, impossible (ou du moins très difficile en

1. SPINE signifie "SParse Interpretable Neural Embeddings" et SINr signifie "SParse Interpretable Node Representations".

2. PROUTEAU (2024, p.126) : "Murphy et al. (2012) already mentioned the idea that in order for word embeddings to be "cognitively plausible", or able to emulate the representation of words in the human mind, only a small set of features should be activated [...] The number of dimensions a human will be able to work with in working memory is bounded by two different kinds of psycholinguistic experiments. *Semantic features production* [...] and *semantic features retention* [...] experiments come to the conclusion that the bound is at around ten. However, most models have far more than ten dimensions activated per word representation. We consider that reaching ten dimensions activated per vector is a desirable horizon for vector-level interpretability. Therefore, we extend the set of criteria for interpretability by adding increased sparsity of each vector to reduce as much as possible the number of activated dimensions for the representation of a word.

pratique) d'activer un seul trait isolé. Ces chevauchements conduisent à l'activation simultanée d'une myriade d'attributs. À l'inverse, si l'on suppose que les composantes non nulles d'un vecteur sparse sont peu corrélées, seules les dimensions réellement pertinentes s'activent — produisant une représentation plus parcimonieuse et plus fidèle aux limites de la mémoire de travail humaine.

Ainsi, nous allons montrer qu'un vecteur sparse de SINr *s'approche* de la représentation d'une instance dans un espace conceptuel. Cependant, les "traits sémantiques" — c'est-à-dire les briques élémentaires qui composent le sens d'un mot — diffèrent beaucoup entre l'un et l'autre. Dans la théorie des espaces conceptuels, il s'agit de prédicats gradables sur une ou plusieurs dimensions, c'est-à-dire pouvant prendre plusieurs valeurs et niveaux d'intensité. En revanche, dans SINr, ces "traits sémantiques" correspondent plutôt à connexions avec d'autres mots. Cette différence s'explique par le procédé de construction des vecteurs sparses de SINr : ils sont dérivés d'un graphe de cooccurrence où chaque dimension correspond à un sous-graphe modulaire, visuellement interprétable comme une « communauté » de nœuds détectée par un algorithme de détection de communautés de mots¹. La construction des vecteurs dans SINr se comprend par une représentation sous forme de graphe dont les nœuds représentent les mots et dont les arêtes représentent les connexions sémantiques. Ainsi, une *communauté* est un groupe de nœuds qui sont densément connectés entre eux et qui ont peu de connexions avec les nœuds des autres groupes. Par exemple, le graphe suivant est constitué de deux communautés :




Schéma extrait de PROUTEAU, DUGUÉ et al. (2024)


Ce graphe simple composé de 8 nœuds et de 12 arêtes est divisé en deux groupes (rose et bleu). Cette partition du graphe en deux est la base pour associer à chaque nœud (mot) un

1. GUILLOT et al. (2023, p.108) : "SINr is a graph-based approach to word embeddings. From a cooccurrence matrix extracted on a corpus, SINr builds a weighted word cooccurrence graph—words are represented by nodes and the number of cooccurrences by edges. A community detection algorithm, the *Louvain* method (Blondel et al., 2008), then uncovers dense groups of co-occurring words in the graph.

vecteur. Puisqu'il y a deux communautés, qu'on notera C_1 et C_2 , chaque noeud u sera associé à un vecteur $\vec{u}$ en deux dimensions. Chaque dimension de ce vecteur représente la "force de connexion" envers l'une de ces deux communautés. Le calcul de la valeur d'un vecteur sur une dimension est déterminé par une simple fraction¹ :

$$\text{valeur de } \vec{u} \text{ sur la dimension } i = \frac{\text{nombre de voisins de } w \text{ qui appartiennent à la communauté } C_i}{\text{nombre total de voisins du nœud } w}$$

Par exemple, le vecteur du noeud 3 est est $[0.75, 0.25]$. Cela signifie que 75% des liens du nœud 3 sont vers d'autres nœuds de la communauté C_1 et 25% vers la communauté C_2 .



Donnons maintenant des exemples concrets pour montrer que cela capture certaines intuitions de la théorie des espaces conceptuels et offre des pistes prometteuses pour modéliser l'intrusion de faux souvenirs.

En premier lieu, la *polysémie* est traitée de manière similaire. La théorie des espaces conceptuels *sépare radicalement* les différentes significations d'un même mot. De même, dans l'espace de SINr, différentes significations ont tendance à apparaître de manière séparées les unes des autres. C'est le cas du mot anglais "mint" dont les trois dimensions les plus fortes correspondent à trois sens distincts et indépendants². GUILLOT et al. (2023) proposent aussi en exemple le mot "oxygen" dont les différentes dimensions semblent recouvrir des champs thématiques différents (chimie, médecine générale/diagnostics, et médecine cardiovasculaire/sanguine).

Ainsi chaque communauté semble pouvoir être interprétée comme un champs thématique. Toutefois, pour une modélisation plus fidèle à la théorie des espaces conceptuels il faudrait

1. PROUTEAU, DUGUÉ et al. (2024, p.12). Voir aussi PROUTEAU, CONNES et al. (2021)

2. La première dimension est représentée par les mots "tbsp, oregano, diced" (cuillère à soupe, origan, coupé en dés). C'est le sens de "mint" comme "menthe" en connexion à d'autres herbes aromatiques.

Une autre dimension est représentée par "Gibson, gigged, charvel" (des marques de guitares et des termes musicaux). Cela correspond à l'expression "mint condition" (état neuf/impeccable), très utilisée dans les annonces de vente des guitares.

La troisième dimension est représentée par "minted, minting, hoards" (frappé, frapper de la monnaie, trésors). Cela correspond au sens de "to mint coins" (frapper de la monnaie) ou "The Royal Mint".

sans doute capturer le type de relation entre deux mots (relation de synonymie, d'antonymie, d'inclusion, de prédicat et d'argument, de similitude perceptive, etc.).

Nous allons donner une heuristique de ce que serait un espace d'embedding parfaitement aligné avec la théorie des espaces conceptuels. Supposons que les deux mots « canari » et « citron » n'aient aucun *aucune autre propriété commune* que la couleur jaune. Dans un espace d'embedding analogue à la théorie des espaces conceptuels, il est possible d'isoler la propriété du jaune à partir des vecteurs correspondant à ces deux mots. Notons $A = (a_1, \dots, a_n)$ et $B = (b_1, \dots, b_n)$ deux vecteurs du mot « canari » et du mot « citron » respectivement, dans un embedding space de dimension n . Pour isoler la propriété "jaune", il faut d'abord quantifier la différence entre ces deux vecteurs pour chaque coordonnée. Définissons la distance entre A et B sur pour leur coordonnée i .

$$\mathcal{D}_i := \mathcal{D}(a_i, b_i), \quad i = 1, \dots, n,$$

Maintenant, l'idée heuristique est d'extraire les k coordonnées sur lesquelles A et B sont les plus similaires. Pour ce faire, il est possible de trier toutes les distances par coordonnée, de la plus petite à la plus grande. Autrement dit, on trouve un ordre d'indices $(i_1, i_2, \dots, i_n)$ tel que :

$$\mathcal{D}(a_{i_1}, b_{i_1}) \leq \mathcal{D}(a_{i_2}, b_{i_2}) \leq \dots \leq \mathcal{D}(a_{i_n}, b_{i_n}).$$

Pour trouver les k dimensions les plus similaires, il suffit alors de retenir les k premiers indices de cette liste : $\{i_1, i_2, \dots, i_k\}$. Le sous-espace de dimension k correspondant, où A et B sont les plus proches, est alors défini par cet ensemble de k coordonnées, c'est-à-dire les paires $\{(a_i, b_i)\}_{i \in \{i_1, \dots, i_k\}}$. Intuitivement, les deux mots « canari » et « citron » n'ont pas beaucoup d'autres propriétés communes que la couleur jaune. On peut ainsi espérer que le sous-ensemble des dimensions sur lesquelles la proximité est la plus forte encode cette couleur. En pratique, il est possible que le choix de la bonne valeur de k soit difficile.

2.5.4. Pondération différentielle

La pondération des dimensions permet d'attribuer une importance variable aux différentes dimensions selon leur pertinence dans un contexte donné. Cette pondération reflète ce qui est jugé pertinent dans un contexte donné. La distance euclidienne pondérée entre deux vecteurs A

et B est définie comme suit :

$$\mathcal{D}_{E.P}(A, B) = \sqrt{\sum_{i=1}^n w_i \cdot |a_i - b_i|^2}$$

où w_i représente le poids attribué à la i -ème dimension. Plus w_i est proche de 1, plus la dimension concernée est importante ; inversement, plus w_i est proche de 0, moins la dimension est importante¹. Pour éviter que les poids attribués à chaque dimension varient librement et entraînent des disproportions s'ils sont tous proches de 0, ou de 1, on peut normaliser les poids de sorte que leur somme soit égale à 1. Bien qu'il soit possible d'attribuer la même importance à toutes les dimensions, un ajustement d'un poids w_i nécessite une modification compensatoire sur les poids associés aux autres dimensions, de sorte que la somme totale des poids reste égale à un.² Ainsi les poids modulent la distance en fonction de la pertinence de chaque dimension³. Le modèle admet que les dimensions sont pondérées différemment dans les deux types de traitement relationnel ou spécifique. On caractérise plus finement cette différence dans les deux paragraphes suivants.

D'un côté, en condition de traitement relationnel, il pourrait y avoir une *corrélation positive significative* entre la proximité des mots sur une dimension et le poids attribué à cette dimension. En effet, dans le traitement relationnel, l'accent est mis sur les similarités sémantiques entre les mots. Cela suggère que les dimensions sur lesquelles les vecteurs des mots sont les plus proches reçoivent des poids plus élevés.

De l'autre côté en revanche, le traitement « item-spécifique » vise à concentrer l'attention des participants sur les caractéristiques *distinctives* de chaque mot. Bien que les mots dans une liste DRM soient *sémantiquement proches*, ce type de traitement s'attache à faire ressortir ce

1. GÄRDENFORS (2000, sec. 1.6.4) BECHBERGER (2023, p.55); FIORINI et al. (2014, p.137) : « (...) parts that are less relevant receive smaller weights and parts that are more relevant receive larger weights ».

2. Distinguons un continuum allant d'une distribution des poids *diffuse* à une distribution *concentrée* :

- Si les poids sont répartis équitablement sur la plupart des dimensions, cela signifie qu'aucune dimension ne se démarque particulièrement des autres, l'attention prend en compte les dimensions de manière globale, voir MAQUESTIAUX (2017, p.172).
- Si les poids sont concentrés sur un nombre restreint de dimensions, cela signifie que l'attention est intensément dirigée vers quelques dimensions jugées cruciales, tandis que les autres sont au second plan, illustrant une situation sélective et concentrée sur certains aspects pertinents du contexte.

3. BECHBERGER (2023, p.164), OSTA-VÉLEZ et GÄRDENFORS (2020, p.12).

qui *distingue* les mots. Par conséquent, il pourrait y avoir une corrélation positive moins forte entre la proximité sur une dimension donnée et le poids affecté à cette dimension en condition de traitement distinctif.

2.5.5. Comment la pondération des dimensions affecte-t-elle les jugements de similarité ?

Pour illustrer l'impact de la pondération des dimensions sur les jugements de similarité, considérons *deux pommes équivalentes* qui sont comparées soit par un enfant sur un étal de marché, soit par un botaniste dans un contexte d'analyse agronomique. Supposons que le concept de « pomme » soit représenté dans plusieurs domaines tels que la couleur, la forme, le goût, la texture, les qualités nutritionnelles et les pépins. À chacune de ces dimensions peut être attribuée une pondération variable reflétant son importance relative dans le contexte donné.

Ainsi, un consommateur et un botaniste peuvent considérer les *mêmes* dimensions pour représenter le concept de pomme tout en pondérant *différemment* ces dimensions.¹ Par exemple, le botaniste pourrait accorder plus d'importance aux pépins, tandis que le consommateur pourrait se focaliser davantage sur l'apparence extérieure de la pomme. Si deux pommes possèdent des pépins très différents, mais présentent des similitudes marquées en termes de texture, de couleur, d'aspect de la chair et de la peau, elles seront jugées *dissimilaires* par le botaniste en raison de la forte pondération qu'il accorde aux pépins, mais *similaires* par le consommateur qui accorde plus d'importance à l'apparence extérieure.² Le paragraphe suivant propose de formaliser l'impact de la pondération des dimensions sur les jugements de similarité.

Pour un concept générique C , on note $\mathcal{R}_\delta^C \subset \mathcal{S}_\delta$ la région associée à C sur la modalité δ . Le poids des ressources attentionnelles allouées à la modalité δ_i pour un objet $\mathbf{x}$ est noté $w_{\delta_i}(\mathbf{x})$. On admet que si $w_{\delta_i}(\mathbf{x}) > 0$, l'objet $\mathbf{x}$ est consciemment représenté par le sujet sur la modalité δ_i , et lorsque $w_{\delta_i}(\mathbf{x}) = 0$, le statut de l'objet $\mathbf{x}$ sur la modalité δ_i ne fait pas du tout partie de la représentation consciente du sujet.

La région définissant le concept **POMME** sur une modalité spécifique δ s'écrit $\mathcal{R}_\delta^P$. Le concept **POMME**, noté $\mathcal{R}^P$, est donc défini comme le produit cartésien des régions sur chaque modalité (c.-à-d. $\mathcal{R}^P = \prod_{\delta \in \Delta} \mathcal{R}_\delta^P$). Par suite, une pomme singulière est représentée par un point défini sur

1. FIORINI et al. (2014)

2. FIORINI et al. (2014) : « Structural similarity judgments are influenced by context : two apples can look very similar to a child in a supermarket, but very different to a botanist ».

toutes les régions définissant le concept de pomme. Formellement, il s'agit d'un point $\mathbf{x} \in \mathcal{R}^P$ qui se décompose en composantes $\mathbf{x} = (\mathbf{x}_\delta)_{\delta \in \Delta}$ avec $\mathbf{x}_\delta \in \mathcal{R}_\delta^P$.

Un tel point $\mathbf{x}$ est défini dans les deux domaines de la forme et de la couleur, notés $\mathcal{S}_{\delta_i}$ et $\mathcal{S}_{\delta_j}$ respectivement. On peut écrire que le sujet prête plus d'attention à la couleur de la pomme $\mathbf{x}$ qu'à sa forme en écrivant $w_{\delta_i}(\mathbf{x}) > w_{\delta_j}(\mathbf{x})$. Reprenons l'exemple précédent comparant deux jugements de similarité entre deux pommes équivalentes.

Soient $\mathbf{x}$ et $\mathbf{y}$ deux pommes singulières perçues simultanément, qui sont donc deux points situés d'une part à l'intérieur de la région associée au concept de pomme sur le domaine des couleurs : $\mathbf{x}, \mathbf{y} \in \mathcal{R}_{\delta_i}^P$ et d'autre part à l'intérieur de la région associée à ce même concept sur le domaine de la forme : $\mathbf{x}, \mathbf{y} \in \mathcal{R}_{\delta_j}^P$.

Notons $\mathcal{D}_{E.P}(\mathbf{x}, \mathbf{y})$ la distance euclidienne pondérée entre $\mathbf{x}$ et $\mathbf{y}$, définie dans la section précédente. Plus cette distance est grande, plus les deux pommes seront perçues dissimilaires ; plus cette distance est petite, plus elles seront perçues similaires. Supposons que $\mathbf{x}$ est très similaire à $\mathbf{y}$ sur la modalité δ_i , mais qu'elle est très différente de $\mathbf{y}$ sur la modalité δ_j . Admettons que si le sujet porte une attention significative à δ_i pour la pomme $\mathbf{x}$, il en sera de même pour l'autre pomme $\mathbf{y}$, qui sera considérée assez fortement sur ce même domaine. Cette hypothèse sert à définir un seul poids sur le domaine δ_i , noté $w_{\delta_i}(\mathbf{x}, \mathbf{y})$. Cette corrélation positive des poids ne fonctionne que pour les domaines similaires, d'où l'on admet qu'il convient de séparer $w_{\delta_j}(\mathbf{x})$ de $w_{\delta_j}(\mathbf{y})$ car une forte activation pour l'un n'est pas corrélée à celle de l'autre¹. Ces préalables étant posés, on peut montrer que la variation des deux poids associés à δ_i et δ_j

1. L'hypothèse que l'attention accordée à une modalité spécifique δ_i pour un élément $\mathbf{x}$, représentée par le poids $w_{\delta_i}(\mathbf{x})$, influence l'attention accordée à ce même domaine pour tous les autres éléments représentés en même temps est pertinente dans des situations où les éléments partagent une forte similarité sur cette modalité (i.e. sont proches dans $\mathcal{S}_{\delta_i}$). Cependant, si deux éléments $\mathbf{x}$ et $\mathbf{y}$ *diffèrent significativement* sur la modalité δ_j (i.e. sont éloignés dans $\mathcal{S}_{\delta_j}$), on peut distinguer les poids attribués à ces modalités pour chaque élément, soit $w_{\delta_j}(\mathbf{x})$ de $w_{\delta_j}(\mathbf{y})$. Cette hypothèse paraît essentiellement utile pour des contextes dans lesquels les éléments partagent une proximité forte sur un domaine. Par exemple, imaginez que vous regardiez dans un panier contenant des framboises, des tomates et des cerises. Si vous portez votre attention sur la couleur rouge pour les framboises, c'est susceptible d'influencer votre attention sur cette même couleur pour les tomates et les cerises. Un autre facteur à considérer est la dynamique temporelle, où le poids accordé à un domaine pour un élément peut *pré-activer* ce domaine pour les éléments qui seront perçus ultérieurement, il paraît plausible qu'une telle préactivation se produise avec l'écoute / la lecture des mots d'une liste DRM.

impacte directement le jugement de similarité entre $\mathbf{x}$ et $\mathbf{y}$ comme suit :

- Plus $w_{\delta_i}(\mathbf{x}, \mathbf{y})$ est grand par rapport à $w_{\delta_j}(\mathbf{x})$ et/ou $w_{\delta_j}(\mathbf{y})$, plus l'attention est portée sur δ_i , qui est le domaine de similarité de $\mathbf{x}$ et $\mathbf{y}$ d'où $\mathcal{D}_{E.P}(\mathbf{x}, \mathbf{y})$ sera petit et $\mathbf{x}$ et $\mathbf{y}$ seront jugés similaires.
- Inversement, si $w_{\delta_i}(\mathbf{x}, \mathbf{y})$ est petit par rapport à $w_{\delta_j}(\mathbf{x})$ et/ou $w_{\delta_j}(\mathbf{y})$, cela signifie que l'attention est portée sur δ_j , qui est le domaine de dissimilarité entre $\mathbf{x}$ et $\mathbf{y}$, d'où $\mathcal{D}_{E.P}(\mathbf{x}, \mathbf{y})$ sera grand, et $\mathbf{x}$ et $\mathbf{y}$ seront jugés dissimilaires.

Le traitement spécifique vise à concentrer l'attention des participants sur les caractéristiques *distinctives* de chaque mot (2.4). Bien que, dans une liste DRM, les mots soient sémantiquement proches, le traitement distinctif tente de mettre le projecteur sur les différences plutôt que les similarités entre les mots. Ainsi, il y aurait une corrélation positive moins *forte* entre la proximité sur une dimension donnée et le poids affecté à cette dimension en condition de traitement distinctif. À l'inverse, dans le traitement relationnel, puisque l'accent est mis sur les similarités sémantiques entre les mots, les dimensions sur lesquelles les vecteurs de mots sont les plus proches reçoivent des poids plus élevés. Cela signifie que la similarité entre les traces mémorielles et le mot leurre critique est potentiellement augmentée, car les dimensions les plus représentatives des liens sémantiques communs sont accentuées. Ainsi, dans un traitement relationnel, il est supposé y avoir une corrélation positive significative entre la proximité sur une dimension et le poids affecté à cette dimension. Il est donc possible d'assigner des poids plus élevés aux dimensions où les mots ont des valeurs qui minimisent les distances et/ou moins de poids aux dimensions où les mots ont des valeurs distantes.

2.5.6. Prédire la réponse lors de l'épreuve de reconnaissance avec un seuil

Les sections (2.5.2) à (2.5.5) visent à représenter l'*appauvrissement du traitement relationnel* (2.4.2). Le dernier paramètre qu'il convient de prendre en compte est *le seuil de décision* (2.5.1) qui vise plutôt à représenter l'*heuristique de la distinctivité* (2.4.3). L'heuristique de la distinctivité repose sur le constat expérimental suivant. Dans une expérience DRM, on peut donner des instructions aux participants pour *conditionner* la réponse « oui, le mot était dans la liste ». D'un côté, on peut demander aux participants de répondre « oui, le mot était dans la liste » *seulement* s'ils disposent d'informations **distinctives et contextuelles** confirmant cette

présence. Si cette instruction conduit à une diminution du taux de FR* par rapport à ceux qui n'ont pas reçu cette instruction, cela indique l'efficacité de l'heuristique. Inversement, on peut demander aux participants de répondre « oui », en se basant seulement sur **un simple sentiment de familiarité** pour intervenir sur le taux de FR*. Si cela entraîne une augmentation du taux de FR* par rapport aux participants sans cette instruction, cela suggère un abaissement d'un seuil de distinctivité qui conditionne la réponse.

Bien que ces phénomènes soient explicables par une modification de la pondération des dimensions, une autre explication passe par un seuil de décision. L'intégration dans le modèle se fait de la même manière que dans (2.5.1) : une fois la similarité entre le mot testé et les traces mémorielles calculée, celle-ci est comparée au seuil de décision pour déterminer si le mot est reconnu comme faisant partie de la liste ou non. Un seuil bas indique une forte propension à reconnaître un mot comme étant dans la liste s'il est similaire aux traces mémorielles, tandis qu'un seuil élevé indique une prudence dans la reconnaissance. Si un mot a une faible similarité avec les traces mémorielles, il sera jugé *ancien* si le seuil est suffisamment *bas*, et comme *nouveau* si le seuil est suffisamment *élevé*. Un seuil faible augmente ainsi le taux de FR*, tandis qu'un seuil élevé réduit ce taux. En effet, si le seuil est élevé, il est nécessaire qu'il y ait une forte similarité pour qu'un mot soit reconnu comme ancien, ce qui réduit le taux de FR*.

La pire configuration, qui maximise le taux de FR*, est donc celle où il y a un traitement relationnel combiné à un seuil bas (où la personne pourrait même faussement reconnaître *tous* les mots faiblement reliés à ceux de la liste). Un traitement spécifique couplé avec un seuil élevé est, à l'inverse, la configuration la plus susceptible de minimiser le taux de FR* car la réponse positive ne concerne que les mots très similaires aux traces mémorielles les plus distinctives.

2.6. Limites

Il n'est pas sûr que le seuil de décision soit un paramètre pouvant être **isolé** et pouvant varier indépendamment du type de traitement et des pondérations des dimensions.

L'explication de la diminution du taux de fausses reconnaissances par *une* variable dont les deux pôles sont le traitement distinctif et le traitement relationnel est peut-être *trop unifiante*. En effet, lorsqu'un article montre qu'une présentation auditive engendre plus de fausses reconnaissances qu'une présentation visuelle (HUNT et al. (2011) ; LANGEVIN et al. (2009)), ce phénomène

est directement expliqué par la *distinctivité* supérieure de la modalité visuelle. Lorsqu'on modifie un paramètre particulier et qu'il en découle une diminution du taux de FR*, on déclare peut-être trop vite que ce paramètre influe sur la *distinctivité* du traitement manquant par là, peut-être, la *diversité des voies* pouvant conduire à ce même effet.

Chapitre 3

Interférences et facilitations

3.1. Interférences et facilitations chez les bilingues

Le traitement du langage chez les individus bilingues soulève une question fondamentale, formulée notamment par VAN HEUVEN et al. (1998) : les bilingues disposent-ils d'un mécanisme d'*accès sélectif*, leur permettant de passer d'une langue à l'autre en isolant complètement l'influence de leurs autres langues ? Ou, au contraire, les lexiques des différentes langues qu'ils maîtrisent sont-ils intrinsèquement *entremêlés* et non sélectifs ? Les deux paragraphes suivants présentent les réponses opposées apportées à cette question.

D'une part, l'hypothèse de l'*accès sélectif* postule qu'il est possible de basculer d'une langue à une autre en effaçant complètement l'influence de toutes les autres langues. Selon cette théorie, un mécanisme d'aiguillage cognitif dirigerait les informations perceptives (visuelles, auditives) vers le lexique de la langue la plus appropriée au *contexte* et à la *tâche en cours*. Par exemple, si un bilingue anglais-français est engagé dans une conversation en anglais, ce mécanisme orienterait tous les mots entendus exclusivement vers son lexique anglais. L'accès aux lexiques des autres langues, jugées non pertinentes, serait alors temporairement *bloqué*. Ainsi, la recherche lexicale serait *confinée* à une seule langue à la fois : l'aiguillage dirige le stimulus vers le lexique de la langue cible, et la recherche s'opère exclusivement au sein de celui-ci.¹

D'autre part, VAN HEUVEN et al. (1998) défendent une proposition opposée, qu'ils nomment l'hypothèse du *lexique intégré*. Selon cette dernière, les langues connues par un individu sont entremêlées et indissociables. Dans ce cadre, un même stimulus peut activer simultanément des mots de langues différentes. Si plusieurs candidats lexicaux sont activés en parallèle, quels facteurs déterminent la sélection du mot final ? Nous nous focaliserons ici sur un critère prépondérant : *la ressemblance phonétique ou orthographique avec le stimulus*.

1. VAN HEUVEN et al. (1998) : « The bilingual participants thus seemed to be capable of operating in an entirely language-specific manner without any influence from their knowledge of the other language ».

Ce critère peut être illustré par un exemple concret. Imaginons un anglophone, ayant des notions de français, en visite à Paris. En marchant dans la rue, il entend quelqu'un prononcer le mot « pain ». Le mot français « pain » ressemble phonétiquement au mot anglais « pane » (vitre). L'hypothèse de la similarité prédit que les deux mots — « pain » en français et « pane » en anglais — seront activés en parallèle, car ils correspondent tous deux au stimulus auditif perçu. Même si le contexte géographique (Paris) suggère fortement que le mot français est le plus probable, le mot anglais « pane » sera tout de même activé dans l'esprit du bilingue en raison de sa proximité phonétique. Ce critère postule donc que la recherche lexicale est d'abord guidée par la similarité perceptive, avant même l'intervention du contexte.

Un autre exemple, centré sur l'orthographe, concerne les « faux amis ». Prenons un locuteur bilingue espagnol-français, dont la langue maternelle est l'espagnol, confronté au mot français « embarrassée ». La forte similarité orthographique avec le mot espagnol « embarazada » (qui signifie « enceinte ») entraînera probablement une activation simultanée des deux mots. Bien que ces termes se ressemblent, leurs significations très différentes peuvent provoquer une confusion sémantique, illustrant un phénomène d'*interférence*.

Pour tester l'hypothèse du lexique intégré, VAN HEUVEN et al. (1998) ont mené une expérience comparant *deux* groupes de participants : un groupe de locuteurs monolingues *anglais* et un groupe de bilingues *néerlandais-anglais*.¹ Le protocole expérimental consistait en une tâche de reconnaissance visuelle de mots utilisant une technique de *démasquage progressif* : un mot initialement masqué était révélé graduellement, et les participants devaient l'identifier le plus rapidement possible. La sélection des mots-stimuli était cruciale : les auteurs ont choisi des mots anglais possédant de nombreux « voisins orthographiques » en néerlandais (c'est-à-dire des mots néerlandais à l'orthographe très similaire). L'objectif était de placer les bilingues dans une situation d'« interférence inter-langues lors de la reconnaissance du mot cible »² L'hypothèse sous-jacente est celle d'une co-activation non-sélective des lexiques : la reconnaissance du mot anglais cible nécessiterait d'abord d'inhiber les candidats lexicaux néerlandais également activés.³

1. VAN HEUVEN et al. (1998, p.471) : « The English participants were all monolingual native speakers of English (...) The Dutch participants were all native speakers of Dutch ».

2. *Ibid.* (1998, p. 460) : « Cross-language interference on target word recognition (...) ».

3. Comme le résume PARRA (2013, p.14) : « (...) bilinguals automatically activate not only words in the other

Concrètement, cette hypothèse prédit que le temps de réaction des bilingues pour reconnaître ces mots anglais spécifiques sera légèrement plus *long* que celui des monolingues. Les résultats de l'expérience ont confirmé cette prédiction : les bilingues néerlandais-anglais mettaient effectivement plus de temps à identifier les mots anglais ayant de nombreux voisins orthographiques en néerlandais. Pour les auteurs, cet allongement du temps de réponse suggère que les mots voisins de l'autre langue ont bien été *activés* en parallèle, créant une compétition lexicale que le monolingue n'éprouve pas.

Toutefois, d'autres recherches en psychologie cognitive ont mis en lumière un phénomène complémentaire à l'interférence : la *facilitation*. L'interférence observée par VAN HEUVEN et al. (1998) survient lorsque des mots orthographiquement similaires ont des *significations différentes*. La situation s'inverse lorsque les significations sont identiques ou proches.

Pour comprendre la facilitation, il est essentiel d'introduire la notion de *cognats* (ou mots apparentés). Il s'agit de mots qui, dans deux langues différentes, partagent une similarité orthographique et/ou phonologique ainsi qu'une signification très proche. Par exemple, « apple » en anglais et « appel » en néerlandais sont des cognats qui désignent tous deux le fruit. On postule que lorsque le stimulus est un cognat, l'activation parallèle des deux représentations lexicales ne crée pas de compétition mais un *renforcement mutuel*, ce qui *facilite* le traitement linguistique.¹

L'activation d'un mot dans une langue A peut donc entraîner l'activation de mots similaires dans la langue B. Cette activation translinguistique ne provoque une interférence que si les significations divergent. En revanche, dans le cas de langues étroitement liées comme l'espagnol et le catalan, où les cognats sont nombreux (ex. : « gato »/« gat » pour « chat »), la facilitation est fréquente. Des expériences menées par COSTA et al. (2000) ou DIJKSTRA et al. (2010) ont montré que les bilingues traitent plus rapidement un mot s'il s'agit d'un cognat. Par exemple, dans une tâche de décision lexicale, « les participants bilingues étaient *plus rapides* pour décider si une chaîne de lettres était un mot ou un non-mot lorsque ce mot était un *cognat* dans leur

language similar to it in orthography, but also the translation equivalent of that word when that word is presented in L2. ».

1. Certains cognats, dits partiels, n'ont pas exactement la même signification, comme « fabric » (tissu) en anglais, « fabbrica » (usine) en italien et « fabrique » (usine) en français. Un autre exemple est « bench » (banc) en anglais et « bank » (banc) en néerlandais, analysé dans TREFFERS-DALLER (2019)

autre langue »¹. Cette accélération est attribuée à l'*activation simultanée* et convergente des représentations dans les deux langues. Ces recherches démontrent donc que, loin de n'être qu'une source d'interférence, la co-activation des langues peut aussi accélérer la reconnaissance de mots.

La section suivante propose un modèle formel qui vise à rendre compte de ces dynamiques d'interférence et de facilitation entre associations linguistiques.

3.2. Un modèle de l'interférence associative

Supposons que des participants apprennent deux associations entre deux mots $A \rightarrow B$ et $A' \rightarrow B'$. L'association fonctionne bien si chaque participant récupère les mots B et B' en ayant pour indices A et A' , respectivement.

KAHANA (2012) propose un modèle de mémoire associative dans lequel chaque mot est représenté par un vecteur d'activation (colonne), et où les associations sont encodées par une matrice formée par des produits externes. La section suivante montre comment encoder des vecteurs et leurs associations dans une matrice W telle que $WA = B$ et $WA' = B'$. La section présente ensuite les interférences prédites lorsque les indices A et A' se ressemblent. Le modèle formalise l'idée que, si les deux mots-indices A et A' sont similaires, il y a un risque accru d'associer le mot B' (au lieu de B) à partir du premier mot-indice et d'associer le mot B (au lieu de B') à partir du second.

Dans ce qui suit, nous utiliserons « $\cdot$ » pour le produit scalaire² et pas de symbole pour le produit matriciel (en notant, par exemple " WA ").

3.2.1 La récupération indicée

L'idée centrale est d'encoder l'association entre un indice A et une cible B dans une matrice notée W . Chaque mot est un vecteur colonne. Prenons l'exemple de deux mots représentés par

1. D'après DIJKSTRA et al. (2010, introduction) : « "For instance, the bilingual participants were found to respond faster to cognates like type, which has the same meaning and spelling (but not pronunciation) in Dutch and English than to interlingual homographs like stage, which is only spelled the same (but in Dutch is pronounced differently and means 'internship'); both types of items were faster than control words that were completely different across languages". ».

2. Pour des vecteurs colonnes $X, Y \in \mathbb{R}^n$, on note $X \cdot Y := X^T Y = \sum_{i=1}^n x_i y_i$.

deux vecteurs colonnes $A, B \in \mathbb{R}^n$:

$$A = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix}, \quad B = \begin{pmatrix} b_1 \\ \vdots \\ b_n \end{pmatrix},$$

où A est unitaire, c'est-à-dire $\sum_{i=1}^n a_i^2 = 1$ ¹. On note $A^\top$ la transposée de A .

On encode l'association $A \rightarrow B$ par la matrice

$$W_1 := B A^\top = \begin{bmatrix} b_1 a_1 & \cdots & b_1 a_n \\ \vdots & \ddots & \vdots \\ b_n a_1 & \cdots & b_n a_n \end{bmatrix}.$$

L'élément (i, j) de W_1 vaut $b_i a_j$ et représente le poids qui propage la j -ième composante de l'indice A vers la i -ième composante de la cible B .

La récupération s'obtient en appliquant W_1 à A :

$$W_1 A = (B A^\top) A = B (A^\top A) = B (A \cdot A) = B,$$

puisque A est unitaire. Ainsi, W_1 « pointe » A vers B .

3.2.2 L'interférence associative

Dans de nombreuses représentations cognitives, les vecteurs d'indices peuvent être *parcimonieux* (sparse) : de nombreuses composantes sont nulles et seules quelques-unes sont actives². En effet, si $a_i = 0$, alors les éléments de la i -ième colonne de W_1 sont multipliés par zéro et ne contribuent pas à $W_1 A$. Si ces $a_i = 0$ sont interprétés comme des "espaces libres" pour encoder d'autres associations dans la matrice W_1 , cela signifie que plus il y a de $a_i = 0$, plus il est possible d'utiliser cette même matrice pour produire d'autres associations. Ainsi les zéros peuvent servir à stocker d'autres associations sans perturber $A \rightarrow B$ seulement si elles sont stockées sur les valeurs de i sur lesquelles $a_i = 0$. Pour illustrer cela, considérons une seconde

1. De $\sum_{i=1}^n a_i^2 = 1$, on déduit $|a_i| \leq 1$ pour tout i . En effet, si $|a_j| > 1$ pour un certain j , alors $\sum_{i=1}^n a_i^2 \geq a_j^2 > 1$, ce qui contredit l'unité de A .

2. Cette hypothèse n'est pas imposée par le modèle linéaire, mais elle est fréquente dans les modèles de mémoire car permet d'augmenter la capacité en limitant les recouvrements.

association $A' \rightarrow B'$, avec $A', B' \in \mathbb{R}^n$ et A' unitaire. L'association de A' vers B' est encodée dans une nouvelle matrice W_2 construite de la même manière que W_1 :

$$W_2 := B' A'^T = \begin{bmatrix} b'_1 a'_1 & \cdots & b'_1 a'_n \\ \vdots & \ddots & \vdots \\ b'_n a'_1 & \cdots & b'_n a'_n \end{bmatrix}.$$

Pour stocker les deux associations dans une même matrice, il suffit d'additionner W_1 et W_2 :

$$W := W_1 + W_2 = BA^T + B'A'^T = \begin{bmatrix} a_1 b_1 + a'_1 b'_1 & \cdots & a_n b_1 + a'_n b'_1 \\ \vdots & \ddots & \vdots \\ a_1 b_n + a'_1 b'_n & \cdots & a_n b_n + a'_n b'_n \end{bmatrix}$$

on obtient, pour la récupération depuis A ,

$$WA = (BA^T + B'A'^T)A = B(A \cdot A) + B'(A' \cdot A) = B + (A' \cdot A) B'.$$

De même, depuis A' ,

$$WA' = B' + (A \cdot A') B.$$

Autrement dit, lorsque A et A' se ressemblent (grand produit scalaire), la réponse récupérée est une combinaison linéaire de la cible et d'une *interférence* proportionnelle à leur similarité ($A \cdot A'$). Si A et A' sont orthogonaux ($A \cdot A' = 0$), les récupérations sont parfaites et indépendantes.

Donnons un exemple concret en déterminant deux indices A et A' qui correspondent à deux vecteurs unitaires ayant 7 composantes et un chevauchement sur l'une d'elles :

$$A = \begin{pmatrix} 0.5 \\ 0.5 \\ 0.5 \\ \textcolor{red}{0.5} \\ 0 \\ 0 \\ 0 \end{pmatrix}, \quad A' = \begin{pmatrix} 0 \\ 0 \\ 0 \\ \textcolor{red}{0.5} \\ 0.5 \\ 0.5 \\ 0.5 \end{pmatrix},$$

de sorte que $A \cdot A' = 0.5 \times 0.5 = \textcolor{red}{0.25}$. Pour des $B, B' \in \mathbb{R}^7$ arbitraires, on a

$$W = BA^T + B'A'^T, \quad \text{et} \quad WA = B + \textcolor{red}{0.25} B'.$$

Élément par élément,

$$WA = \begin{pmatrix} b_1 + 0.25 b'_1 \\ \vdots \\ b_7 + 0.25 b'_7 \end{pmatrix}.$$

Psychologiquement, on peut dire que A « active » majoritairement B , mais qu'une partie de l'activation « fuit » vers B' parce qu'une partie des traits/indices de A est partagée avec A' . Plus le partage est grand, plus la « teinte » de B' dans la réponse grandit.

Généralisation. Kahana généralise son modèle au cas où un sujet doit mémoriser L paires de mots associés. Il s'agit donc d'encoder L paires $(A_1, B_1), \dots, (A_L, B_L)$ dans une matrice carrée $n \times n$. Comme précédemment, $A_i, B_i \in \mathbb{R}^n$ et tous les A_i unitaires. Chaque association est encodée par

$$W_i := B_i A_i^\top \quad (i = 1, \dots, L),$$

et la matrice qui contient toutes les associations $A_i \rightarrow B_i$ est donnée par la somme de toutes les matrices W_i :

$$\mathbf{W} = \sum_{i=1}^L W_i = \sum_{i=1}^L B_i A_i^\top.$$

La qualité de la récupération d'un B_k à partir de A_k via $\mathbf{W}$ dépend du degré d'orthogonalité entre A_k et les autres vecteurs indices A_i ($i \neq k$). Si A_k n'a aucune superposition avec tous les autres A_i (c'est-à-dire si $\forall i \neq k, A_k$ est orthogonal à A_i) alors la récupération sera optimale¹. Par « récupération optimale » il faut comprendre qu'on récupère exactement B_k dans le produit matriciel correspondant à la récupération : $\mathbf{W}A_k = B_k$. En revanche, s'il y a un chevauchement entre A_k et certains vecteurs A_i , le modèle prédit qu'il y aura une interférence entre plusieurs associations de telle manière que l'issue de la récupération sera une combinaison linéaire de B_k et des vecteurs B_i associés à des A_i qui chevauchent A_k . Cette interférence apparaît explicitement dans la formule suivante :

$$\mathbf{W}A_k = B_k + \sum_{i \neq k} (A_i \cdot A_k) B_i.$$

1. Deux vecteurs sont *orthogonaux* si leur produit scalaire est égal à 0. Formellement les indices sont orthogonaux deux à deux si $A_i \cdot A_k = 0$ pour $i \neq k$. L'orthonormalité ($\|A_i\| = 1$ et l'orthogonalité) garantissent la récupération $\mathbf{W}A_k = B_k$ sans interférence.

Cette formule rend compte qu'on récupère B_k *plus* la somme de toutes les perturbations des autres B_i associés à des A_i chevauchant A_k : chaque similarité ($A_i \cdot A_k$) ajoute une composante d'interférence proportionnelle dans la sortie. En revanche, la somme indiquée en rouge ci-dessus est nulle si les indices sont orthogonaux deux à deux, en quel cas la récupération est optimale.

3.2.3. Interprétations psychologiques du modèle

On peut interpréter A_i comme des ensembles de traits *phonologiques* et B_i comme des ensembles de traits *sémantiques*. Le modèle prédit alors que deux mots proches phonologiquement (indices fortement corrélés, $A_i \cdot A_k$ grand) se concurrencent à la récupération sémantique, d'où une plus forte probabilité de confusions et, potentiellement, des temps de récupération accrus. Une telle interprétation semble cohérente avec certains modèles séparant ces différentes modalités. Par exemple, Dell propose un réseau dans lequel les unités linguistiques sont représentées sous forme de nœuds interconnectés. Les trois couches de ce réseau sont les suivantes :

1. Couche sémantique : contient les attributs sémantiques des mots.
2. Couche lexicale (« lemmes ») : contient l'identité des mots individuels.
3. Couche phonologique : contient les phonèmes composant les mots.

Grâce aux connexions entre ces différents niveaux, il est possible de récupérer la sémantique d'un mot à partir de sa phonétique, et inversement, de retrouver un mot individuel phonologiquement à partir d'attributs sémantiques (par ex. associer l'attribut « carapace » au lemme sémantique « tortue »)¹.

Les activations sémantiques parasites prévues par le modèle de KAHANA (2012) peuvent être *très résiduelles* et *transitoires* : deux états sémantiques B_i et B_j peuvent coexister brièvement,

1. Le modèle de Dell ouvre aussi la voie à des critiques et des améliorations du modèle de KAHANA (2012). Par exemple, le modèle de Dell intègre souvent deux paramètres clés :

- *Les poids sémantiques* : représentent la force des connexions entre les unités sémantiques et lexicales. Un poids sémantique faible reflète une difficulté d'accès au sens d'un mot.
- *Les poids phonologiques* : représentent la force des connexions entre les lemmes et les phonèmes. Un poids phonologique faible indique une difficulté d'accès à la forme sonore d'un mot.

En faisant varier ces poids, on peut modéliser « la difficulté dans la récupération des mots » propre aux aphasies ou aux démences (voir FOREST (2005, p.183)).

puis l'un l'emporte si son activation est plus forte, l'autre s'éteint et l'état dominant se stabilise. On peut (au moins métaphoriquement) considérer que les coordonnées associées à B_i se comportent comme un attracteur¹.

Dans cette hypothèse, des activations proches de l'attracteur B_i convergent vers lui. La théorie des systèmes dynamiques représente ce phénomène via la notion de *bassin d'attraction*. Ce processus de récupération est parfois appelé *auto-association*. À partir d'un indice incomplet ou bruité d'un item, l'état d'un réseau auto-associatif peut retrouver le motif complet correspondant à cet item. Ainsi, dans certains modèles qui utilisent des réseaux de neurones récurrents, l'état du réseau à un instant donné se représente comme un vecteur d'activations dans un espace d'états à très haute dimension ; l'entraînement façonne dans cet espace des bassins d'attraction correspondant aux motifs d'activation fréquemment rencontrés. Lorsqu'on présente une entrée partielle, la dynamique récurrente fait évoluer ce vecteur le long d'une trajectoire dans l'espace d'états — par mises à jour itératives — jusqu'à convergence dans le puits le plus proche, c'est-à-dire l'attracteur qui complète le mieux l'information fournie. Suivant une métaphore spatiale proposée par HUTCHISON (2003), la « distance » entre deux attracteurs reflète la similarité des items correspondants : plus deux items sont similaires, plus leurs bassins le sont aussi².

1. GÄRDEFORS (2000, sec. 7.2.1) : « If the ANN is sufficiently regular in its behavior, the set of attractor points will form a low-dimensional hyper-surface in the high-dimensional state space of the ANN. Under certain conditions, this surface can be interpreted as a conceptual space. »

2. HUTCHISON (2003, p.807) : "Currently, the most popular type of distributed network for modeling semantic priming is a recurrent network, in which all the features are interconnected and the model learns by settling into frequently occurring patterns. These learned patterns are referred to as attractor basins, because the network is biased to settle into one of these known patterns when given partial information. [...] These models clearly predict priming from items sharing a overlap in features. If the previous word was semantically similar to the new word, the network will settle faster to the attractor basin of the new stimulus than if the previous word was dissimilar. Some researchers have used a spatial metaphor for describing basins of attraction, claiming that more similar patterns are stored closer together so that the network has a shorter distance to travel [...] Distance, in this sense, refers to the amount of updates (iterations) the model requires in order to stabilize on the new pattern".

Conclusion

Dans le premier chapitre, nous avons exposé l'application de la théorie des espaces conceptuels aux couleurs. En premier lieu, nous avons pointé deux problèmes de l'espace RVB qui étaient *structurellement résolus* dans l'espace HSB, puis nous avons introduit les espaces colorimétriques CIELAB et CIELUV (1.1 ; 1.2). Partant de cela, toutes les parties suivantes de ce premier chapitre expliquent comment construire un *espace conceptuel des couleurs* qui rende compte de la *catégorisation*. La section 1.4.1 expose les hypothèses qui président à la collecte des données et la section 1.4.2. explique l'application d'un *multidimensional scaling* sur ces données. En exposant les deux théories concurrentes de la catégorisation que sont la théorie des exemplaires (1.4.3) et la théorie du prototype (1.4.4), nous espérons avoir montré que la théorie des espaces conceptuels s'appuie sur l'hypothèse que l'espace conceptuel répond à des *contraintes*.

En s'appuyant sur la théorie du prototype, nous avons montré que les diagrammes de Voronoï offrent une méthode parcimonieuse pour partitionner l'espace colorimétrique en régions distinctes. Bien qu'une telle partition permette de rendre compte de l'*apprentissage* des couleurs par induction¹ et par *généralisation*², elle semble néanmoins difficilement rendre compte de la *flexibilité* sémantique et des *cas-limites*. La section 1.5 expose donc une version sophistiquée du modèle fondée sur des régions prototypiques convexes pour produire des régions frontières. Bien que ce modèle des diagrammes de Voronoï généralisé et les hypothèses de convexité semblent spéculatives, on peut les prendre comme *heuristiques* permettant de générer des *prédictions empiriques testables*³.

Dans le deuxième chapitre, nous avons essayé d'appliquer la théorie des espaces conceptuels au langage naturel. Plus précisément, ce chapitre tente de modéliser l'apparition de faux souvenirs dans les expériences DRM (2.1.1) qui désignent concrètement le fait de reconnaître des mots sémantiquement reliés aux mots d'une liste sans pour autant s'y trouver. Le chapitre propose d'utiliser la théorie des espaces conceptuels pour modéliser ce phénomène, en examinant notamment *la récupération* d'un mot dans la mémoire de travail et *la modulation des*

1. GÄRDENFORS (2000, chap.6) ; Snajder (2017).

2. POTH (2019).

3. GÄRDENFORS (2019) : « the convexity criterion is not proposed as something that necessarily holds of an application, but as an empirical law that generates testable predictions. »

traits sémantiques par l'attention pouvant contribuer à l'apparition de faux souvenirs. L'une des difficultés, à notre sens, tient à ce que les espaces dans lesquels les significations des mots sont usuellement représentées ne peuvent être appelés « espaces conceptuels » qu'en un sens faible, parce qu'ils semblent ne satisfaire qu'imparfaitement les requisits imposés par Gärdenfors. Il nous semble qu'à mesure qu'un espace de similarité en 2D ou 3D est construit avec *beaucoup* de mots appartenant à des classes *différentes*, étant donc hétérogènes entre eux, plus les dimensions et directions des vecteurs dans l'espace de similarité obtenus seront difficilement interprétables. C'est d'ailleurs sans doute la raison pour laquelle les recherches proposent généralement de représenter une liste de mots du niveau de base appartenant tous à une même classe (e.g., une liste de noms de mammifères¹). Une piste de recherche prometteuse vise précisément à tenter d'interpréter les vecteurs en très haute dimensionnalité d'un espace latent (cf. 2.3.2). De plus, nous avons essayé de tracer un pont entre l'idée de *distinctivité* comme facteur modulant le taux de fausses reconnaissances dans les expériences DRM (2.4) et la notion de *distinctivité* telle qu'elle est abordée dans la théorie des espaces conceptuels². La notion de distinctivité est facile à cerner dans le cadre d'une sémantique **compositionnelle**, autrement dit lorsque les constituants sémantiques sont *discrets*. Dans un tel cadre on peut admettre, par exemple, que le concept de « zèbre » peut être décomposé en composants tels que « rayures », « quadrupède », « herbivore », et « habitant de la savane », etc. Pour quantifier la *distinctivité* de chaque propriété, on peut utiliser un coefficient de Jaccard sur un ensemble d'animaux, chacun caractérisé par de tels traits. C'est sur ce modèle intuitif qu'on considère les propriétés morphologiques, orthographiques et/ou phonologiques des mots comme étant *plus distinctives* que leurs propriétés sémantiques. Cependant, cette approche rencontre au moins deux difficultés.

Premièrement, la théorie des espaces conceptuels n'est pas *strictement componentielle*, car toute propriété n'est pas *binaire* mais *gradable* sur un continuum correspondant aux axes de toutes les dimensions du domaine sur lesquelles elle est définie. Par conséquent, dire que « cerise » et « tomate » partagent la propriété « rouge » est imprécis, car les régions de l'espace colorimétrique correspondant au ROUGE pour ces deux concepts peuvent ne pas **se superposer**

1. C'est ce que font DOUVEN, VERHEYEN et al. (2023), MOULLEC (2024) en sélectionnant vingt noms de *mammifères*, ou encore DERRAC et SCHOCKAERT (2015) avec des mots-clés concernant des *films*.

2. Osta-Velez (2023), article s'inscrivant plutôt dans le cadre d'une approche componentielle en considérant par exemple la crinière comme un attribut distinctif du lion par rapport à une « contrast class ».

parfaitement. Certes, *l'intersection* des deux régions pourrait être considérée suffisamment grande pour dire qu'il s'agit d'une *propriété en commun*, mais cela conduit à d'autres difficultés : comment mesurer la taille de l'intersection de ces deux régions ? Quel est le seuil d'intersection nécessaire pour dire d'une propriété qu'elle est partagée par deux éléments et la considérer comme commune ? Autrement dit, il est difficile de définir un processus opérationnel permettant d'identifier une propriété *distinctive*.

Deuxièmement, les méthodes exposées dans le deuxième chapitre pour extraire des dimensions interprétables à partir du niveau « *sous-conceptuel* »¹, c'est-à-dire le niveau *brut* des vecteurs en haute dimensionnalité, sont certainement des méthodes *naïves* ou *simplistes*. Par exemple, la méthode décrite dans la section (2.5.3) suppose qu'un sous-ensemble spécifique des dimensions d'un vecteur *encode* une propriété spécifique *contenue* dans la signification du mot associé à ce vecteur.

Nous estimons que le deuxième chapitre adopte une perspective relativement *statique*. Ce caractère *statique* tient par exemple à ce que la théorie des espaces conceptuels rencontre beaucoup de difficultés à modéliser les connotations et les variations sémantiques en fonction du contexte. Les adjectifs y sont *restreints* à un seul domaine, dans lequel se trouve leur *sens littéral* et leurs *connotations* possibles ne sont donc pas capturées dans ce domaine unique. Par exemple, le fait que l'adjectif « bleu » connote la mer, le ciel, ou le calme implique de sortir du domaine des couleurs. Puisque les *propriétés* ne peuvent être définies que sur *un* domaine, la représentation des connotations n'est possible que pour les *concepts*. Mais, pour les concepts polysémiques ou abstraits, la modélisation est difficile.

Dans un espace latent, les directions qui correspondent à une variation sémantique interprétable ne sont généralement pas alignées avec les axes de cet espace. Modifier la valeur d'une seule dimension (se déplacer le long d'un axe) affecte plusieurs attributs sémantiques à la fois. C'est ce non-alignement qui constitue l'enchevêtrement (*entanglement*). Il devient donc très difficile d'isoler un ensemble de dimensions ou de directions qui encodent une feature indépen-

1. GÄRDENFORS (2000, chap. 2) distingue trois niveaux : le « symbolique », le « conceptuel » et le « sous-conceptuel ». Au niveau symbolique, les observations sont représentées en les décrivant dans un langage spécifique. Au niveau conceptuel, les observations sont caractérisées dans un espace conceptuel. Au niveau infra-conceptuel, les observations sont caractérisées par les entrées des récepteurs sensoriels. L'auteur considère le traitement qui a lieu dans les réseaux de neurones artificiels comme un exemple de modélisation au niveau infra-conceptuel.

damment de toutes les autres. Face à ce constat, certains travaux de recherche explorent des architectures qui contraignent la géométrie de l'espace latent pour y favoriser l'interprétabilité (cf. 2.5.3).

Dans la section (2.5.4) nous avons proposé la distance euclidienne pondérée pour prendre en compte les influences du contexte sur la sémantique d'un mot. Mais les différents **poids** affectés à chaque dimension doivent être définis *manuellement* : étant donnée une phrase (ou un contexte plus large), la théorie des espaces conceptuels ne permet pas *d'inférer* quel sera le poids respectif de chaque dimension dans ce contexte. Par exemple, le fait que telle ou telle dimension du mot "profond" soit activée selon qu'il s'agisse d'un "amour profond" ou d'un "puit profond". Le modèle exige toujours une supervision manuelle des poids qui font la pondération. C'est aussi le cas pour les embeddings statiques (e.g. Word2vec, GloVe, etc.) qui capturent les propriétés distributionnelles du mot sur tous ses usages. Donc si un mot a plusieurs sens, son vecteur capture toutes ses significations à la fois. Les mécanismes d'attention sont des outils coûteux mais performants pour orienter le sens d'un mot en fonction de son contexte. Il serait très intéressant de voir si l'on peut rapprocher le mécanisme d'attention de la méthode exposée dans la section 2.5.5 en collectant de nombreux embeddings contextuels d'un même mot puis en faisant une réduction de dimensionnalité.

Le troisième chapitre montre qu'il faut identifier certains principes qui régissent la dynamique des activations sémantiques sur des intervalles de temps très courts (inférieurs à la seconde). Pour cela, nous nous sommes d'abord appuyés sur les expériences de VAN HEUVEN et al. (1998) (cf. 3.1), en évoquant ensuite le modèle de KAHANA (2012) (cf. 3.2), pour esquisser les grandes lignes d'un modèle dynamique dans la section (3.3.1). Opérationnaliser un tel modèle dynamique implique de collecter des données et des résultats d'expériences.

Un autre défaut majeur de la théorie des espaces conceptuels considère les différents domaines $\delta_1, \dots, \delta_n$ *isolément* les uns des autres alors qu'en pratique, elles entretiennent presque toujours de fortes corrélations. BECHBERGER (2023) a essayé de modéliser les corrélations dans sa thèse (cf. Annexe B, sec. 2).

En somme, nous n'avons pas réussi, avec la théorie des espaces conceptuels, à représenter la signification d'un ensemble hétérogène de mots abstraits. Cependant, cette théorie demeure une heuristique féconde dont la force réside dans sa capacité à structurer des gestes de pensées et à offrir un pont entre les modèles symboliques et les modèles distribués.

Annexe A : Deux approches de la sémantique

L'approche "classique" de la sémantique

Une classe est un ensemble d'objets regroupés par des attributs communs. Les attributs qu'un objet doit nécessairement avoir pour appartenir à une classe sont parfois appelés *propriétés essentielles* ou *nécessaires*, par opposition à celles qui sont *accidentelles*, ou *contingentes*. Un concept apparaît donc comme un ensemble d'éléments qui partagent *tous* un (ou plusieurs) attribut(s).

Dans son *Organon*, Aristote définit le *genre* comme un *prédicat* commun à plusieurs choses ayant des *différences spécifiques* entre elles¹. Par exemple, « animal » est le genre commun à l'espèce humaine, à l'espèce des chevaux, des oiseaux, etc. Chaque espèce se distingue de toutes les autres par sa différence spécifique. Par exemple, l'espèce des « lions » peut être définie comme des félins (genre) dotés d'une crinière (différence spécifique).

Traditionnellement, une classe (ou un concept) peut être défini en *extension* ou en *intension* :

L'**extension** d'un concept désigne la collection de tous les objets qui tombent sous ce concept. L'extension englobe tous les objets qu'on peut ranger sous ce concept. Ainsi, l'extension du concept *cheval* est constituée par tous les chevaux.

L'**intension** d'un concept (on dit parfois son *contenu*, sa *compréhension*) désigne les caractères du concept, c'est-à-dire la conjonction des propriétés que possèdent nécessairement les objets qui tombent sous lui. L'intension est l'ensemble des attributs (ou propriétés) nécessaires et suffisants pour dire qu'un objet appartient à une catégorie.

Ainsi, l'espèce doit être définie en compréhension par des propriétés essentielles qui déterminent son appartenance au genre *et* par des propriétés essentielles qui permettent de distinguer cette espèce de toutes les autres au sein de ce même genre. Étant admis qu'un genre contient au moins deux espèces, ce dernier a une plus grande extension que ses espèces, lesquelles nécessitent plus de conditions dans leurs définitions, autrement dit, des déterminations supplémentaires par rapport au genre.

Passer du concept d'espèce (plus spécifique) au concept de genre (plus général) correspond à une montée en abstraction, un mouvement du particulier vers le général. Nous pouvons

1. ARISTOTE, *Organon*, *Topiques* I, 5, 102a31-32.


distinguer trois processus principaux illustrant cette dynamique, présentés ici selon un ordre croissant d'abstraction et de formalité :

Si on veut rester strictement dans un cadre classique, il semble qu'on peut présenter simplement le processus d'abstraction comme suit : en partant d'une collection d'objets reconnus comme appartenant à un même concept (par exemple, en voyant plusieurs chaises différentes), on peut induire leurs caractéristiques communes essentielles pour construire ou affiner l'intension (les conditions nécessaires et suffisantes pour qu'un X soit considéré comme 'chaise')¹. Cette intension nouvellement formulée détermine alors une extension *plus vaste*, car elle s'applique potentiellement à toutes les chaises existantes ou imaginables, pas seulement celles observées initialement.

La relation « X et Y sont deux *espèces* de Z » (ou de manière équivalente « Z est le *genre* de X et Y ») peut être représentée de deux manières distinctes : soit de manière *arborescente* où X et Y sont deux nœuds inférieurs connectés au nœud supérieur Z , soit de manière *spatiale*, où X et Y sont *inclus* à l'intérieur de Z comme dans une boîte. Les propriétés qui définissent Z sont également attribuées à X et Y . Interprété dans une arborescence, cela veut dire que les nœuds inférieurs *héritent* des propriétés des nœuds supérieurs. Interprété spatialement, cela veut dire qu'une propriété définissant un ensemble est *transmise* à ses sous-ensembles. Ainsi, plus un nœud est *haut* dans l'arborescence, plus les propriétés qui le caractérisent sont *générales*, et inversement. De la même manière, moins les conditions requises pour appartenir à Z sont restrictives et spécifiques, plus l'extension de Z sera *vaste*, et inversement. Ces principes semblent particulièrement bien exemplifiés dans les taxonomies des êtres vivants, ou bien dans celles des objets mathématiques. Par exemple, Nicole et Arnauld proposent une arborescence hiérarchique entre quelques *concepts géométriques*².

1. En ce sens l'abstraction est pensée comme une extraction : on recherche une pépite d'or, on élimine tout ce qui ne vaut rien, tout ce qui ne sert pas. Cette conception de l'abstraction comme extraction se retrouve dans l'étymologie grecque et latine : le terme grec pour « abstraction » est « *aphairesis* » qui signifie littéralement « enlever quelque chose à quelque chose d'autre ».

2. ARNAULD et al. (1992, p.53 ; p.311) décrivent ces relations par les notions de genres et d'espèces, par exemple : « le quadrilatère, qui est un genre au regard du parallélogramme et du trapèze, est une espèce au regard de la figure ».



Exemple d'arborescence logique selon Arnauld et Nicole

Classification basées sur la fréquence

Ainsi l'approche classique de la classification repose sur l'identification de propriétés essentielles permettant de définir des catégories aux frontières nettes et de les organiser hiérarchiquement. Bien qu'efficace pour les concepts mathématiques (Fig. 9), il s'agit d'une vision essentialiste de la catégorisation qui ne rend pas compte de la catégorisation dans le langage naturel. Il est souvent impossible d'identifier un ensemble unique de conditions nécessaires et suffisantes pour définir des catégories naturelles. C'est dans ce contexte que certains, comme Whewell, ont proposé une approche plus souple et qui part davantage des données empiriques.

Dans son article consacré à Whewell, WARD (2023) le situe parmi les penseurs qui considèrent les propriétés naturelles comme des *clusters*. Cette approche, appelée théorie des clusters, s'oppose à l'idée que les concepts peuvent être définis par des conditions nécessaires et suffisantes. Whewell met en avant une perspective *non-essentialisme* de classification qui ne s'appuie pas sur des propriétés essentielles, fixes et invariables pour définir des groupes. Les membres d'un groupe partagent un ensemble de caractéristiques, mais il n'est pas nécessaire que chaque membre possède toutes ces caractéristiques. Selon WARD (2023), Whewell propose une théorie des clusters qui repose sur trois principes fondamentaux :

1. **Similarité** : Les individus d'un même type naturel partagent de nombreuses propriétés.
2. **Séparation** : Les propriétés cooccurentes qui caractérisent les types naturels sont regroupées.

pées dans le sens où il existe des "écarts" entre les types dans l'espace des propriétés.

3. **Anti-essentialisme** : De nombreux ou la plupart des types naturels ne possèdent pas d'essence : il n'y a pas de conditions nécessaires et suffisantes pour appartenir à un type.

Le premier engagement (*Similarité*) implique qu'une collection d'objets ne peut être un genre naturel que si ses objets partagent de nombreuses propriétés. Il n'est toutefois pas nécessaire qu'il y ait une propriété que tous et seulement les membres d'un genre aient en commun. Le troisième engagement (*Anti-essentialisme*) suggère précisément que les catégories ne sont pas associées à des conditions d'appartenance nécessaires et suffisantes. Ainsi, les théoriciens des clusters se positionnent entre ces deux extrêmes en exigeant à la fois des similitudes et une séparation entre les différentes catégories, tout en refusant de les essentialiser.

L'une des raisons pour laquelle Whewell apparaît comme théoricien des **clusters** est qu'il suggère qu'une catégorie a un *centre* qui en est le plus représentatif :

Natural Groups are best described, not by any Definition which marks their boundaries, but by a Type which marks their center¹

Les espèces qui appartiennent à un genre gravitent autour du centre de ce dernier. Les espèces qui appartiennent à un genre sont *rangées autour* de l'espèce-type du genre. Un genre regroupe des espèces présentant un continuum de ressemblances, certaines très proches du type et d'autres plus éloignées, mais toutes ayant plus d'affinités entre elles qu'avec les espèces d'autres genres.

De nombreuses techniques permettent d'évaluer à quel point un jeu de données satisfait chacun des trois critères énoncés ci-dessus, comme le clustering.

Tels qu'ils sont définis par Borg et Groenen, les clusters sont des regroupements de points *denses* et *séparés* les uns des autres². Ainsi, en principe, les clusters ont à la fois une forte similarité interne et une séparabilité.

L'analyse en clusters vise à regrouper des objets de manière à maximiser la similarité au sein de chaque groupe et à minimiser la similarité entre les différents groupes. Cette méthode fait partie de l'apprentissage non supervisé, car elle ne nécessite pas de pré-étiquetage des

1. Whewell, *Novum Organon Renovatum*, 1858, p.21.

2. BORG et GROENEN (2005, p.104)) : "a cluster is a particular region whose points are all closer to each other than to any point in some other region. This makes the points in a cluster look relatively densely packed, with "empty" space around the cluster".

données pour effectuer la partition en clusters. Considérons un ensemble de données noté $D = \{x_1, \dots, x_n\}$, où chaque x_i est un vecteur multidimensionnel.

Une mesure de la similarité interne d'un cluster C est définie comme la somme des distances entre toutes les paires distinctes de points au sein de ce cluster. Cette mesure évalue la proximité des éléments qu'il contient, reflétant ainsi la qualité de son homogénéité. Cette mesure est formellement donnée par :

$$\text{Similarité Interne}(C) = \sum_{\substack{x, y \in C \\ x \neq y}} \mathcal{D}(x, y)$$

où $\mathcal{D}(x, y)$ représente la distance entre les points x et y . Une faible similarité interne indique que les points du cluster sont proches les uns des autres, suggérant un cluster bien défini et homogène. À l'inverse, une similarité interne élevée peut indiquer que les points sont dispersés, suggérant un cluster moins cohérent.

Lien avec le modèle symbolique de RICKARD et al. (2007)

RICKARD et al. (2007, p.4547) proposent un modèle anti-essentialiste en définissant les concepts comme des matrices de cooccurrences entre propriétés. Prenons l'exemple de deux propriétés P_A et P_B définies par :

- P_A : être une pomme rouge
- P_B : être une pomme douce

La cooccurrence $C(P_A, P_B)$ est égale à 1 si toutes les pommes rouges sont douces, c'est-à-dire si pour tout x , $P_A(x)$ implique $P_B(x)$. En revanche, $C(P_B, P_A)$ correspond à la proportion de pommes rouges parmi les pommes douces. Même si toutes les pommes rouges qu'un sujet a consommées étaient douces ($C(P_A, P_B) = 1$), si celles-ci sont en petit nombre par rapport au nombre total de pommes qu'il a mangées, $C(P_B, P_A)$ peut être faible. Par exemple, $C(P_B, P_A) = 0,1$ signifie que 10 % des pommes douces goûtées par le sujet étaient rouges, ou, de manière équivalente, que 90 % des pommes douces goûtées par le sujet n'étaient pas rouges.

L'hypothèse de RICKARD et al. (2007) est que les propriétés qui s'activent le plus fortement dans l'esprit du sujet sont celles qui cooccurrent ensemble le plus fréquemment pour les objets considérés. Cette approche basée sur la *fréquence* peut rendre compte de certaines variabilités inter-individuelles. Par exemple, le mot « citron » activera plus fortement la propriété « jaune »

chez un sujet qui a rencontré une minorité de citrons verts par rapport au total des citrons croisés au cours de sa vie. Inversement, pour un sujet ayant une expérience majoritairement composée de citrons verts, le mot « citron » pourrait être moins fortement associé à la couleur jaune.

L'approche de RICKARD et al. (2007) propose également une méthode pour classer les propriétés d'une catégorie (par exemple, les caractéristiques des oiseaux) de la plus caractéristique à la moins caractéristique, en se basant sur la fréquence de cooccurrence des propriétés. Pour ce faire, il faut partir d'un ensemble de propriétés $\{P_1, \dots, P_m\}$ et connaître la fréquence avec laquelle P_i co-occure avec P_j pour chaque paire de propriétés constructibles avec cet ensemble. Avec tous ces éléments, il est en effet possible d'ordonner ces propriétés des plus caractérisantes aux moins caractérisantes. L'idée étant que lorsqu'on pense au concept d'« oiseau » par exemple, on pense *d'abord* aux propriétés qui cooccurrent le plus souvent ensemble chez les oiseaux qu'on a rencontrés. Ils avancent que lorsqu'on pense à un concept, par exemple « oiseau », les premières propriétés qui viennent à l'esprit sont celles qui apparaissent le plus souvent ensemble dans les exemples d'oiseaux rencontrés. Pour mesurer à quel point une propriété P_i est caractéristique, ils proposent que l'on prenne en compte toutes les valeurs de corrélation $C(P_i, P_j)$ et $C(P_j, P_i)$ pour tout $P_j \in \{P_1, \dots, P_m\}$. Intuitivement, cela veut dire collecter toutes les réponses aux questions : « Combien de fois ai-je rencontré un x ayant la propriété P_i mais pas P_j ? » et « Combien de fois ai-je rencontré un x ayant P_j mais pas P_i ? » pour tout $P_j \in \{P_1, \dots, P_m\}$. Cela permet bien de rendre compte que l'attribut "savoir voler" vient en pensée quand on pense aux oiseaux et vice versa, que l'autruche et/ou le pingouin soient peu représentatifs de cette catégorie. Ce ne sera pas le cas des propriétés qui n'ont pas de bons scores de cooccurrence avec les autres. Par exemple, bien que la propriété de « nager sous l'eau » s'applique aux pingouins ou aux cormorans, la plupart des x rencontrés qui satisfont les propriétés correspondant aux oiseaux, ne satisfont pas cette propriété ; vice versa, la probabilité que x ait des plumes sachant que x sait nager sous l'eau ne paraît pas très élevée.

RICKARD et al. (2007) proposent d'établir un seuil σ ne retenant que les propriétés dont les scores de cooccurrence dépassent ce seuil. Leur idée est d'isoler les propriétés qui constituent *le cœur sémantique* du concept. L'idée de retenir les propriétés qui cooccurrent le plus et de poser ce seuil σ revient à chercher un sous-ensemble de propriétés fortement connectées entre elles — proche de l'idée d'un cluster dense dans un graphe de similarité.

Annexe B : notions mathématiques utilisées

1. Notions issues des statistiques / probabilités

La **covariance** de deux variables aléatoires X et Y est l'espérance du produit des écarts de chaque variable à sa propre espérance :

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

où $\mathbb{E}[X]$ et $\mathbb{E}[Y]$ sont les espérances respectives de X et Y .

L'**écart-type**, noté σ , est une mesure de dispersion qui quantifie, en moyenne, la distance des valeurs d'un ensemble à leur moyenne :

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

où n est le nombre d'observations, x_i la i -ème observation et μ la moyenne.

Le **coefficient de corrélation linéaire**, noté ρ , indique à quel point deux variables sont corrélées :

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

où σ_X et σ_Y sont les écarts-types de X et Y . La valeur de ρ est comprise entre -1 et 1 . Plus ρ est proche de 1 , plus la corrélation positive entre les variables est forte. Plus ρ est proche de -1 , plus la corrélation entre les variables est fortement négative (X a une forte tendance à diminuer quand Y augmente et vice versa). Si ρ est proche de 0 , cela signifie qu'il n'y a pas de corrélation linéaire entre les variables.

2. Distances

Soient deux points $A = (x_1, y_1)$ et $B = (x_2, y_2)$ dans un plan. Admettons que x corresponde à l'abscisse et y à l'ordonnée. Si l'on trace à partir de A une *projection horizontale* jusqu'à la verticale passant par B , puis une *projection verticale* jusqu'à B , on obtient deux segments perpendiculaires. Ces deux segments correspondent aux différences des composantes sur les axes des abscisses et des ordonnées, à savoir $|x_2 - x_1|$ et $|y_2 - y_1|$ respectivement. Ces deux segments forment les deux côtés d'un triangle rectangle dont l'hypoténuse est précisément le segment $\overline{AB}$. D'après le théorème de Pythagore, ce segment est donné par :

$$\sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2},$$

Cela se généralise à des dimensions supérieures. Considérons deux points de l'espace $\mathbb{R}^n$, dont le vecteur de différence est

$$(\Delta_1, \Delta_2, \dots, \Delta_n).$$

Chaque coordonnée Δ_i représente la variation le long de l'axe i . Comme, par convention, les axes de $\mathbb{R}^n$ sont orthogonaux deux à deux, ces différences jouent le même rôle que les côtés perpendiculaires du triangle rectangle en dimension 2. Ainsi, la longueur du vecteur de différence, c'est-à-dire la distance entre les deux points, est donnée par la formule générale :

$$\mathcal{D} = \sqrt{\Delta_1^2 + \Delta_2^2 + \dots + \Delta_n^2}.$$

qui est exactement la formule de la distance euclidienne entre A et B . Cette distance conforme à l'intuition visuelle est généralement utilisée dans le cadre de la théorie des espaces conceptuel et est appelée *distance euclidienne* et définie pour deux points $\mathbf{x}$ et $\mathbf{y}$ par :

$$\mathcal{D}_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{\sum_{i=1}^d (x_i - y_i)^2}$$

À un niveau de généralité plus haut, BECHBERGER (2023, p.55) commence en définissant la métrique de Minkowski d'ordre $r > 0$ pondérée par des poids w_i :

$$\mathcal{D}_r(x, y) = \left(\sum_{i=1}^m w_i \times |x_i - y_i|^r \right)^{\frac{1}{r}}$$

où les poids w_i représentent l'importance relative des différentes dimensions dans le contexte donné (détails dans la section 2.5.4). La distance euclidienne et la métrique de Manhattan sont deux cas spécifiques de la métrique de Minkowski avec $r = 1$ et $r = 2$ respectivement.

Les apports possibles de la distance de Mahalanobis

Certaines autres distances pourraient avoir des applications assez intéressantes. Par exemple, nous montrons ci-dessous que la distance de Mahalanobis est pertinente lorsqu'il existe des corrélations à peu près linéaires entre plusieurs attributs¹.

La distance de Mahalanobis "pondère" les directions selon la structure de covariance : si un point a un écart important le long d'une direction alignée sur l'axe de corrélation, ce point

1. BECHBERGER (2023, pp.60-63 sec. 2.2.1)

sera jugé typique ; en revanche s'il a un écart important le long d'une direction opposée à la corrélation, le point sera considéré comme atypique.

Considérons le concept de « banane » et supposons un espace conceptuel dans lequel se trouvent un très grand nombre d'instances (de bananes singulières) qui ont été observées et goûtées. L'espace conceptuel contenant ces points est construit sur le domaine de la couleur (vert à brun foncé) et de la texture (de dur à mou). Empiriquement, ces deux attributs sont fortement corrélés : plus une banane brunit, plus elle devient molle. Si l'on représente chaque banane rencontrée comme un point sur un plan 2D (couleur, texture), ces points forment un nuage ayant une forme elliptique, allongée le long de la direction de corrélation.

Soit c la couleur (indice de brunissement) et t la texture. Définissons des coordonnées normalisées :

$$z_c = \frac{c - \mu_c}{\sigma_c}, \quad z_t = \frac{t - \mu_t}{\sigma_t}$$

et soit ρ la corrélation entre c et t . Alors

$$D_M^2 = \frac{z_c^2 - 2\rho z_c z_t + z_t^2}{1 - \rho^2}.$$

Supposons que les deux dimensions sont fortement corrélées (p. ex. $0.5 < \rho < 1$). Ces préalables étant posés, la distance de Mahalanobis permet par exemple de rendre compte qu'une banane un peu verte et un peu dure sera jugée typique tandis qu'une banane verte et molle sera jugée atypique. Pour une telle banane, supposons que z_c est négatif et z_t positif. Le produit $z_c \times z_t < 0$, donc $-2\rho z_c z_t > 0$, ce qui augmente D_M^2 . De manière symétrique, une banane très mûre ET dure a un z_c positif et élevé et z_t est négatif, d'où $z_c \times z_t < 0$, donc $-2\rho z_c z_t > 0$, ce qui augmente D_M^2 . Cette combinaison va à l'encontre de la corrélation attendue et se projette de l'autre côté de l'ellipse : la banane sera jugée atypique.

3. Notions d'informatique appliquée au langage naturel

Term Frequency (TF). Soit $f_{t,d}$ le nombre d'occurrences du terme t dans le document d . On définit communément a TF (*Term frequency*) mesure l'importance du terme dans le document considéré.

$$\text{raw TF :} \quad \text{tf}_{t,d} = f_{t,d}.$$

$$\text{normalized TF :} \quad \text{tf}_{t,d} = \frac{f_{t,d}}{\sum_{t'} f_{t',d}}$$

Soit N le nombre total de documents dans le corpus et df_t la fréquence documentaire du terme t (c'est-à-dire le nombre de documents contenant t). L'IDF est défini par :

$$idf_t = \log\left(\frac{N}{df_t}\right).$$

Plus un terme apparaît dans beaucoup de documents (df_t grand), moins il est informatif plus son IDF sera faible. À l'inverse, si un terme est rare (petit df_t), il est plus discriminant et son IDF sera élevé. Par exemple, puisque les mots « un », « ou », « et » apparaissent presque partout, leur IDF sera proche de 0.

Le **PMI** (*Pointwise mutual information*) désigne le *ratio* entre la probabilité d'observer les mots x et y ensemble (probabilité conjointe) et la probabilité d'observer les mots x et y tout seuls :

$$\mathbf{PMI}(x, y) = \log_2 \frac{P(x \wedge y)}{P(x) \cdot P(y)}$$

$P(x \wedge y)$ est la probabilité que les mots x et y concourent dans un contexte. Le contexte du mot x correspond à un nombre de mot nombre de mot spécifiques avant et après x .

Les *fréquences* des deux mots x et y affectent le résultat du **PMI**. Supposons par exemple qu'on compare **PMI**("the", "dog") et **PMI**("dog", "cat"). Puisque "the" est un article fréquemment utilisé en anglais, bien plus que "dog" et "cat", alors $P(\text{"the"}) > P(\text{"dog"})$ et $P(\text{"the"}) > P(\text{"cat"})$. Il en découle que le dénominateur $P(\text{"the"}) \cdot P(\text{"dog"})$ sera plus élevé que le dénominateur $P(\text{"dog"}) \cdot P(\text{"cat"})$, ce qui augmentera **PMI**("dog", "cat") par rapport à **PMI**("the", "dog"), si le numérateur est fixé.

Plus généralement, plus les mots x et y sont fréquents, plus $P(x) \cdot P(y)$ tendra à être élevé et à contrebalancer la valeur du **PMI**. Inversement, les mots les moins fréquents auront tendance à diminuer le dénominateur.

La **similarité cosinus** entre deux mots $w_a = (a_1, \dots, a_n)$ et $w_b = (b_1, \dots, b_n)$ est donnée par :

$$\text{CosineSim}(w_a, w_b) = \frac{w_a \cdot w_b}{\|w_a\| \cdot \|w_b\|} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n (a_i)^2} \cdot \sqrt{\sum_{i=1}^n (b_i)^2}}$$

$\text{CosineSim}(w_a, w_b)$ prend des valeurs dans l'intervalle $[-1 ; 1]$ et est équivalent au cosinus de l'angle θ entre les deux vecteurs w_a et w_b . Plus les valeurs sont proches de +1, plus cela indique que w_a et w_b sont dans la même direction, tandis que -1 correspond à des directions opposées. Si w_a et w_b sont orthogonaux, $w_a \times w_b = 0$ et donc $\text{CosineSim}(w_a, w_b) = 0$.

4. Le positionnement multidimensionnel (*Multidimensional scaling* (MDS))

La fonction de coût dite *stress* mesure l'écart entre les dissimilarités observées dans les données et les distances euclidiennes entre points dans une configuration X .

Soit $D = (\delta_{ij})$ la matrice des dissimilarités entre N objets. Pour une configuration

$$X = (x_1, \dots, x_N) \subset \mathbb{R}^M,$$

on note $d_{ij}(X)$ la distance euclidienne entre x_i et x_j dans la configuration X . Le *raw stress* (stress brut) de la configuration X est alors défini par

$$S_{\text{raw}}(X) = \sum_{i < j} (d_{ij}(X) - \delta_{ij})^2.$$

L'objectif du MDS (métrique) est de trouver des points $x_1, \dots, x_N \in \mathbb{R}^M$ tels que

$$\mathcal{D}_E(x_i, x_j) \approx \delta_{ij} \quad \text{pour tout } i, j \in \{1, \dots, N\},$$

c'est-à-dire une configuration X qui minimise $S_{\text{raw}}(X)$:

$$\arg \min_X S_{\text{raw}}(X).$$

Il faut noter que les vecteurs x_i ne sont pas uniques : avec la distance euclidienne, ils peuvent être arbitrairement traduits, tournés ou réfléchis, puisque ces transformations ne modifient pas les distances dans X .

Comme la valeur du stress brut est influencée par l'échelle des δ_{ij} et du nombre d'objets, il est d'usage de rapporter une version normalisée, telle que le Stress-1 comme l'indiquent BORG et GROENEN (2005, p.42) :

$$\sigma_1(X) = \sqrt{\frac{\sum_{i < j} (d_{ij}(X) - \delta_{ij})^2}{\sum_{i < j} d_{ij}(X)^2}}.$$

Cette version facilite la comparaison entre configurations et jeux de données de tailles ou d'échelles différentes.

Annexe C - Suppléments au chapitre 2

Glossaire DRM

Le taux de fausses reconnaissances du mot leurre ($FA_{crit.leure}$) est la proportion de participants qui ont répondu "ancien" face au mot leurre critique lors de la phase de reconnaissance de l'expérience DRM. Plus précisément, considérons une expérience DRM menée avec des participants, chacun d'entre eux étant exposé à une liste unique liée à un seul mot-leurre critique. Supposons que pendant le test de reconnaissance, chaque mot-leurre critique n'est présenté qu'une seule fois à chaque participant. Si, au cours de ce test, k participants sur n ont reconnu à tort le mot-leurre critique associé à leur liste, le taux de reconnaissance erronée est de $\frac{k}{n}$. Le taux de reconnaissance erronée correspond donc au pourcentage de participants qui ont reconnu à tort le mot-leurre critique.

Le taux de fausses reconnaissances des mots contrôles ($FA_{control}$) est la proportion de participants qui ont répondu "ancien" pour tous les mots non présentés, en incluant à la fois les mots reliés (dont le leurre critique) et les mots non-reliés. La valeur de $FA_{crit.leure}$ varie entre 0 (les mots nouveaux sont toujours reconnus comme nouveaux) et 1 (les mots nouveaux sont toujours reconnus comme anciens). ($FA_{crit.leure}$) capture donc la tendance d'un groupe de participants à répondre "oui" ou "non" spécifiquement pour les mots non présentés dans la liste initiale (voir Mark J HUFF et al., 2020).

Le taux de rejets corrects des mots contrôles (CR) représente la proportion de mots nouveaux (non présentés dans la liste) que les participants identifient correctement comme nouveaux. Puisqu'il n'y a que deux réponses possibles mutuellement exclusives pour chaque mot présenté : $CR + FA_{control} = 1$ et $CR = 1 - FA_{control}$.

Le taux de reconnaissance correcte (HR) désigne la proportion de mots correctement reconnus parmi ceux qui figurent effectivement dans la liste étudiée. Considérons une expérience DRM avec n participants. Au cours de la phase de reconnaissance, chaque participant se voit présenter G mots issus de la liste étudiée et doit indiquer s'il les reconnaît ou non. Le taux de réussite correspond à la proportion de mots correctement reconnus parmi les G mots testés,

calculée en moyenne sur l'ensemble des n participants. Soit B_i le nombre de réponses correctes pour le participant i , c'est-à-dire le nombre de mots correctement reconnus parmi les G mots testés. Le taux de reconnaissance correct moyen, HR , est donné par

$$HR = \frac{\sum_{i=1}^n B_i}{n \times G}$$

où $\sum_{i=1}^n B_i$ représente la somme des réponses correctes de tous les participants. Plus HR est proche de 1, plus les participants ont correctement reconnu tous les mots testés ; à l'inverse, plus HR est proche de 0, plus les participants n'ont pas reconnu les mots de la première liste.

Tableau 1 : Proportion de sujets (en %) ayant rappelé le mot leurre en fonction de différentes listes DRM entendues à l'oral. Extrait de STADLER et al. (1999).

Lures	List Words	False alarm rate
window	door, glass, pane, shade, ledge, sill, house, open, curtain, frame, view, breeze, sash, screen, shutter	65
sleep	bed, rest, awake, tired, dream, wake, snooze, blanket, doze, slumber, snore, nap, peace, yawn, drowsy	61
Smell	nose, breathe, sniff, aroma, hear, see, nostril, whiff, scent, reek, stench, fragrance, perfume, salts, rose	60
doctor	nurse, sick, lawyer, medicine, health, hospital, dentist, physician, ill, patient, office, stethoscope, surgeon, clinic, cure	60
smoke	cigarette, puff, blaze, billows, pollution, ashes, cigar, chimney, fire, tobacco, stink, pipe, lungs, flames, stain	54
chair	table, sit, legs, seat, couch, desk, recliner, sofa, wood, cushion, swivel, stool, sitting, rocking, bench	54
sweet	sour, candy, sugar, bitter, good, taste, tooth, nice, honey, soda, chocolate, heart, cake, tart, pie	54

Lures	List Words	False alarm rate
rough	smooth, bumpy, road, tough, sandpaper, jagged, ready, coarse, uneven, riders, rugged, sand, boards, ground, gravel	53
needle	thread, pin, eye, sewing, sharp, point, prick, thimble, haystack, thorn, hurt, injection, syringe, cloth, knitting	52
anger	mad, fear, hate, rage, temper, fury, ire, wrath, happy, fight, hatred, mean, calm, emotion, enrage	49
trash	garbage, waste, can, refuse, sewage, bag, junk, rubbish, sweep, scraps, pile, dump, landfill, debris, litter	49
soft	hard, light, pillow, plush, loud, cotton, fur, touch, fluffy, feather, furry, downy, kitten, skin, tender	46
city	town, crowded, state, capital, streets, subway, country, New York, village, metropolis, big, Chicago, suburb, county, urban	46
cup	mug, saucer, tea, measuring, coaster, lid, handle, coffee, straw, goblet, soup, stein, drink, plastic, sip	45
cold	hot, snow, warm, winter, ice, wet, frigid, chilly, heat, weather, freeze, air, shiver, arctic, frost	44
mountain	hill, valley, climb, summit, top, molehill, peak, plain, glacier, goat, bike, climber, range, steep, ski	42
slow	fast, lethargic, stop, listless, snail, cautious, delay, traffic, turtle, hesitant, speed, quick, sluggish, wait, molasses	42
river	water, stream, lake, mississippi, boat, tide, swim, flow, run, barge, creek, brook, fish, bridge, winding	42

Annexe D

Les modèles GAN et la théorie des espaces conceptuels

StyleGAN est un réseau antagoniste génératif (GAN)¹ capable de produire des images réalistes. L'une de ses versions les plus connues et étudiées est spécialisée sur les visages humains, mais le modèle étant open-source, il en existe de nombreuses versions spécialisées dans d'autres domaines.

Son architecture repose sur un *espace latent*, un espace vectoriel de haute dimension où chaque point correspond à un visage unique. Une propriété fondamentale de cet espace est sa continuité sémantique : une interpolation linéaire entre deux vecteurs latents (par exemple, un vecteur w_A pour le visage A et w_B pour le visage B) engendre une transition visuelle fluide et cohérente entre les deux visages. Il y a au moins trois parallèles possibles avec la théorie des espaces conceptuels :

- Les points représentent des instances de concepts (par ex. des visages spécifiques).
- Certaines dimensions de l'espace peuvent correspondre à des qualités sémantiques (par ex. l'âge, l'expression, la couleur de cheveux, etc.).
- La distance (généralement euclidienne) entre deux points est corrélée à leur dissimilarité perceptive.

Nous détaillons ci-dessous le deuxième et le troisième point.

L'interprétabilité des directions sémantiques

Niu et al. (2023) proposent une méthode qui permet de découvrir dans l'espace latent de StyleGAN2 des directions sémantiquement interprétables. Ils ajustent ces directions afin de réduire leur enchevêtrement avec d'autres facteurs de variation, de sorte que chaque direction obtenue corresponde de manière plus spécifique à l'attribut visé. Ils montrent par exemple qu'ils peuvent isoler une direction associée à l'action faciale "relever les coins des lèvres", qui permet de faire apparaître un sourire. En principe, en se déplaçant le long de ce "vecteur du

1. Pour les détails techniques voir BECHBERGER (2023, sec. 6.3.3, pp.331-337), qui s'intéresse plus spécifiquement à InfoGAN, modèle un peu antérieur à StyleGAN qui est plus simple et plus léger.

sourire", chaque visage passe progressivement d'une expression neutre à un large sourire tout en conservant en grande partie son identité et sa pose.

Partant, nous avons tenté d'identifier un vecteur $v_{sourire}$ dans l'espace latent $\mathcal{W}$ de StyleGAN3 qui est corrélée à l'intensité du sourire¹. En principe, cette direction linéaire permet de moduler le degré de sourire. Notons w un point arbitraire qui correspond à un visage dans l'espace latent de StyleGAN3. En ajoutant le vecteur $v_{sourire}$, pondéré par un scalaire α , au visage w , on peut moduler le degré de sourire sans altérer de manière significative les autres caractéristiques. L'équation de cette transformation est :

$$w' = w + \alpha \cdot v_{sourire}$$

où w' est le nouveau visage, $\alpha < 0$ réduit le sourire, $\alpha = 0$ préserve l'expression originale et $\alpha > 0$ l'intensifie. Cette opération est l'analogue d'un déplacement le long d'une unique dimension de qualité dans un espace conceptuel.

Pour vérifier visuellement qu'on peut effectivement "moduler le degré de sourire", on a échantillonné aléatoirement des vecteurs latents puis généré plusieurs séquences d'images en ajoutant la direction du sourire à différentes intensités. Dans l'image ci-dessous, nous appliquons cette direction à un visage en faisant varier $\alpha \in \{-2; -1,5; -1; 0; 1; 1,5; 2\}$ pour illustrer cette progression fluide :



La *distance* dans l'espace latent et la *dissimilarité* perçue

En principe, la proximité (resp. distance) dans un espace conceptuel reflète fidèlement la similarité (resp. dissimilarité) perçue. Bien que la métrique de l'espace latent de StyleGAN n'ait pas été conçue dans ce but, certaines études psychophysiques ont confirmé l'existence d'une corrélation entre la distance et la dissimilarité perçue. Plusieurs expériences montrent qu'il existe une relation *monotone* : plus deux vecteurs latents sont éloignés, plus les images correspondantes sont jugées dissemblables par des observateurs humains.

1. https://github.com/GwenTsang/conceptual_spaces/blob/main/StyleGAN/Smile.ipynb

Plusieurs travaux sur des visages générés par StyleGAN2 vont dans ce sens. SHIMIZU et al. (2022) ont constaté que des déplacements plus importants dans l'espace latent entraînaient des changements perceptifs plus marqués. De manière encore plus directe, MECKE et al. (2024) ont mené une expérience où les participants évaluaient la similarité de paires de visages générés avec des déplacements fixes dans l'espace latent ; les résultats ont montré une forte baisse de la similarité perçue à mesure que la distance latente augmentait.

Ce principe s'étend au-delà des visages. En utilisant un modèle StyleGAN entraîné sur des scènes d'intérieur, SON et al. (2022) ont créé des trajectoires circulaires dans l'espace latent. Ils mettent en oeuvre une tâche de jugement par paires, dont les résultats montrent que la similarité perçue par les participants diminue de façon systématique et continue avec l'augmentation de la distance angulaire entre les scènes sur la roue¹, ce qui corrobore l'idée qu'il y a une correspondance entre distance et dissimilarité perçue.

La plupart de ces études ont été menées avec StyleGAN2, mais en raison de la similarité d'architecture, ces conclusions devraient s'appliquer également à StyleGAN3.

Notons toutefois que le requisit de *convexité* n'est pas parfaitement satisfait. Certains travaux ont montré que pour de nombreux attributs binaires (souriant/non-souriant, jeune/âgé), la séparation dans l'espace latent est *approximativement linéaire*, c'est-à-dire qu'elle peut être modélisée par un hyperplan SHEN et al. (2020).

Remarquons de plus qu'il y a dans ce modèle une séparation fonctionnelle entre le traitement de la forme/structure d'une image et celui de ses textures/détails de surface. Ces différentes couches qui servent pour des attributs distincts pourraient peut-être s'interpréter par analogie comme des "domaines" au sens de la théorie des espaces conceptuels.

1. SON et al. (2022, p.452) : "With the generated scene wheels, we validated the perceived similarity of the generated scene images using pairwise similarity judgment. We observed that participants' similarity judgments corresponded to the images' distance on a wheel".




Schéma de l'injection de style par couche dans le générateur de StyleGAN. Le vecteur de style étendu $\mathbf{w}^+ \in \mathbf{W}^+$ est décomposé (symbolisé par l'accolade) en sous-vecteurs $\mathbf{w}_i$. Chacun de ces sous-vecteurs est ensuite injecté en entrée du bloc de génération correspondant, comme

$$\text{l'illustrent les flèches horizontales. } \mathbf{w}^+ = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n] \quad \text{où} \quad \mathbf{w}_i \in \mathbb{R}^{512}$$

Références

- ARNAULD, Antoine, Pierre NICOLE et Charles JOURDAIN. 1992. *La logique, ou l'art de penser*. Gallimard, Paris.
- BECHBERGER, Lucas. 2023. « Using Conceptual Spaces for Artificial Intelligence ». Universität Osnabrück, Osnabrück. Thèse de doct.
- BECHBERGER, Lucas et Kai-Uwe KÜHNBERGER. 2017. *Measuring Relations Between Concepts In Conceptual Spaces*.
- BENDIFALLAH, Lina, Julie ABBOU, Igor DOUVEN et Heather BURNETT. 2025. « Conceptual spaces for conceptual engineering? Feminism as a case study ». *Review of Philosophy and Psychology* 161, p. 199-229.
- BERNS, Roy S., Fred W. BILLMEYER et Max SALTZMAN. 2019. *Billmeyer and Saltzman's principles of color technology*. Wiley, Hoboken, NJ. Fourth edition.
- BOLT, Joe, Bob COECKE, Fabrizio GENOVESE, Martha LEWIS, Dan MARSDEN et Robin PIEDELEU. 2019. « Interacting conceptual spaces I: Grammatical composition of concepts ». *Conceptual spaces: Elaborations and applications*. Springer. P. 151-181.
- BORG, Ingwer et Patrick J. F. GROENEN. 2005. *Modern multidimensional scaling: theory and applications*. Springer, New York. 2nd ed.
- BORG, Ingwer, Patrick J. F. GROENEN et Patrick MAIR. 2013. *Applied Multidimensional Scaling*. Springer Berlin Heidelberg, Berlin, Heidelberg.
- BORG, Ingwer, Patrick J. F. GROENEN et Patrick MAIR. 2018. *Applied multidimensional scaling and unfolding*. Springer, Cham. 2nd ed.
- BRAINERD, C. J., M. CHANG et D. M. BIALER. 2020. « From association to gist ». *Journal of Experimental Psychology: Learning, Memory, and Cognition* 4611, p. 2106-2127.
- BRAINERD, C. J., M. CHANG, D. M. BIALER et X. LIU. 2023. « From association to gist: Some critical tests ». *Journal of Experimental Psychology: Learning, Memory, and Cognition*.
- BRAINERD, Charles Jon et Valerie F. REYNA. 2005. *The science of false memory*. Oxford University Press, New York.
- CHANG, M. et C.J. BRAINERD. 2021. « Semantic and phonological false memory: A review of theory and data ». *Journal of Memory and Language* 119, p. 104210.

- CHANG, Minyu et Brendan JOHNS. 2023. « Integrating distributed semantic models with an instance memory model to explain false recognition ». *Proceedings of the Annual Meeting of the Cognitive Science Society*.
- COSTA, Albert, Alfonso CARAMAZZA et Nuria SEBASTIAN-GALLES. 2000. « The cognate facilitation effect: implications for models of lexical access. » *Journal of Experimental Psychology: Learning, Memory, and Cognition* 265, p. 1283.
- DEESE, James. 1959. « Influence of Inter-Item Associative Strength upon Immediate Free Recall ». *Psychological Reports* 53, p. 305-312.
- DEESE, James. 1959. « On the prediction of occurrence of particular verbal intrusions in immediate recall ». *Journal of Experimental Psychology* 581, p. 17-22.
- DERRAC, Joaquin et Steven SCHOCKAERT. 2015. « Inducing semantic relations from conceptual spaces: a data-driven approach to plausible reasoning ». *Artificial Intelligence* 228, p. 66-94.
- DIJKSTRA, Ton, Koji MIWA, Bianca BRUMMELHUIS, Maya SAPPELLI et Harald BAAYEN. 2010. « How cross-language similarity and task demands affect cognate recognition ». *Journal of Memory and language* 623, p. 284-301.
- DOUVEN, Igor. 2016. « Vagueness, graded membership, and conceptual spaces ». *Cognition* 151, p. 80-95.
- DOUVEN, Igor. 2023. « The role of naturalness in concept learning: A computational study ». *Minds and Machines* 334, p. 695-714.
- DOUVEN, Igor, Lieven DECOCK, Richard DIETZ et Paul ÉGRÉ. 2013. « Vagueness: A Conceptual Spaces Approach ». *Journal of Philosophical Logic* 421, p. 137-160.
- DOUVEN, Igor et Peter GÄRDENFORS. 2020. « What are natural concepts? A design perspective ». *Mind & Language* 353, p. 313-334.
- DOUVEN, Igor, Steven VERHEYEN, Shira ELQAYAM, Peter GÄRDENFORS et Matías OSTA-VÉLEZ. 2023. « Similarity-based reasoning in conceptual spaces ». *Frontiers in Psychology* 14, p. 1234483.
- DOUVEN, Igor, Sylvia WENMACKERS, Yasmina JRAISSATI et Lieven DECOCK. 2017. « Measuring Graded Membership: The Case of Color ». *Cognitive Science* 413, p. 686-722.
- EKMAN, Gosta. 1954. « Dimensions of Color Vision ». *The Journal of Psychology* 382, p. 467-474.

- EVAIN, Solène. 2024. « Dimensions de variation de la parole spontanée pour l'étude inter-corpus des performances de systèmes de reconnaissance automatique de la parole ». Thèse de doct. 2024GRALM037.
- FAIRCHILD, Mark D. 2013. *Color appearance models*. John Wiley & Sons, Inc, Chichester, West Sussex. Third edition.
- FIORINI, Sandro Rama, Peter GÄRDENFORS et Mara ABEL. 2014. « Representing part-whole relations in conceptual spaces ». *Cognitive Processing* 152, p. 127-142.
- FOREST, Denis. 2005. *Histoire des aphasies : une anatomie de l'expression*. Presses universitaires de France, Paris. 1re éd. OCLC : ocm63109428.
- GALLO, David A. et Henry L. ROEDIGER III. 2002. « Variability among word lists in eliciting memory illusions: evidence for associative activation and monitoring ». *Journal of Memory and Language* 473, p. 469-497.
- GÄRDENFORS, Peter. 2000. *Conceptual Spaces: The Geometry of Thought*. The MIT Press.
- GÄRDENFORS, Peter. 2014. *Geometry of meaning : semantics based on conceptual spaces*. The MIT Press, Cambridge, Massachusetts. First MIT Press edition.
- GÄRDENFORS, Peter. 2019. « Convexity is an empirical law in the theory of conceptual spaces: Reply to Hernández-Conde ». *Conceptual spaces: Elaborations and applications*. Springer. P. 77-80.
- GUILLOT, Simon, Thibault PROUTEAU et Nicolas DUGUE. 2023. « Sparser is better: one step closer to word embedding interpretability ». *Proceedings of the 15th International Conference on Computational Semantics*. Association for Computational Linguistics, Nancy, France. P. 106-115.
- GUNTER, Raymond W., Glen E. BODNER et Tanjeem AZAD. 2007. « Generation and mnemonic encoding induce a mirror effect in the DRM paradigm ». *Memory & Cognition* 355, p. 1083-1092.
- HARNAD, Stevan. 1990. « The symbol grounding problem ». *Physica D: Nonlinear Phenomena* 421-3, p. 335-346.
- HEGE, Amanda C. G. et Chad S. DODSON. 2004. « Why Distinctive Information Reduces False Memories: Evidence for Both Impoverished Relational-Encoding and Distinctiveness Heuristic Accounts ». *Journal of Experimental Psychology: Learning, Memory, and Cognition* 304, p. 787-795.

- HENLEY, Nancy M. 1969. « A psychological study of the semantics of animal terms ». *Journal of verbal learning and verbal behavior* 82, p. 176-184.
- HUFF, Mark J, Glen E BODNER et Matthew R GRETZ. 2020. « Reducing false recognition in the Deese-Roediger/McDermott paradigm: Related lures reveal how distinctive encoding improves encoding and monitoring processes ». *Frontiers in Psychology* 11, p. 602347.
- HUFF, Mark J. et Glen E. BODNER. 2013. « When does memory monitoring succeed versus fail? Comparing item-specific and relational encoding in the DRM paradigm ». *Journal of Experimental Psychology: Learning, Memory, and Cognition* 394, p. 1246-1256.
- HUFF, Mark J. et Glen E. BODNER. 2019. « Item-specific and relational processing both improve recall accuracy in the DRM paradigm ». *Quarterly Journal of Experimental Psychology* 726, p. 1493-1506.
- HUFF, Mark J., Glen E. BODNER et Jonathan M. FAWCETT. 2015. « Effects of distinctive encoding on correct and false memory: A meta-analytic review of costs and benefits and their origins in the DRM paradigm ». *Psychonomic Bulletin & Review* 222, p. 349-365.
- HUNT, R. Reed, Rebekah E. SMITH et Kathryn R. DUNLAP. 2011. « How does distinctive processing reduce false recall? » *Journal of Memory and Language* 654, p. 378-389.
- HUTCHISON, Keith A. 2003. « Is semantic priming due to association strength or feature overlap? A microanalytic review ». *Psychonomic bulletin & review* 104, p. 785-813.
- KAHANA, Michael Jacob. 2012. *Foundations of human memory*. Oxford university press, New York.
- KISTLER, Max. 2016. *L'esprit matériel: réduction et émergence*. Ithaque, Paris. 1re édition.
- KLEIBER, Georges. 2007. « Adjectifs de couleur et gradation: une énigme... «très» colorée ». *Travaux de linguistique* 552, p. 9-44.
- LANGÉVIN, Sabine, Hélène SAUZÉON, Laurence TACONNAT et Bernard N'KAOUA. 2009. « Les fausses reconnaissances induites par les paradigmes DRM, MI et tâches dérivées ». *L'année psychologique* 1094, p. 699-729.
- MAQUESTIAUX, François. 2017. *Psychologie de l'attention*. De Boeck supérieur, Louvain-la-Neuve (Belgique). 2e éd.
- MCCABE, David P., Alison G. PRESMANES, Chuck L. ROBERTSON et Anderson D. SMITH. 2004. « Item-specific processing reduces false memories ». *Psychonomic Bulletin & Review* 116, p. 1074-1079.

- MECKE, Lukas, Daniel BUSCHEK, Uwe GRUENEFELD et Florian ALT. 2024. *Exploring the Lands Between: A Method for Finding Differences between AI-Decisions and Human Ratings through Generated Samples*.
- MOORE, Brian C. J. 2013. *An introduction to the psychology of hearing*. Brill, Leiden. Sixth edition.
- MOULLEC Matthieu and Douven, Igor. 2024. « Cheaper spaces ». *Minds and Machines* 351, p. 6.
- NAIRNE, James S. 2006. « Modeling distinctiveness: Implications for general memory theory ». *Distinctiveness and memory*, p. 27-46.
- NELSON, Douglas L et Cathy L McEvoy. 2000. « What is this thing called frequency? » *Memory & Cognition* 284, p. 509-522.
- NELSON, Douglas L., Vanesa M. MCKINNEY, Nancy R. GEE et Gerson A. JANCZURA. 1998. « Interpreting the influence of implicitly activated memories on recall and recognition ». *Psychological Review* 1052, p. 299-324.
- NIU, Yongjie, Mingquan ZHOU et Zhan LI. 2023. « Disentangling the latent space of GANs for semantic face editing ». *PLOS ONE* 1810.
- OSTA VÉLEZ, Matías. 2020. « Inference and the structure of concepts ». Université Paris-1 Panthéon Sorbonne et Ludwig-Maximilians Universität München. Thèse de doct.
- OSTA-VÉLEZ, Matías et Peter GÄRDENFORS. 2020. « Category-based induction in conceptual spaces ». *Journal of Mathematical Psychology* 96.
- PARRA, Marisol. 2013. « False recognition driven by meaning and form : The dynamics of bilingual memory representations ». Florida Atlantic University. Thèse de doct.
- PETILLI, Marco A., Marco MARELLI, Giuliana MAZZONI, Michela MARCHETTI, Luca RINALDI et Daniele GATTI. 2024. « From vector spaces to DRM lists: False Memory Generator, a software for automated generation of lists of stimuli inducing false memories ». *Behavior Research Methods* 564, p. 3779-3793.
- POTH, Nina L. 2019. « Conceptual spaces, generalisation probabilities and perceptual categorisation ». *Conceptual spaces: Elaborations and applications*. Springer. P. 7-28.
- PROUTEAU, Thibault. 2024. « Graphs, Words, and Communities : converging paths to interpretability with a frugal embedding framework ». Université Le Mans. PhD Thesis.
- PROUTEAU, Thibault, Victor CONNES, Nicolas DUGUÉ, Anthony PEREZ, Jean-Charles LAMIREL, Nathalie CAMELIN et Sylvain MEIGNIER. 2021. « SINr: fast computing of sparse interpretable

- node representations is not a sin! » *International Symposium on Intelligent Data Analysis*. P. 325-337.
- PROUTEAU, Thibault, Nicolas DUGUÉ et Simon GUILLOT. 2024. « From communities to interpretable network and word embedding: an unified approach ». *Journal of Complex Networks* 126, cnae034.
- RICKARD, John T., Janet AISBETT et Greg GIBBON. 2007. « Reformulation of the theory of conceptual spaces ». *Information Sciences* 17721, p. 4539-4565.
- ROEDIGER, Henry L. et Kathleen B. McDERMOTT. 1995. « Creating false memories: Remembering words not presented in lists ». *Journal of Experimental Psychology: Learning, Memory, and Cognition* 214, p. 803-814.
- ROEDIGER, Henry L., Jason M. WATSON, Kathleen B. McDERMOTT et David A. GALLO. 2001. « Factors that determine false recall: A multiple regression analysis ». *Psychonomic Bulletin & Review* 83, p. 385-407.
- ROMNEY, A. Kimball, Devon D. BREWER et William H. BATCHELDER. 1993. « Predicting Clustering From Semantic Structure ». *Psychological Science* 41, p. 28-34.
- SHEN, Yujun, Jinjin GU, Xiaou TANG et Bolei ZHOU. 2020. *Interpreting the Latent Space of GANs for Semantic Face Editing*.
- SHEPARD, Roger N. 1962. « The analysis of proximities: Multidimensional scaling with an unknown distance function. II ». *Psychometrika* 273, p. 219-246.
- SHEPARD, Roger N. 1974. « Representation of structure in similarity data: Problems and prospects ». *Psychometrika* 394, p. 373-421.
- SHEPARD, Roger N. 1987. « Toward a universal law of generalization for psychological science ». *Science* 2374820, p. 1317-1323.
- SHIMIZU, Kye, Naoto IENAGA, Kazuma TAKADA, Maki SUGIMOTO et Shunichi KASAHARA. 2022. « Human Latent Metrics: Perceptual and Cognitive Response Correlates to Distance in GAN Latent Space for Facial Images ». *ACM Symposium on Applied Perception 2022*. ACM, TBC USA. P. 1-10.
- SMITH, Kendal A., Mark J. HUFF, Laura A. PAZOS, Joseph L. SMITH et Kyla M. COSENTINO. 2022. « Item-specific encoding reduces false recognition of homograph and implicit mediated critical lures ». *Memory* 303, p. 293-308.

- SON, Gaeun, Dirk B. WALTHER et Michael L. MACK. 2022. « Scene wheels: Measuring perception and memory of real-world scenes with a continuous stimulus space ». *Behavior Research Methods* 541, p. 444-456.
- STADLER, Michael A., Henry L. ROEDIGER et Kathleen B. McDERMOTT. 1999. « Norms for word lists that create false memories ». *Memory & Cognition* 273, p. 494-500.
- STEYVERS, Mark, Richard M. SHIFFRIN et Douglas L. NELSON. 2005. « Word Association Spaces for Predicting Semantic Similarity Effects in Episodic Memory ». *Experimental cognitive psychology and its applications*. HEALY, Alice F. American Psychological Association, Washington. P. 237-249.
- TREFFERS-DALLER, Jeanine. 2019. « What defines language dominance in bilinguals? » *Annual Review of Linguistics* 51, p. 375-393.
- VAN HEUVEN, Walter J.B., Ton DIJKSTRA et Jonathan GRAINGER. 1998. « Orthographic Neighborhood Effects in Bilingual Word Recognition ». *Journal of Memory and Language* 393, p. 458-483.
- WARD, Zina B. 2023. « William Whewell, Cluster Theorist of Kinds ». *Hopos: The Journal of the International Society for the History of Philosophy of Science* 132, p. 362-386.